상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

SJTU

대규모 모델 기술과 발전

장줘성 (Zhang Zhuosheng)
상하이 교통대학 컴퓨터학원
zhangzs@sjtu.edu.cn
https://bcmi.sjtu.edu.cn/~zhangzs

음수사원 • 애국영교

목차

- 대규모 모델 개요
  - 발전 개관
  - 개념 및 범주
- 사전 학습 모델
  - 주요 유형
  - 모델 아키텍처
- 대규모 언어 모델
  - 패러다임 변화
  - 주요 대표 모델
  - 핵심 기술
  - 배포 방식
- 개념 확장
  - 버티컬(특화) 대규모 모델
  - 멀티모달 파운데이션
  - 에이전트 파운데이션

목차

- 대규모 모델 개요
  - 발전 개관
  - 개념 및 범주
- 사전 학습 모델
  - 주요 유형
  - 모델 아키텍처
- 대규모 언어 모델
  - 패러다임 변화
  - 주요 대표 모델
  - 핵심 기술
  - 배포 방식
- 개념 확장
  - 버티컬(특화) 대규모 모델
  - 멀티모달 파운데이션
  - 에이전트 파운데이션

인공지능의 발전

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 인공지능 기술은 소규모 데이터에서 빅데이터로, 소형 모델에서 대규모 모델로, 전용에서 범용으로 발전하며 대규모 모델 시대에 진입함
- **방대한 비라벨 데이터에서 대규모 자기지도 사전 학습을 수행하여 풍부한 언어 지식과 세계 지식을 습득**
- **자연어 상호작용을 통해 다양한 태스크를 수행하며, 다중 시나리오·다목적·학제 간 태스크 처리 역량을 갖춤**

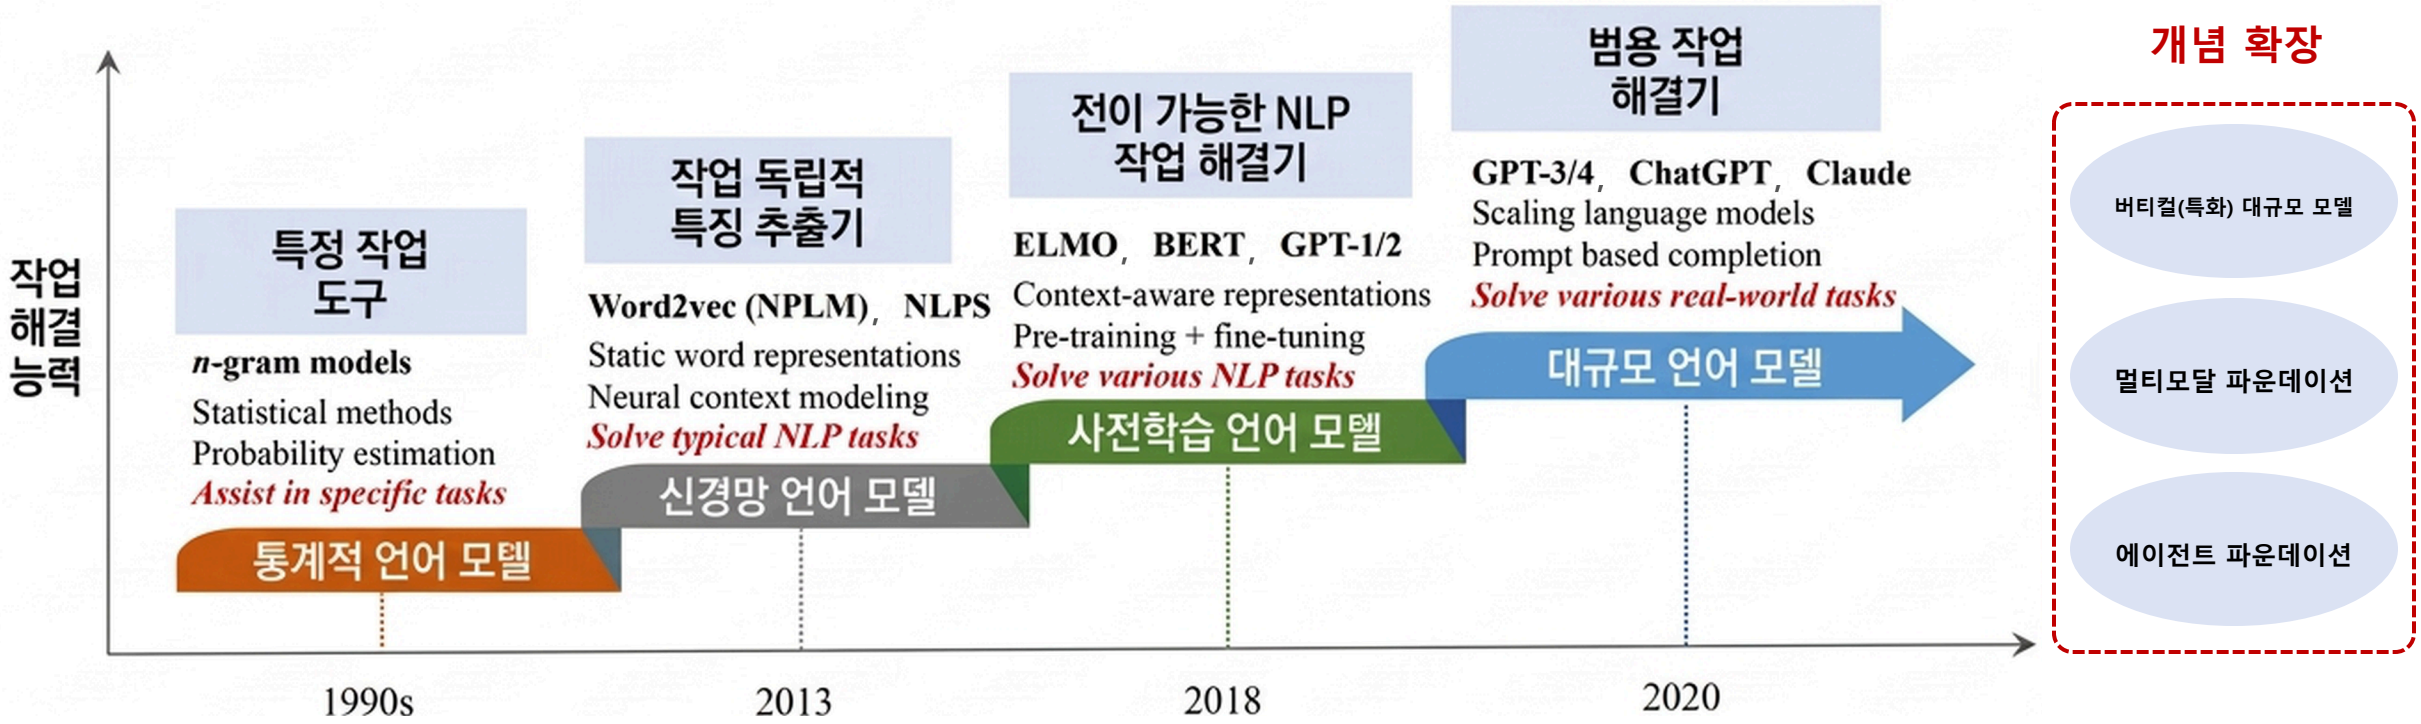

[1] Zhao, Wayne Xin, et al. A Survey of Large Language Models. arXiv preprint arXiv:2303.18223.

대규모 모델의 범주

목차

- 대규모 모델 개요
  - 발전 개관
  - 대규모 모델 범주
- **사전 학습 모델**
  - **주요 유형**
  - **모델 아키텍처**
- 대규모 언어 모델
  - 패러다임 변화
  - 주요 대표 모델
  - 핵심 기술
- 개념 확장
  - 버티컬(특화) 대규모 모델
  - 멀티모달 파운데이션
  - 에이전트 파운데이션

사전 학습 언어 모델 (PLM)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- **언어 지능의 새로운 패러다임 — 사전 학습 언어 모델 (대표: ELMo, BERT, GPT-1/2)**
  - **대규모 데이터에서 자기지도 사전 학습 후 파인튜닝을 거쳐 각 태스크에 적응하며, 빅데이터·대규모 모델·고성능 연산을 효과적으로 활용**
  - **주로 언어 분석 및 이해 태스크에 활용됨**

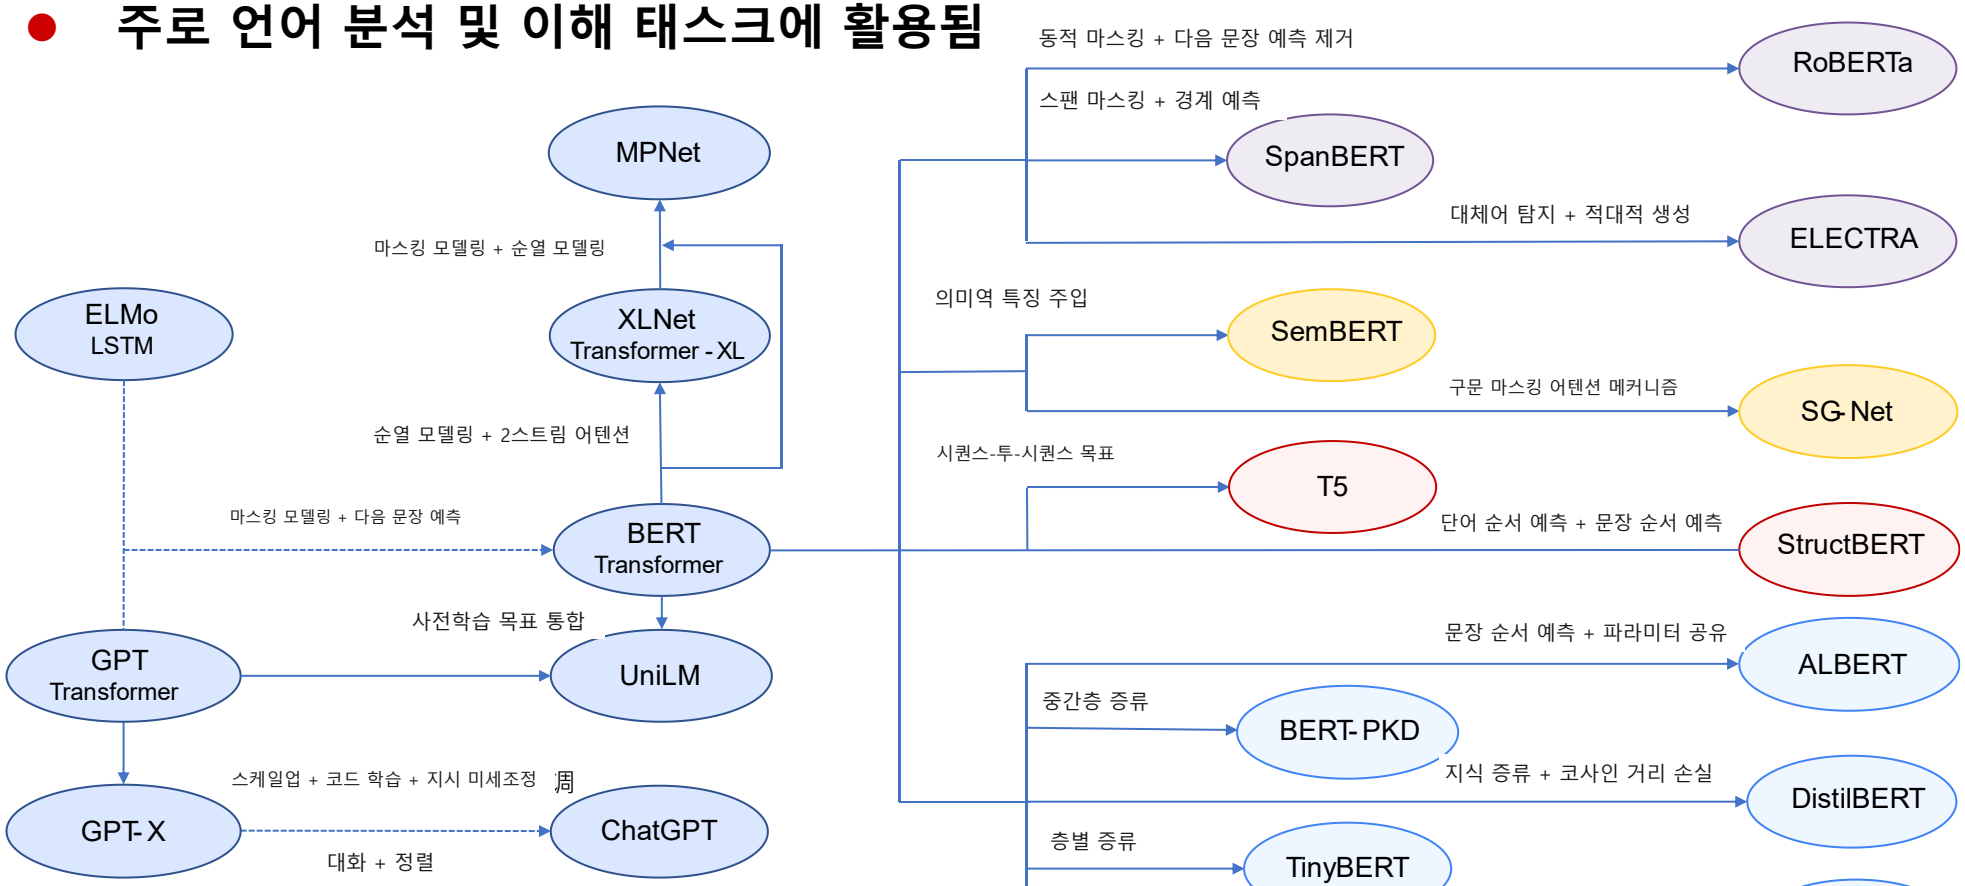

[1] Zhang, Zhuosheng, et al. Machine Reading Comprehension: The Role of Contextualized Language Models and Beyond. arXiv preprint arXiv:2005.06249.

주요 유형

인코더 모델 (Encoder-Only)

디코더 모델 (Decoder-Only)

인코더-디코더 모델 (Encoder-Decoder)

시간에 따른 각 모델 유형의 관심도 변화

- 2021년경 이전에는 인코더 모델과 인코더-디코더 모델의 파생형이 계속 등장했으며, 이러한 흐름을 "BERTology"라 부르기도 함
- 2021년경 이후 디코더 모델이 비약적으로 발전하면서 "Next-Level"의 생성형 대규모 모델 시대를 맞이함

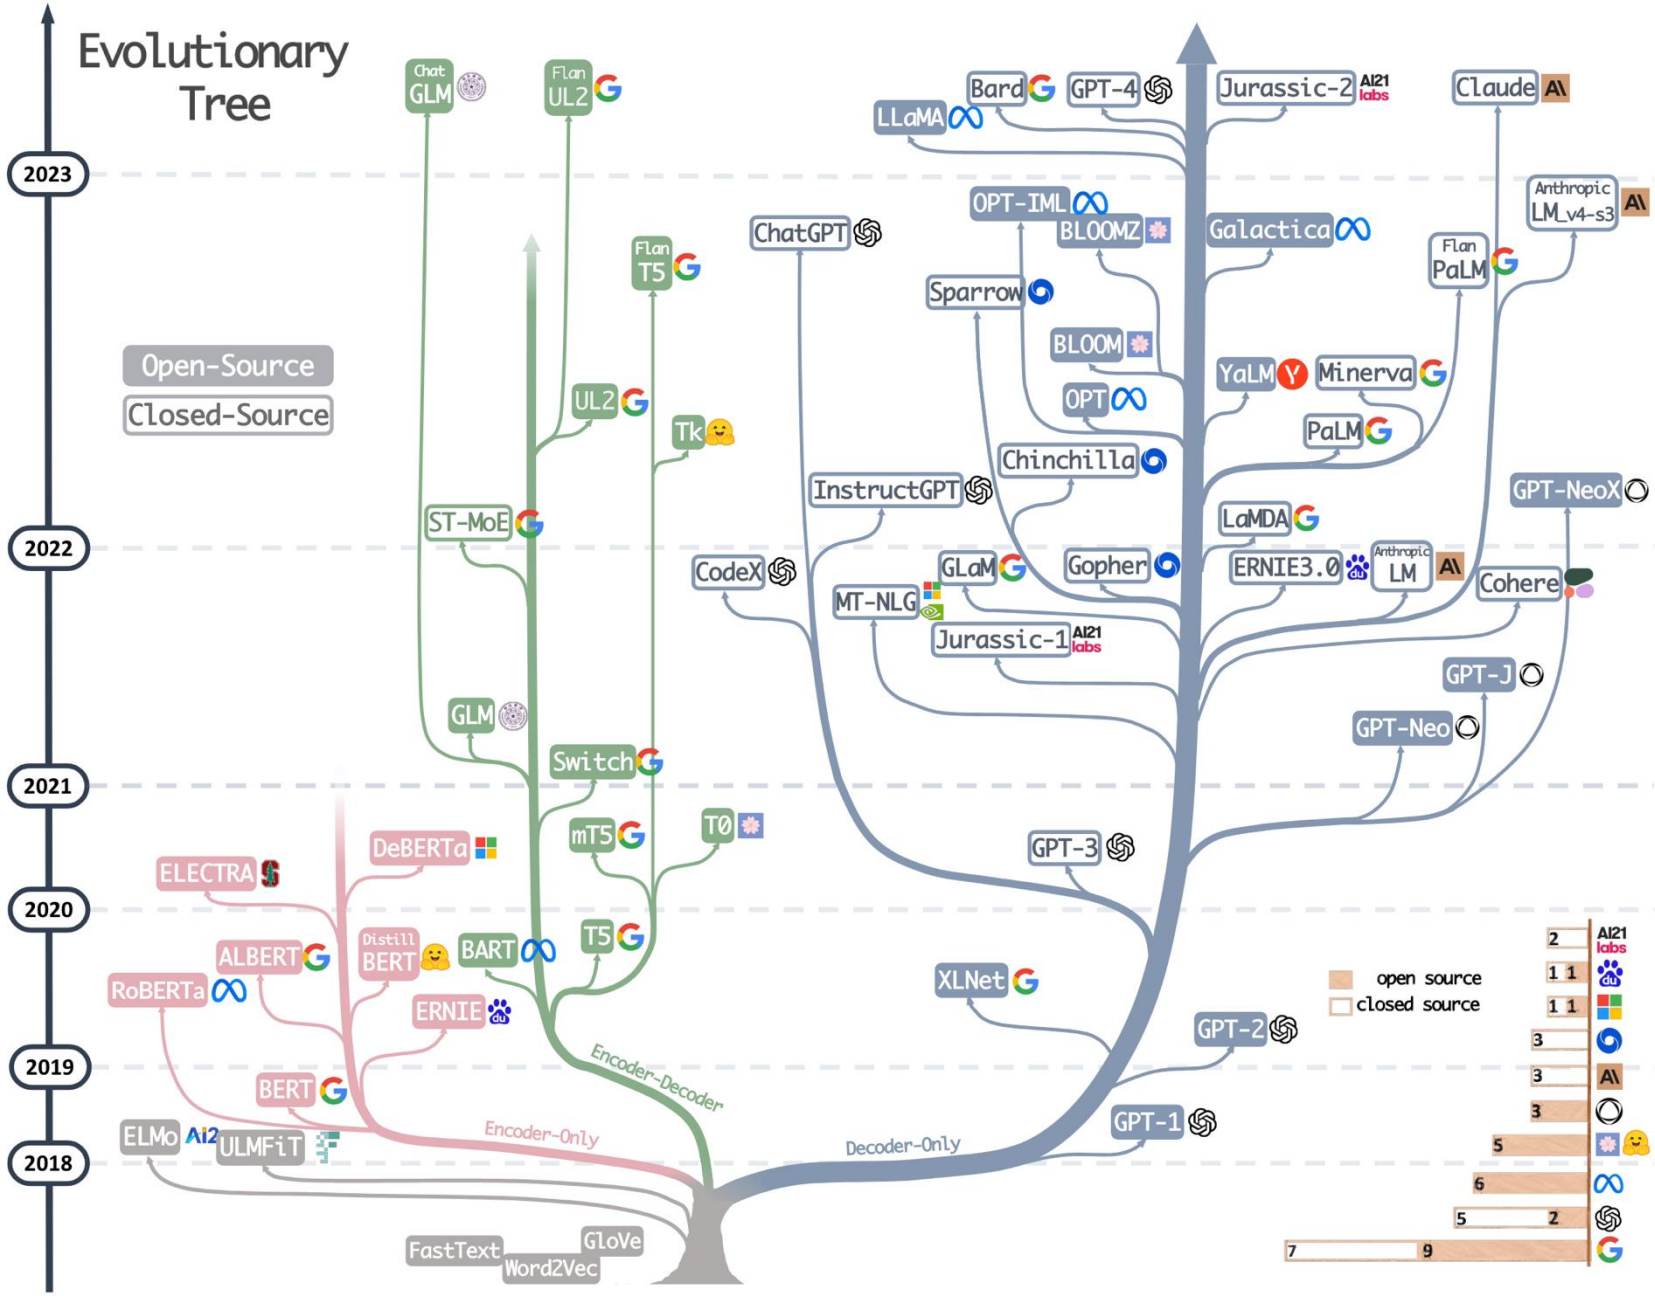

[1] Rogers, Anna, et al. A primer in BERTology: What we know about how BERT works. TACL, 2021.

[2] Minaee, Shervin, et al. Large language models: A survey. arXiv preprint arXiv:2402.06196.

사전 학습 모델링의 관점

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 자기지도 사전 학습 모델링 관점에서 아키텍처별로 학습 목표에 차이가 존재함
  - 인코더 모델: 마스크 언어 모델링 (Masked Language Modeling, MLM)
  - 디코더 모델: 자기회귀 언어 모델링 (Auto-regressive Language Modeling)
  - 인코더-디코더 모델: 시퀀스-투-시퀀스 모델링 (Sequence to Sequence Modeling)

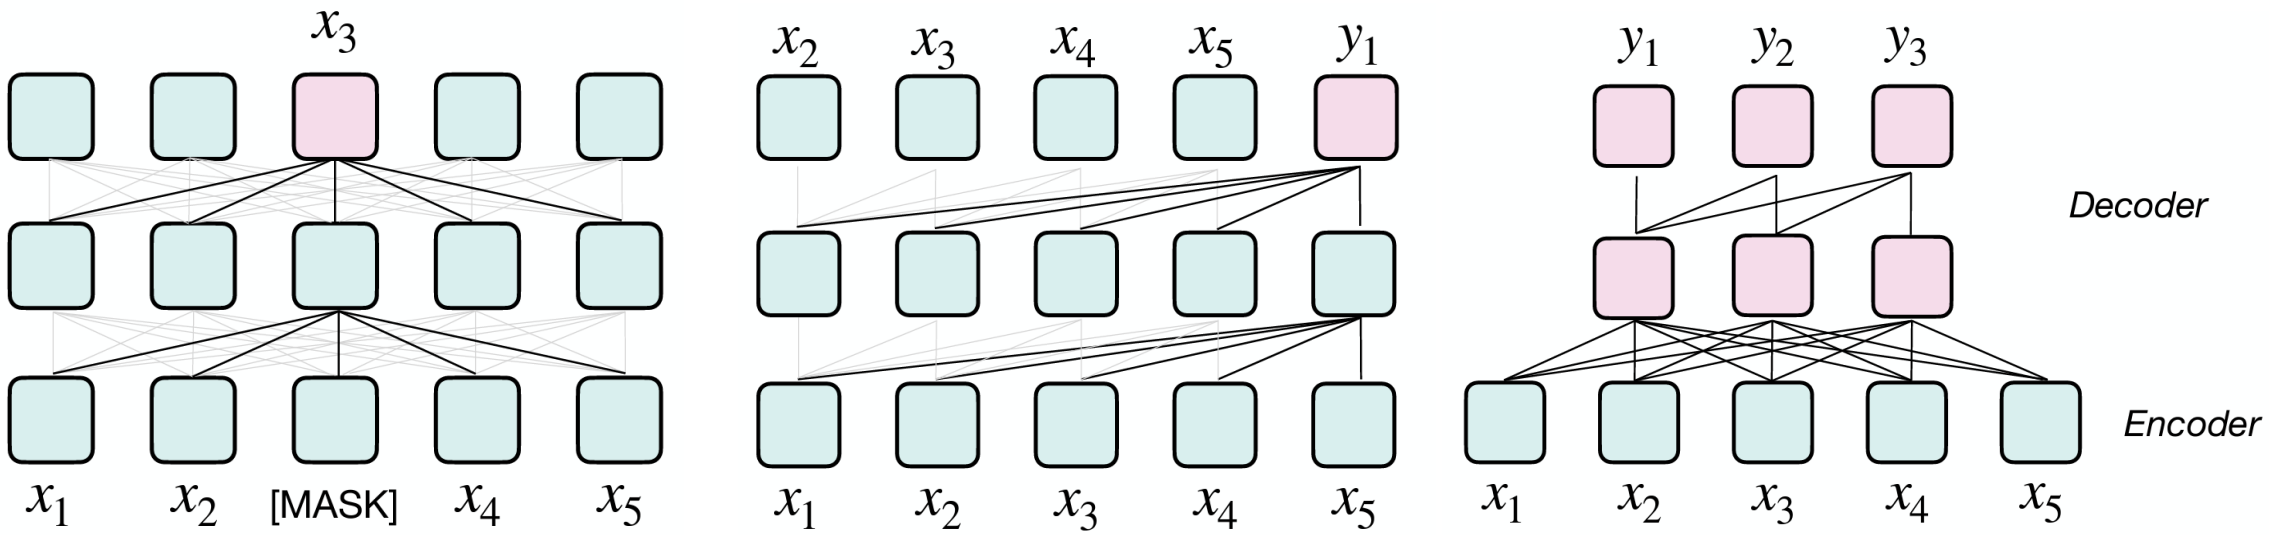

$$\mathcal{L}_{\text{MLM}} = -\sum_{x_m \in M(\mathbf{x})} \log \mathbf{P}(x_m | \mathbf{x}_{\setminus M(x)})$$

$$\mathcal{L}_{\text{LM}} = -\log \mathbf{P}(\mathbf{x}) = -\sum_{i=1}^{T} \log \mathbf{P}(x_i | x_{<i})$$

$$\mathcal{L}_{\text{Seq2Seq MLM}} = -\sum_{\mathbf{x}_{i:j} \in M(\mathbf{x})} \sum_{t=i}^{j} \log \mathbf{P}(x_t | \mathbf{x}_{\setminus M(\mathbf{x})}, \mathbf{x}_{i:t-1})$$

[1] Ding, Ning, et al. Parameter-efficient fine-tuning of large-scale pre-trained language models. Nature Machine Intelligence, 2023.

인코더 모델

- 주요 학습 목표: 마스크 언어 모델링 (Masked Language Modeling, MLM)

$$\mathcal{L}_{\text{MLM}} = -\sum_{x_m \in M(\mathbf{x})} \log \mathbf{P}(x_m | \mathbf{x}_{\setminus M(x)})$$

- 대표 모델: BERT, RoBERTa, ALBERT

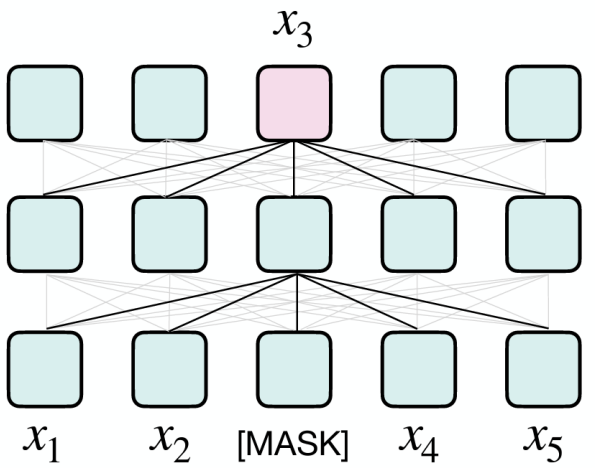

NotNext 학습

Transformer Encoder

[CLS] 우리 함께 직접 [MASK] 대규모 모델 개발 전 과정

디코더 모델

상하이교통대학

- 주요 학습 목표: 자기회귀 언어 모델링 (Auto-regressive Language Modeling)

$$\mathcal{L}_{\mathrm{LM}} = -\log \mathbf{P}(\mathbf{x}) = -\sum_{i=1}^{T} \log \mathbf{P}(x_i | x_{<i})$$

- 대표 모델: GPT, Llama, PaLM 시리즈 등

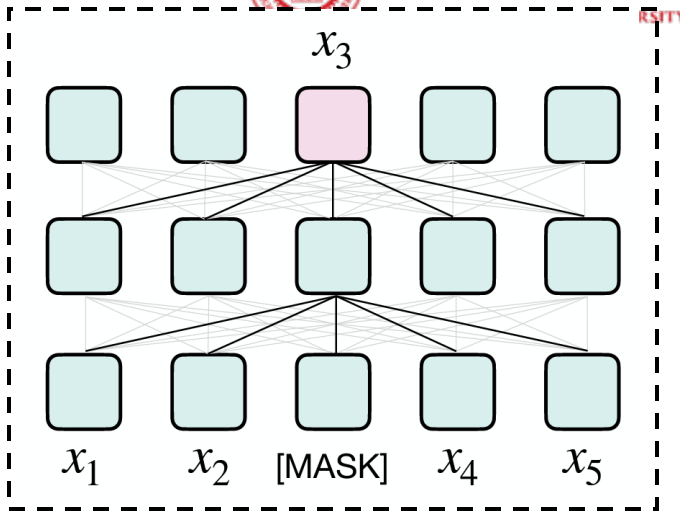

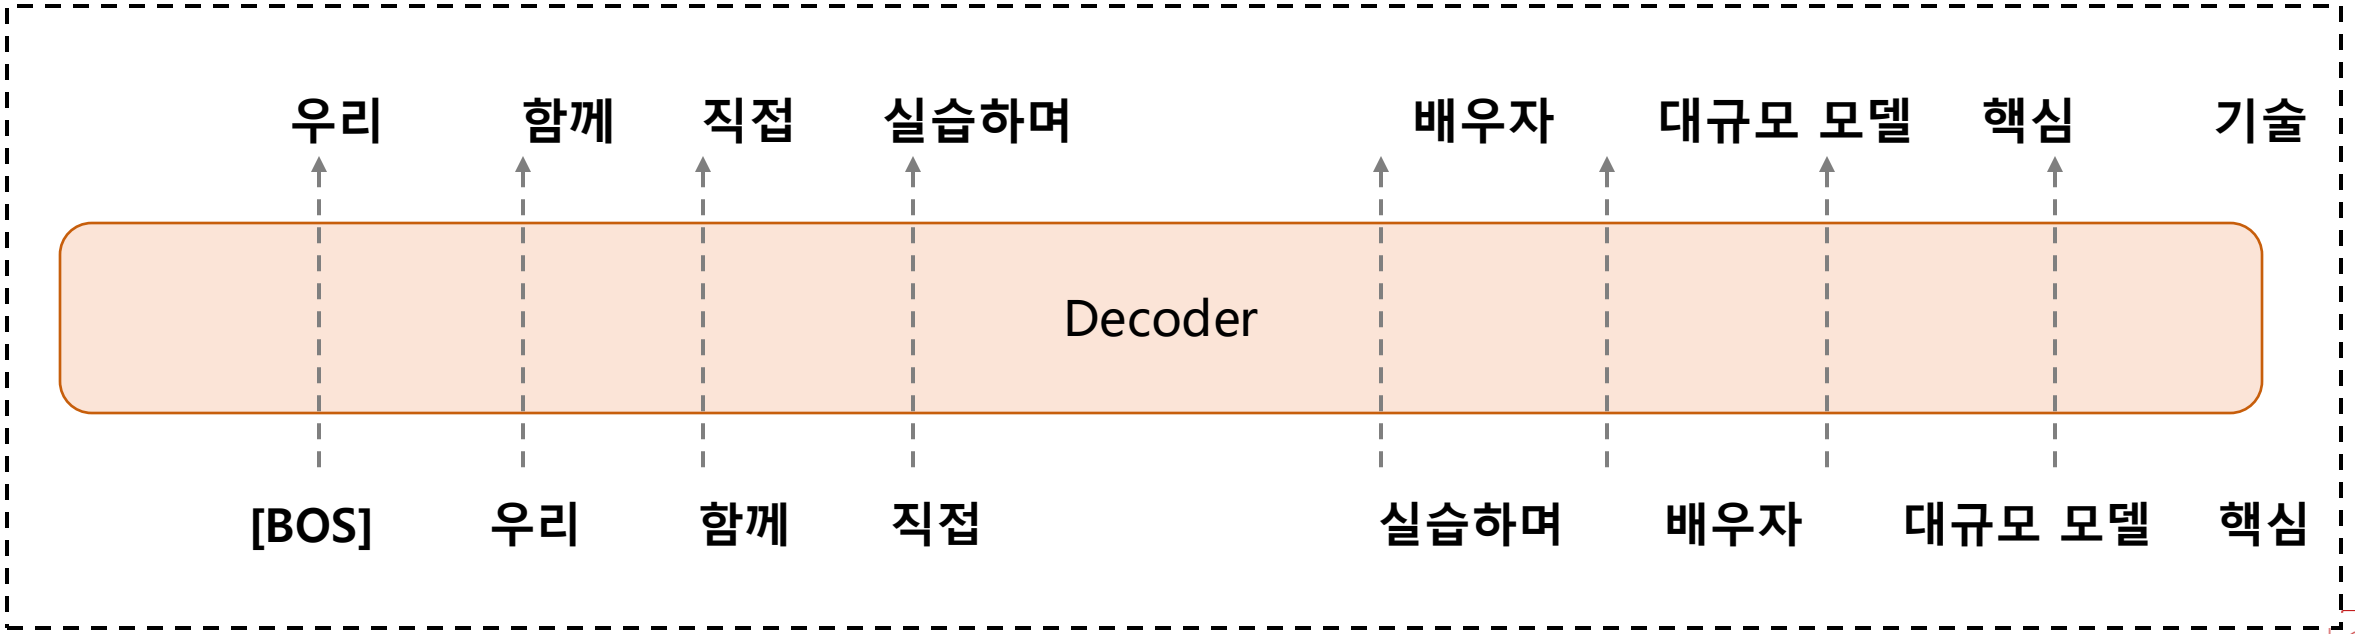

장단점 비교

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

인코더 모델 (BERT)

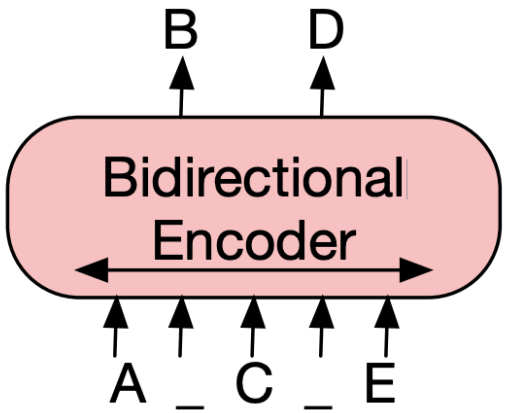

장점: 양방향 문맥을 활용하여 언어 이해 성능이 뛰어남

단점:

[MASK] 특수 토큰 사용으로 인해 사전학습-파인튜닝 간 괴리가 발생하며, 마스킹된 토큰들이 서로 독립이라 가정함

디코더 모델 (GPT)

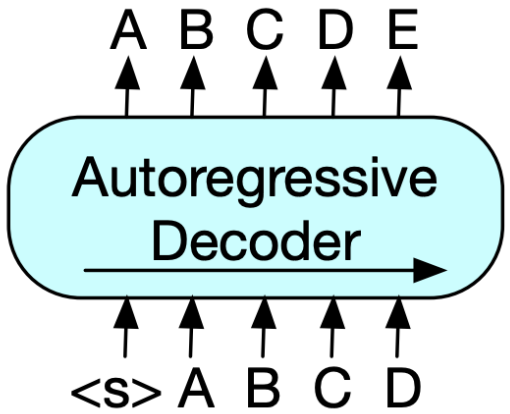

장점: 생성 태스크에 본질적으로 적합하며 대규모 학습 데이터 구축이 용이함

단점:

단방향 모델링에 국한되어 양방향 문맥 정보를 동시에 활용하기 어려움

인코더-디코더 모델

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 주요 학습 목표: 시퀀스-투-시퀀스 모델링 (Sequence to Sequence Modeling)

$$\mathcal{L}_{\text{Seq2Seq MLM}} = -\sum_{\mathbf{x}_{i:j} \in M(\mathbf{x})} \sum_{t=i}^{j} \log \mathbf{P}(x_t | \mathbf{x}_{\setminus M(\mathbf{x})}, \mathbf{x}_{i:t-1})$$

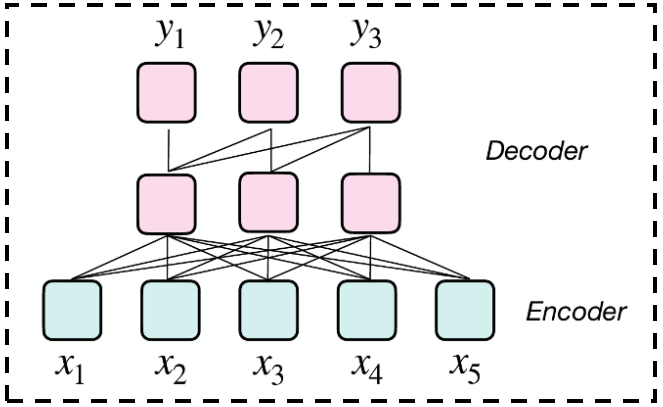

- 대표 모델: T5, BART

<X> 직접 실습 <Y> 대규모 모델 <Z>

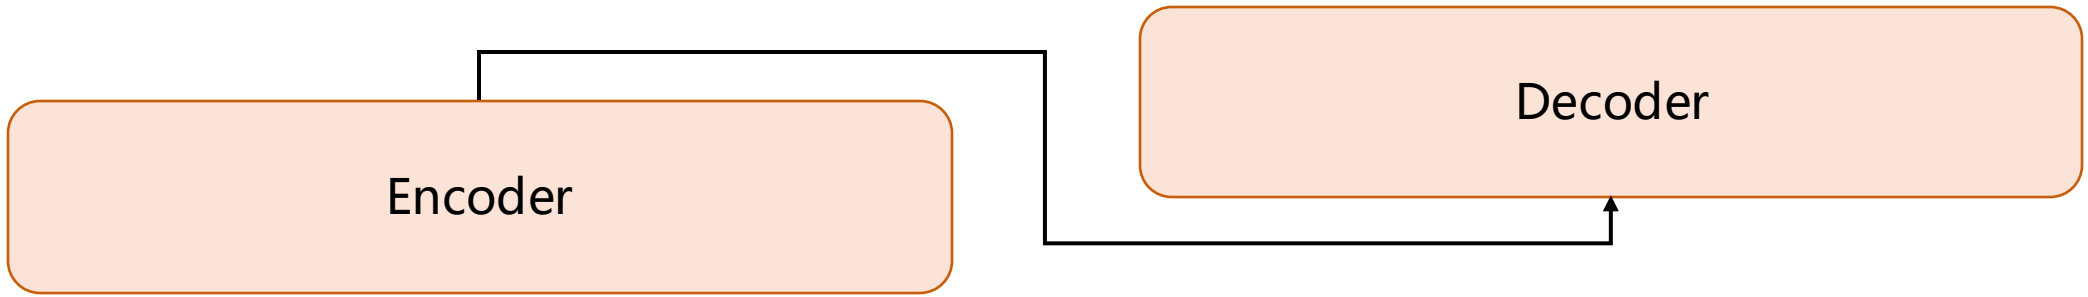

우리 함께 <Y> 배우자 <Y> 대규모 모델 핵심 기술

응용 시나리오에 따른 모델 선택

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

인코더 모델

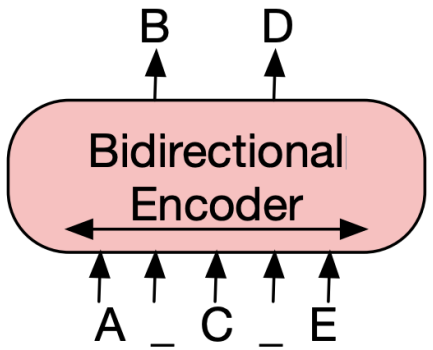

분류·회귀 등 판별(Discriminative) 태스크

디코더 모델

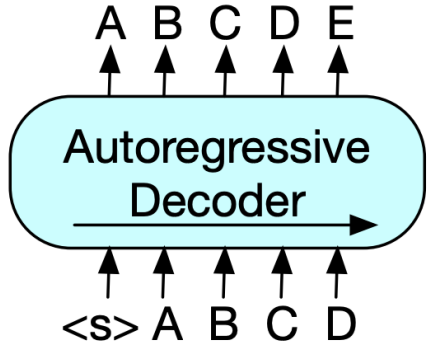

개방형 생성(Generative) 태스크에 적합

인코더-디코더 모델

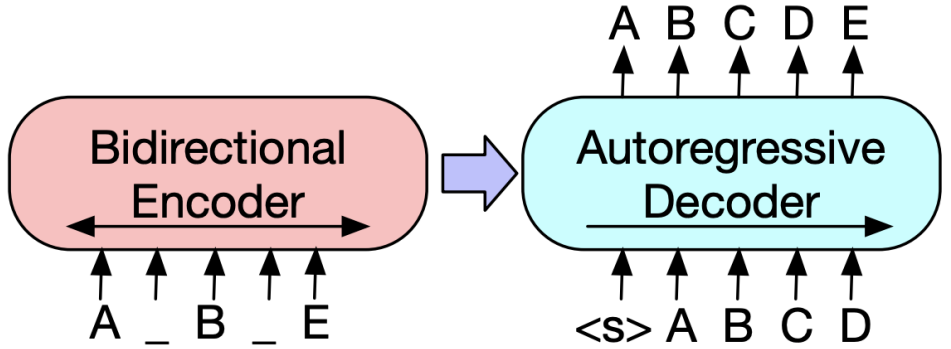

판별 및 생성 능력을 모두 겸비

사전 학습 언어 모델: 모델 아키텍처

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- **RNN (LSTM)**
  - 단어 간 의존 관계를 포착하나, 그래디언트 소실/폭주 문제로 인해 RNN은 학습이 어려운 경우가 많음
  - 연산 속도가 느리고 장기 의존성(Long-range dependency) 학습 능력에 한계가 있음
- **Transformer √ (Attention is all you need)**
  - RNN의 순환 구조를 완전히 배제하고 자기 어텐션(Self-Attention) 메커니즘을 채택해 전역적으로 처리
  - **세 가지 가중치 행렬(Query, Key, Value)로 문맥 의존 관계를 포착**
  - 다층 신경망: 각 계층은 멀티헤드 어텐션(Multi-Head Attention)과 피드포워드 네트워크(FFN)로 구성
  - **위치 인코딩(Positional Encoding) 추가**

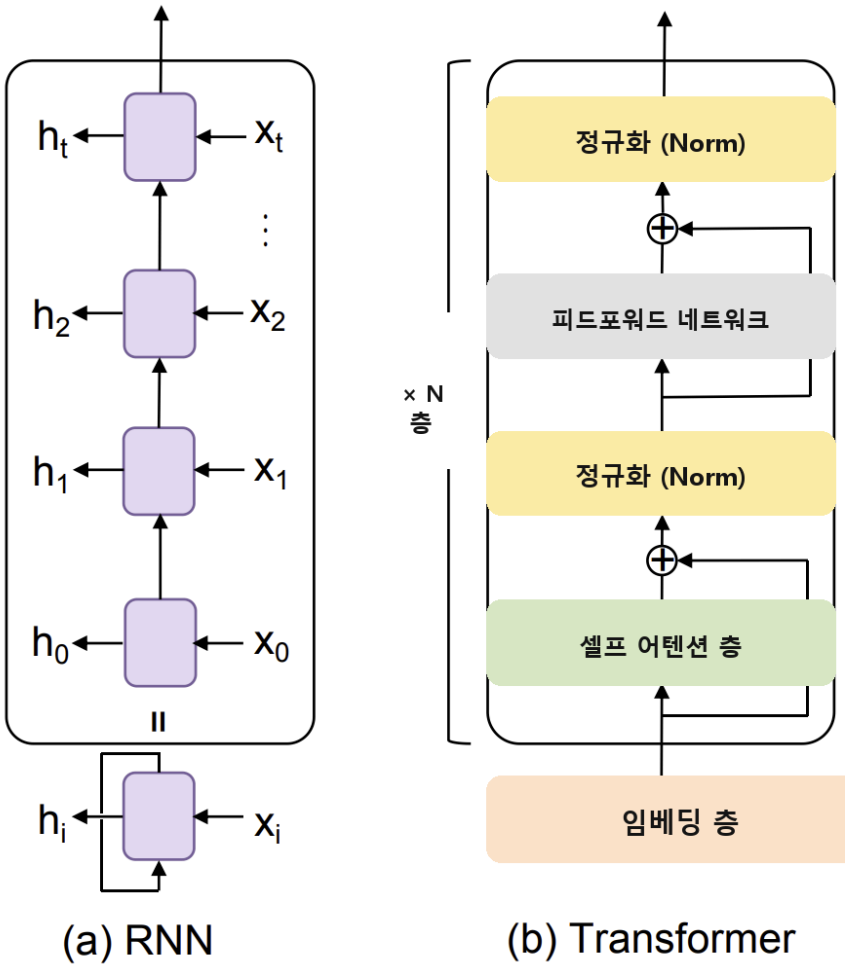

(a) RNN (b) Transformer

목차

- 대규모 모델 개요
  - 발전 개관
  - 대규모 모델 범주
- 사전 학습 모델
  - 주요 유형
  - 모델 아키텍처
- **대규모 언어 모델**
  - **패러다임 변화**
  - **핵심 기술**
  - **주요 대표 모델**
  - **배포 방식**
- **개념 확장**
  - **버티컬(특화) 대규모 모델**
  - **멀티모달 파운데이션**
  - **에이전트 파운데이션**

대규모 모델 개관

상하이교통대학

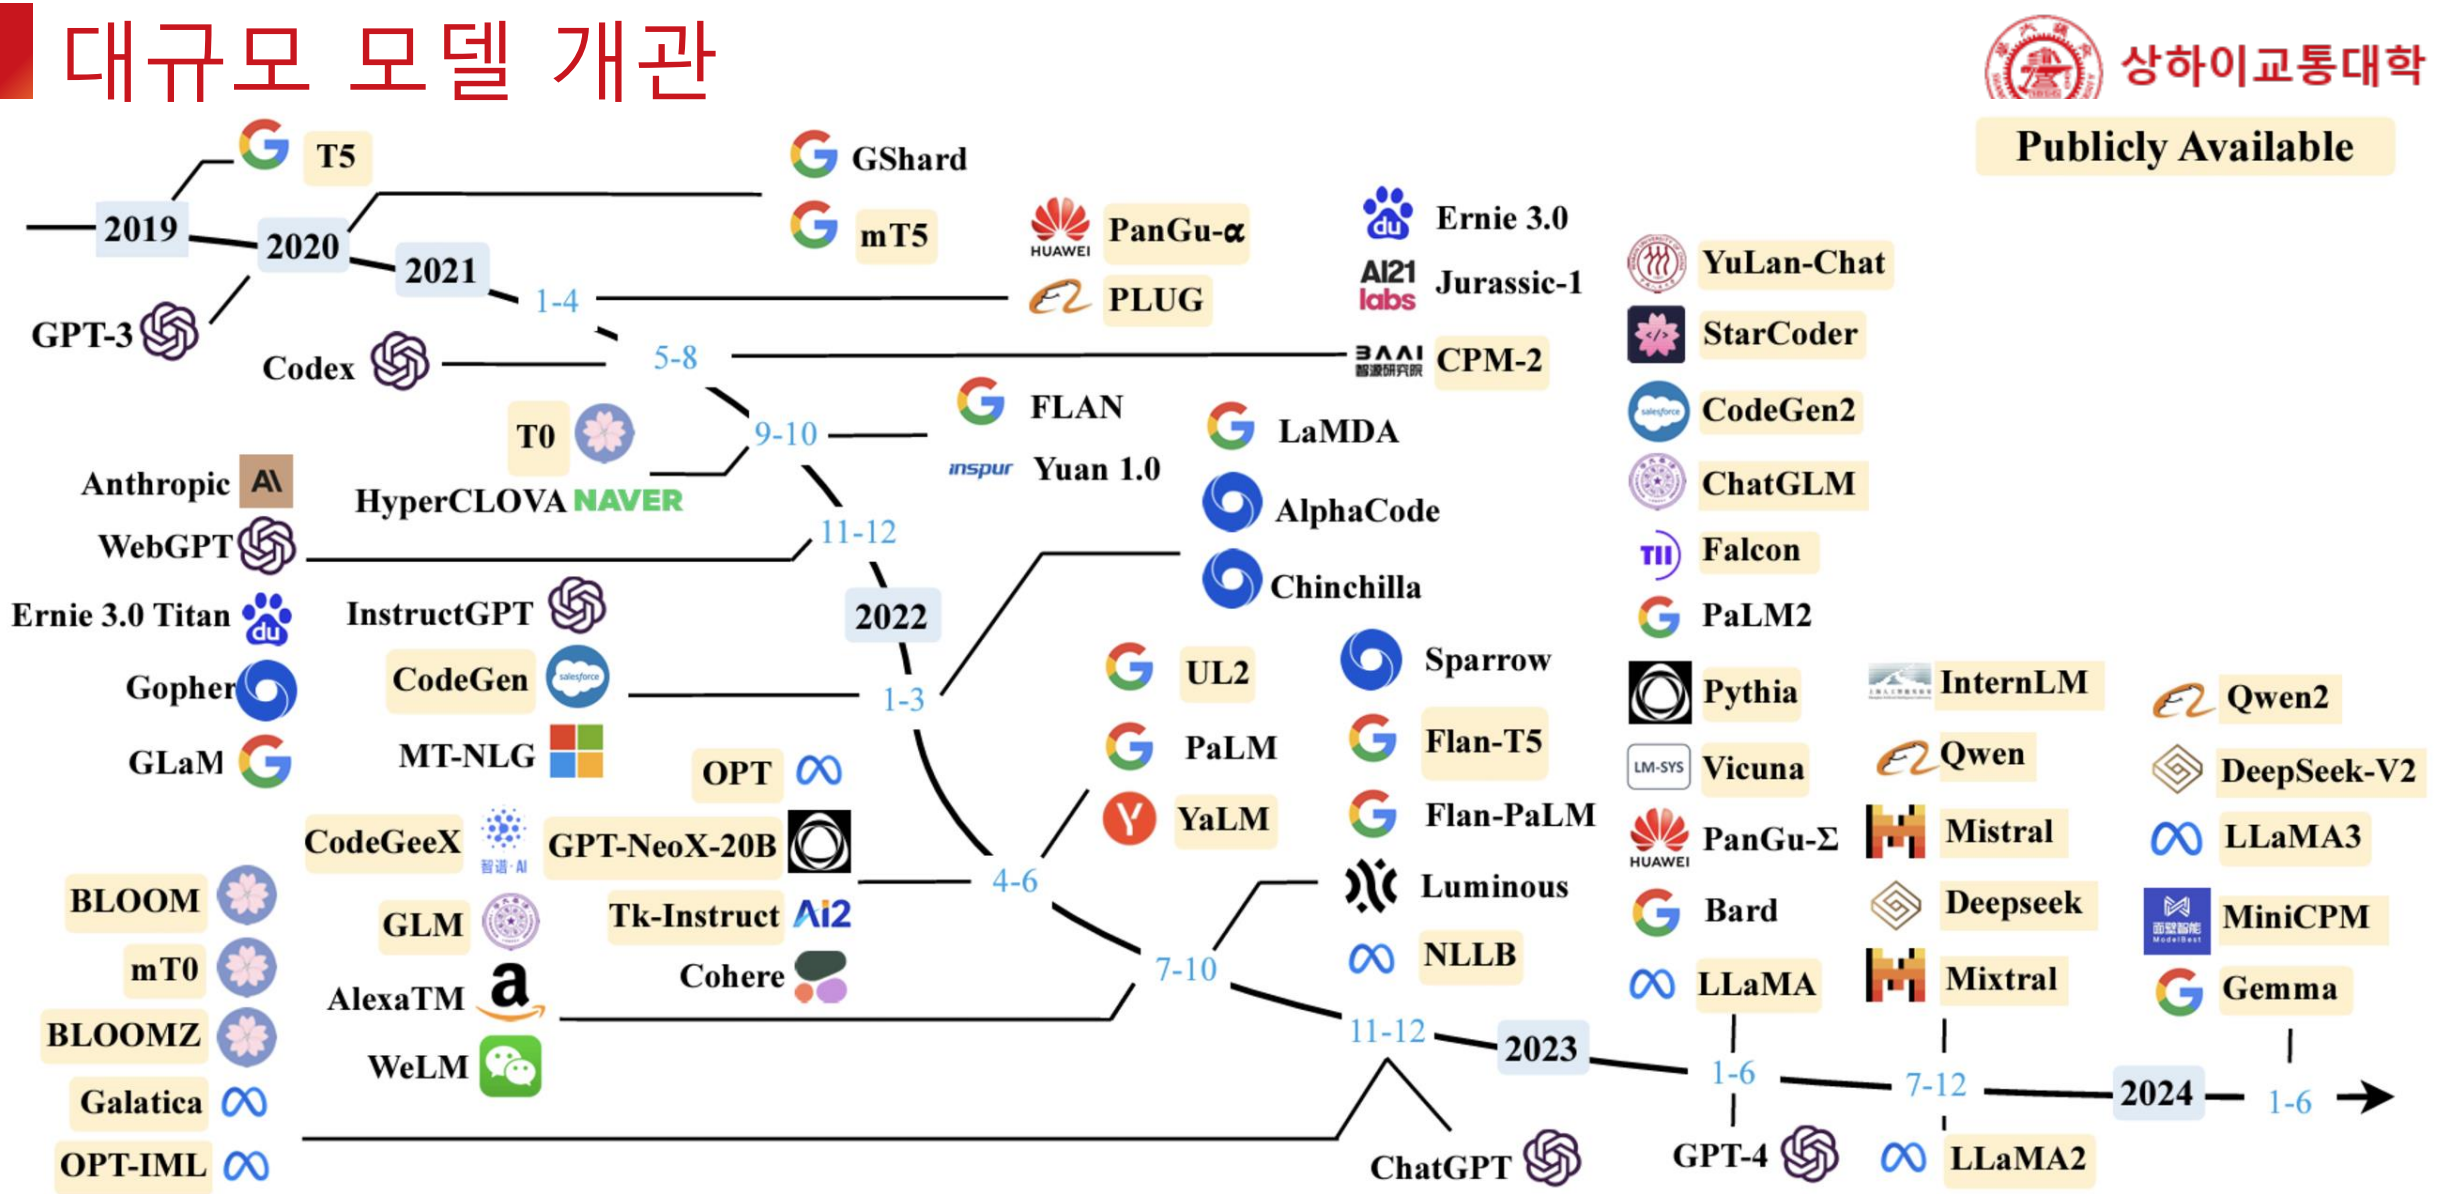

[1] Zhao, Wayne Xin, et al. A Survey of Large Language Models. arXiv preprint arXiv:2303.18223.

대규모 모델 시대의 패러다임 변화

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 기술 패러다임의 전환: 개별 태스크 전용 학습에서 중앙화된 "사전 학습 + 사후 학습" 및 "사전 학습 + 프롬프트 러닝"으로
- 태스크 패러다임의 통합: 각기 독립된 태스크 형식에서 통합된 시퀀스-투-시퀀스(Seq2Seq) 모델링 형식으로

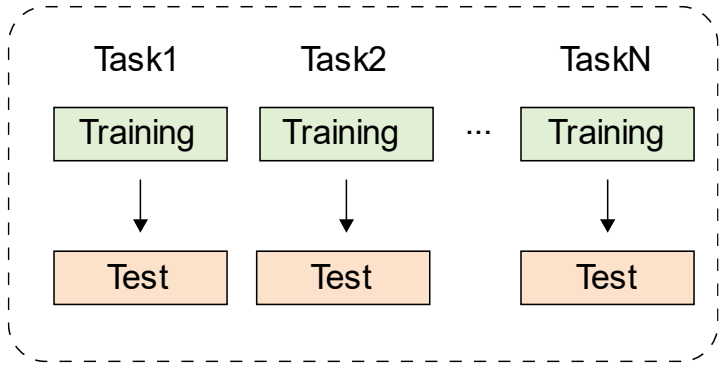

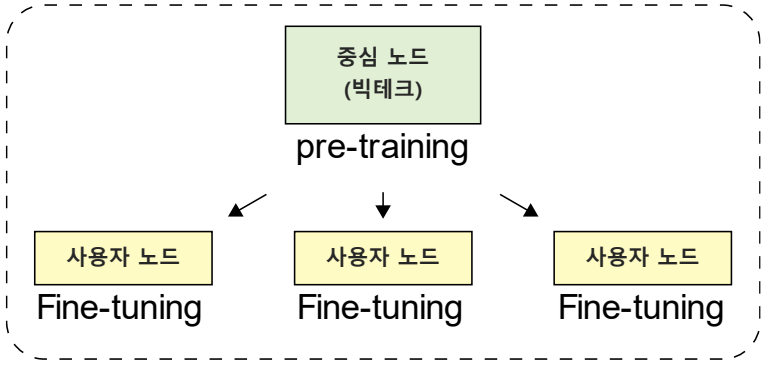

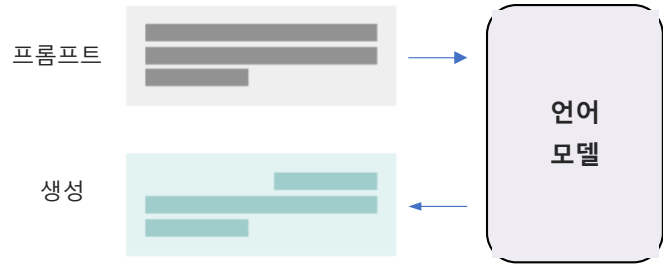

과거

각 태스크마다 사용자가 개별적으로 모델을 구축하고 전체 머신러닝 학습을 직접 수행

현재 (학습)

중심 노드에서 범용 대규모 사전 학습을 완수해 완성에 가까운 모델을 제공하고, 이를 표준 모듈로 삼아 사후 학습(SFT/RL)으로 폭넓은 시나리오에 적응

현재 (응용)

- 프롬프트 엔지니어링
  - 인컨텍스트 러닝
  - 사고의 사슬 프롬프팅
  - 워크플로우 오케스트레이션
- 경량화 학습

개별화된 학습 → 사전 학습 + 사후 학습(SFT/RL)

대규모 모델 시대의 패러다임 변화

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 기술 패러다임의 전환: 개별 태스크 전용 학습에서 중앙화된 "사전 학습 + 사후 학습" 및 "사전 학습 + 프롬프트 러닝"으로
- **태스크 패러다임의 통합: 각기 독립된 태스크 형식에서 통합된 시퀀스-투-시퀀스(Seq2Seq) 모델링 형식으로**

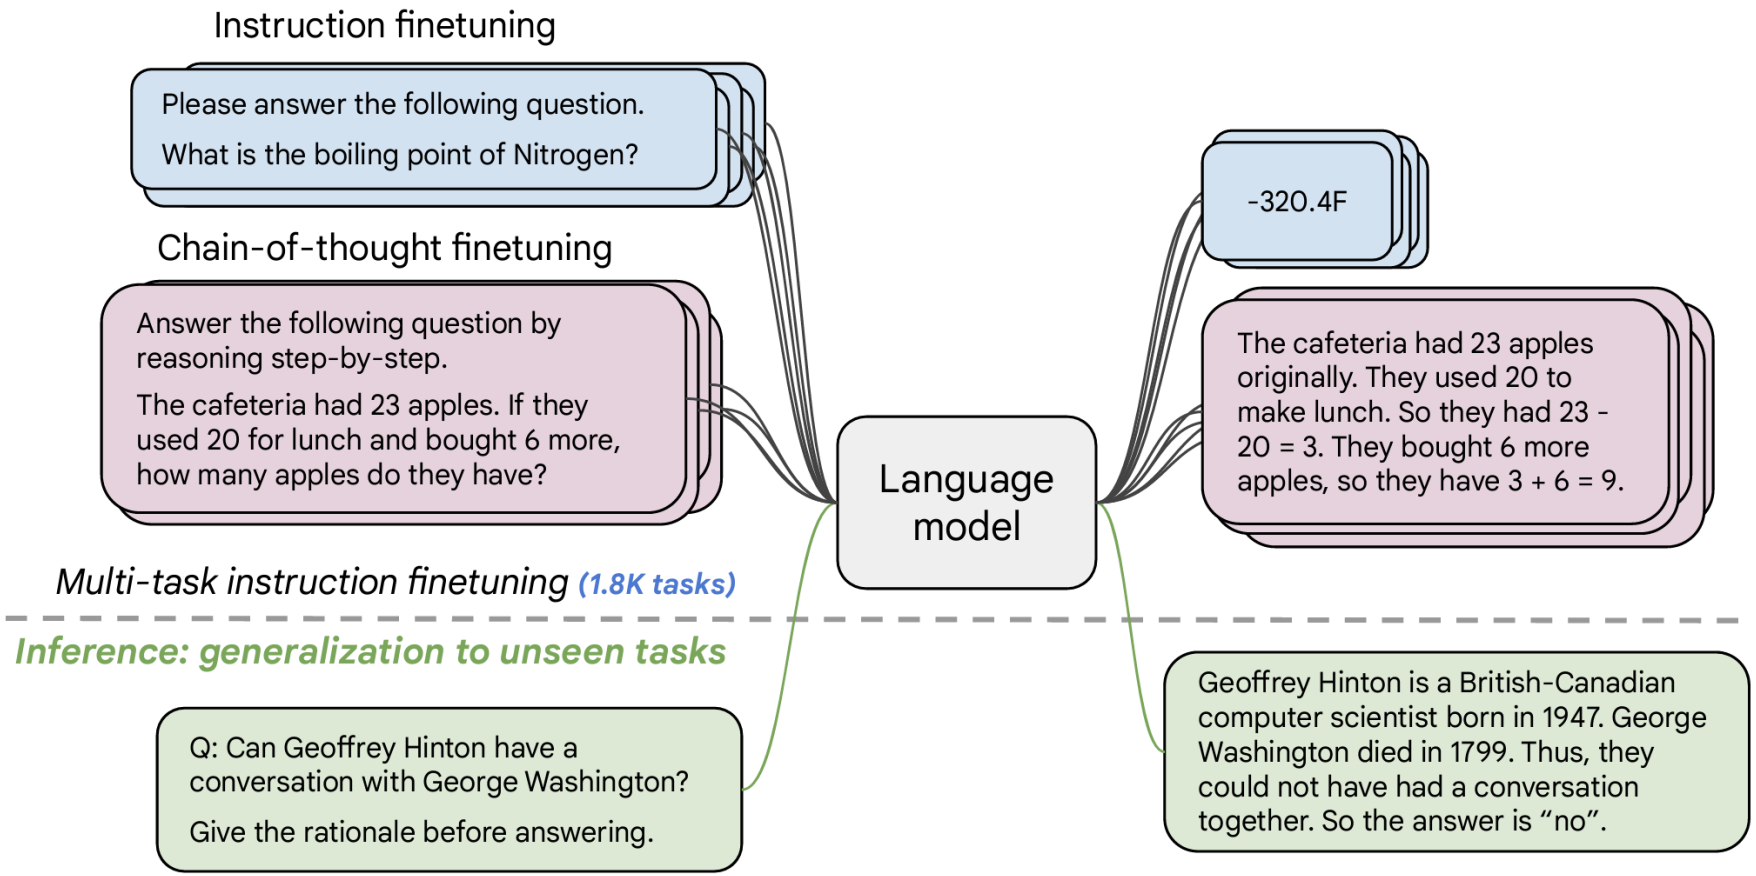

[1] Chung, H.W., et al. Scaling instruction-finetuned language models. JMLR, 2024.

대규모 언어 모델 (LLM)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

❑ 대규모 언어 모델: 강력한 알고리즘과 막대한 연산 자원을 투입해 방대한 데이터로부터 복잡한 확률 분포 함수를 학습

- 더 많은 연산량과 더 큰 추론 비용
- 더 강력한 일반화 성능 및 창발적 능력(Emergent Abilities) 발현

유형 비교	사전 학습 언어 모델 (PLM) (중소형 모델, 일반 모델)	대규모 언어 모델 (LLM) (생성형 대규모 모델)
대표 모델	ELMo，BERT，GPT-1/2	GPT-3、ChatGPT、LLaMA
모델 구조	RNN，Transformer	Transformer
어텐션 메커니즘	양방향, 단방향	단방향
학습 방식	디노이징 오토인코더	자기회귀 생성
특화 태스크 유형	이해, 판별	생성
모델 규모	약 10B 파라미터 이하	약 10B~100B 파라미터 이상
다운스트림 적용 방식	파인튜닝	파인튜닝 & 프롬프트 러닝
창발적 능력	소규모 데이터 도메인 전이	인컨텍스트 러닝, 사고의 사슬

[1] Minaee, Shervin, et al. Large language models: A survey. arXiv preprint arXiv:2402.06196.

대규모 언어 모델 (LLM)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

모델	기업 / 기관	파라미터	사전학습 하드웨어	일	GPU·일	데이터 규모
"소형" 언어 모델						
ELMo (Peters et al., 2018)	AllenAI	96M	3×1080 GPU	14	42	4GB
$BERT_{large}$ (Devlin et al., 2019)	Google	340M	64× TPU	4	256	16GB
GPT-1 (Radford et al., 2018)	OpenAI	117M	8× P6000 GPU	25	200	4.5GB
XLNet (Yang et al., 2019)	Google	360M	512× TPU	2.5	1280	160GB
$ELECTRA_{large}$ (Clark et al., 2020)	Google	335M	-	-	-	160GB
대규모 언어 모델 (LLM)						
BLOOM (Scao et al., 2022)	BigScience	176B	384×A100 GPU	118	45K	1.61TB
Chinchilla (Hoffmann et al., 2022)	DeepMind	70B	4096×TPU v3	-	-	140T Tokens
ERNIE3.0 (Sun et al., 2021)	바이두 百度	10B	384×V100 GPU	-	-	4TB
Galactica (Taylor et al., 2022)	Meta AI	120B	128×A100 GPU	-	-	106B Tokens
Gopher (Rae et al., 2021)	DeepMind	280B	4096×TPU v3	38	156K	10.5TB (300B Tokens)
GPT-3 (Brown et al., 2020)	OpenAI	175B	175 약 100 GPU	约 90	158K	45TB
LaMDA (Thoppilan et al., 2022)	Google	137B	1024×TPU v3	57.7	59K	1.56T Tokens
M6 (Lin et al., 2021)	알리바바 阿里巴巴	100B	128×A100 GPU	-	-	1.9T 이미지 + 97.2G 텍스트
OPT (Zhang et al., 2022)	Meta AI	175B	99 약 100 GPU	约 60	60K	180B Tokens
PaLM (Chowdhery et al., 2022)	Google	540B	6144×TPU v4	50	307K	780B Tokens
T5 (Raffel et al., 2020)	Google	11B	1024×TPU v3	25	26K	750GB

- 학습 데이터: 다원화
  - 단순한 자연어 텍스트뿐만 아니라 자연어 텍스트, 프로그래밍 코드, 화학 분자식, 유전자 서열, 나아가 이미지까지 다양한 데이터의 결합
- 학습 방식: 판별식 사전 학습(BERT 등)에서 생성형 사전 학습(GPT 등)으로 전면적 전환
- 모델 아키텍처: 양방향 Transformer에서 단방향 Transformer(Decoder-only)
- 응용 방식: 파인튜닝에서 사용자 친화적인 프롬프트 러닝으로 발전
  - 필요 샘플 감소: 일정량의 라벨 데이터가 필수였던 것에서 퓨샷(Few-shot), 나아가 제로샷(Zero-shot)으로
  - 프롬프트 러닝의 작동 방식이 인간-기계 대화 형태에 근접함

핵심 기술

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

❑ 대표적인 3대 핵심 구축 단계: 사전 학습(Pre-training), 지시문 파인튜닝(SFT), 정렬(Alignment)

대규모 모델 구축 프로세스

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

	사전 학습	지시문 파인튜닝	정렬 (Alignment)
데이터	원시 데이터 수천억 토큰의 텍스트, 도서, 웹페이지, 코드 등	라벨링된 사용자 지시문 수만 건의 사용자 자연어 지시문과 대응되는 정답	라벨링된 선호도 비교 쌍 수십만~수백만 건의 비교 쌍 및 사용자 지시문
모델	베이스 모델	SFT 모델	정렬된 모델
목표	도메인/범용 지식 습득	지시 이행 능력 향상	더 안전하고 유용한 응답 생성
	수개월 단위의 학습 시간	수일 단위의 학습 시간	수일 단위의 학습 시간

핵심 기술 1: 사전 학습 (Pre-training)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

알고리즘

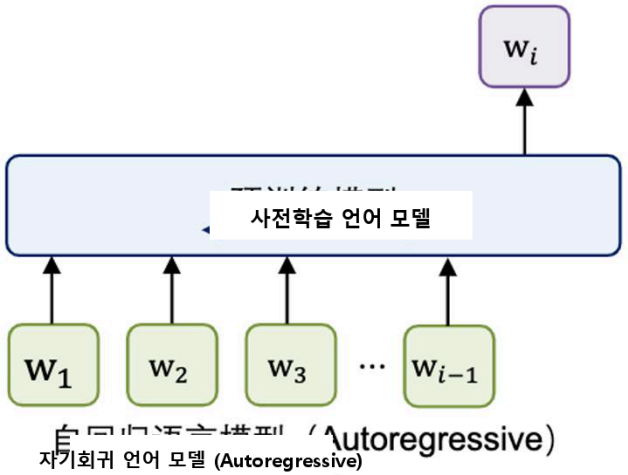

자기회귀 언어 모델 (Autoregressive)

$$p(w_1, w_2, \cdots, w_n) = \prod_{i=1}^{n} p(w_i | w_1, w_2, \cdots, w_{i-1})$$

데이터 **컴퓨팅 파워**

	Model	Release Time	Size (B)	Base Model	Adaptation IT	Adaptation RLHF	Pre-train Data Scale	Latest Data Timestamp	Hardware (GPUs / TPUs)	Training Time	Evaluation ICL	Evaluation CoT
Publicly Available	T5 [82]	Oct-2019	11	-	-	-	1T tokens	Apr-2019	1024 TPU v3	-	✓	-
	mT5 [83]	Oct-2020	13	-	-	-	1T tokens	-	-	-	✓	-
	PanGu-α [84]	Apr-2021	13*	-	-	-	1.1TB	-	2048 Ascend 910	-	✓	-
	CPM-2 [85]	Jun-2021	198	-	-	-	2.6TB	-	-	-	-	-
	T0 [28]	Oct-2021	11	T5	✓	-	-	-	512 TPU v3	27 h	✓	-
	CodeGen [86]	Mar-2022	16	-	-	-	577B tokens	-	-	-	✓	-
	GPT-NeoX-20B [87]	Apr-2022	20	-	-	-	825GB	-	96 40G A100	-	✓	-
	Tk-Instruct [88]	Apr-2022	11	T5	✓	-	-	-	256 TPU v3	4 h	✓	-
	UL2 [89]	May-2022	20	-	-	-	1T tokens	Apr-2019	512 TPU v4	-	✓	✓
	OPT [90]	May-2022	175	-	-	-	180B tokens	-	992 80G A100	-	✓	-
	NLLB [91]	Jul-2022	54.5	-	-	-	-	-	-	-	✓	-
	CodeGeeX [92]	Sep-2022	13	-	-	-	850B tokens	-	1536 Ascend 910	60 d	✓	-
	GLM [93]	Oct-2022	130	-	-	-	400B tokens	-	768 40G A100	60 d	✓	-
	Flan-T5 [69]	Oct-2022	11	T5	✓	-	-	-	-	-	✓	✓
	BLOOM [78]	Nov-2022	176	-	-	-	366B tokens	-	384 80G A100	105 d	✓	-
	mT0 [94]	Nov-2022	13	mT5	✓	-	-	-	-	-	✓	-
	Galactica [35]	Nov-2022	120	-	-	-	106B tokens	-	-	-	✓	✓
	BLOOMZ [94]	Nov-2022	176	BLOOM	✓	-	-	-	-	-	✓	-
	OPT-IML [95]	Dec-2022	175	OPT	✓	-	-	-	128 40G A100	-	✓	✓
	LLaMA [57]	Feb-2023	65	-	-	-	1.4T tokens	-	2048 80G A100	21 d	✓	-
	Pythia [96]	Apr-2023	12	-	-	-	300B tokens	-	256 40G A100	-	✓	-
	CodeGen2 [97]	May-2023	16	-	-	-	400B tokens	-	-	-	✓	-
	StarCoder [98]	May-2023	15.5	-	-	-	1T tokens	-	512 40G A100	-	✓	✓
	LLaMA2 [99]	Jul-2023	70	-	✓	✓	2T tokens	-	2000 80G A100	-	✓	-
	Baichuan2 [100]	Sep-2023	13	-	✓	✓	2.6T tokens	-	1024 A800	-	✓	-
	QWEN [101]	Sep-2023	14	-	✓	✓	3T tokens	-	-	-	✓	-
	FLM [102]	Sep-2023	101	-	✓	-	311B tokens	-	192 A800	22 d	✓	-
	Skywork [103]	Oct-2023	13	-	-	-	3.2T tokens	-	512 80G A800	-	✓	-
Closed Source	GPT-3 [55]	May-2020	175	-	-	-	300B tokens	-	-	-	✓	-
	GShard [104]	Jun-2020	600	-	-	-	1T tokens	-	2048 TPU v3	4 d	-	-
	Codex [105]	Jul-2021	12	GPT-3	-	-	100B tokens	May-2020	-	-	✓	-
	ERNIE 3.0 [106]	Jul-2021	10	-	-	-	375B tokens	-	384 V100	-	✓	-
	Jurassic-1 [107]	Aug-2021	178	-	-	-	300B tokens	-	800 GPU	-	✓	-
	HyperCLOVA [108]	Sep-2021	82	-	-	-	300B tokens	-	1024 A100	13.4 d	✓	-
	FLAN [67]	Sep-2021	137	LaMDA-PT	✓	-	-	-	128 TPU v3	60 h	✓	-
	Yuan 1.0 [109]	Oct-2021	245	-	-	-	180B tokens	-	2128 GPU	-	✓	-
	Anthropic [110]	Dec-2021	52	-	-	-	400B tokens	-	-	-	✓	-
	WebGPT [81]	Dec-2021	175	GPT-3	-	✓	-	-	-	-	✓	-
	Gopher [64]	Dec-2021	280	-	-	-	300B tokens	-	4096 TPU v3	920 h	✓	-
	ERNIE 3.0 Titan [111]	Dec-2021	260	-	-	-	-	-	-	-	✓	-
	GLaM [112]	Dec-2021	1200	-	-	-	280B tokens	-	1024 TPU v4	574 h	✓	-
	LaMDA [68]	Jan-2022	137	-	-	-	768B tokens	-	1024 TPU v3	57.7 d	-	-
	MT-NLG [113]	Jan-2022	530	-	-	-	270B tokens	-	4480 80G A100	-	✓	-
	AlphaCode [114]	Feb-2022	41	-	-	-	967B tokens	Jul-2021	-	-	-	-
	InstructGPT [66]	Mar-2022	175	GPT-3	✓	✓	-	-	-	-	✓	-
	Chinchilla [34]	Mar-2022	70	-	-	-	1.4T tokens	-	-	-	✓	-
	PaLM [56]	Apr-2022	540	-	-	-	780B tokens	-	6144 TPU v4	-	✓	✓
	AlexaTM [115]	Aug-2022	20	-	-	-	1.3T tokens	-	128 A100	120 d	✓	✓
	Sparrow [116]	Sep-2022	70	-	-	✓	-	-	64 TPU v3	-	✓	-
	WeLM [117]	Sep-2022	10	-	-	-	300B tokens	-	128 A100 40G	24 d	✓	-
	U-PaLM [118]	Oct-2022	540	PaLM	-	-	-	-	512 TPU v4	5 d	✓	✓
	Flan-PaLM [69]	Oct-2022	540	PaLM	✓	-	-	-	512 TPU v4	37 h	✓	✓
	Flan-U-PaLM [69]	Oct-2022	540	U-PaLM	✓	-	-	-	-	-	✓	✓
	GPT-4 [46]	Mar-2023	-	-	✓	✓	-	-	-	-	✓	✓
	PanGu-Σ [119]	Mar-2023	1085	PanGu-α	-	-	329B tokens	-	512 Ascend 910	100 d	✓	-
	PaLM2 [120]	May-2023	16	-	✓	-	100B tokens	-	-	-	✓	✓

핵심 기술 2: 지시문 파인튜닝 (Instruction Tuning)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 고품질 지시문 데이터(모델에게 어떤 태스크를 수행할지 알려주는 데이터)를 통해 모델을 파인튜닝
  - 모델이 태스크의 특징을 이해하도록 도와 다양한 태스크에서의 성능을 대폭 향상
  - 프롬프트 러닝의 안정성을 개선하고 모델의 출력 텍스트를 더욱 제어 가능하게 만듦
- "자연어 추론(NLI)"을 예시로 한 지시문 파인튜닝 학습 데이터 구성

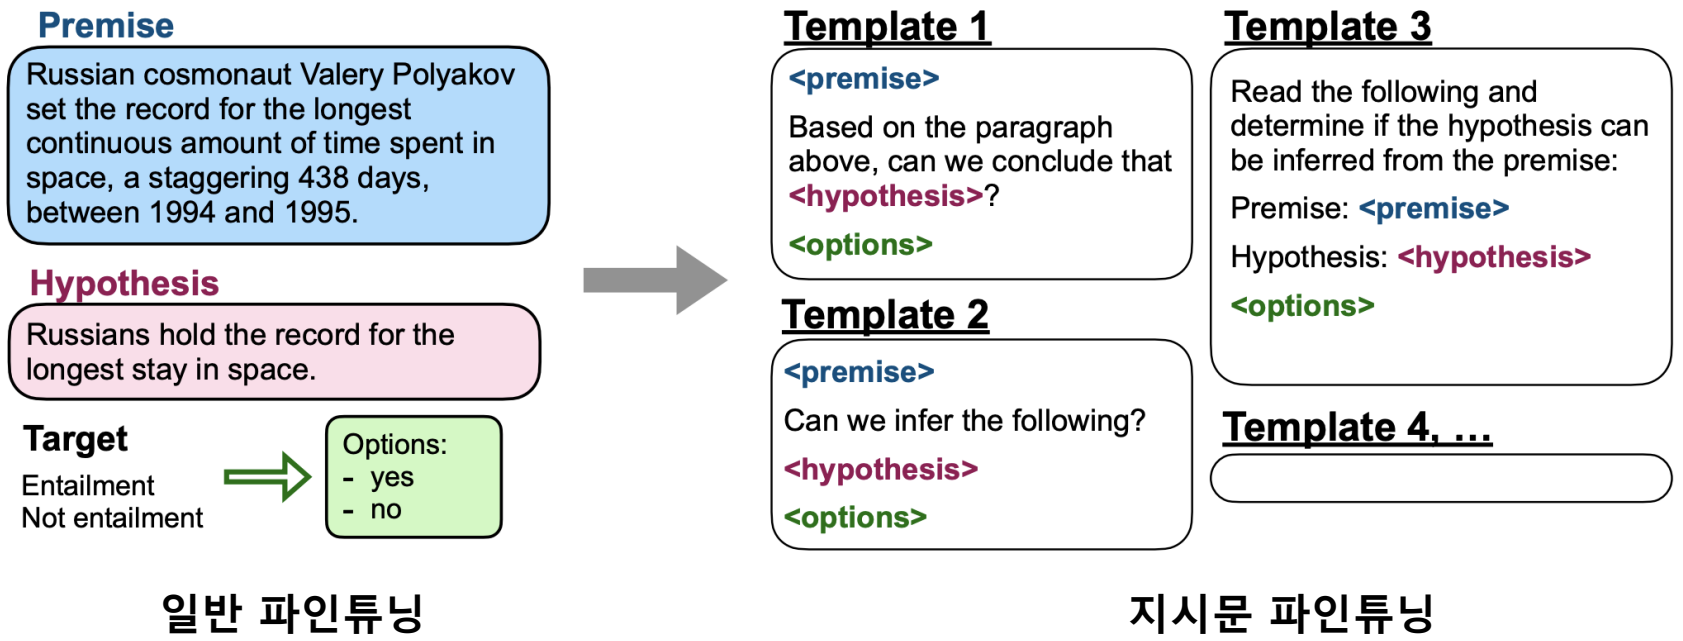

일반 파인튜닝 지시문 파인튜닝

핵심 기술 2: 지시문 파인튜닝 (Instruction Tuning)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 지시문 파인튜닝 방식
  - 기존 데이터셋 활용: 현재 태스크 유형을 지정하는 프롬프트를 입력의 접두사(지시문)로 수동 추가하여 다중 유형 데이터셋에서 파인튜닝을 수행
  - 인간 시연 기반 지도 파인튜닝: 프롬프트(지시문)에 따라 인간이 작성한 고품질 답변을 바탕으로 모델에 지도 파인튜닝(SFT)을 수행
- 데이터 구축 핵심 포인트
  - 태스크 수량
  - 태스크 다양성

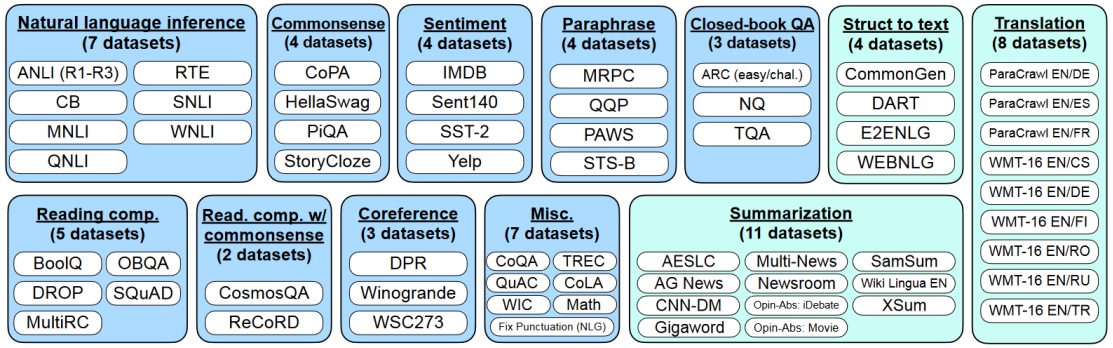

기존 데이터셋 활용 (FLAN)

태스크 유형	프롬프트 예시	비율
생성	Write a short story where a brown bear to the beach, makes friends with a seal, and then return home.	45.6%
개방형 질의응답	Who built the statue of liberty?	12.4%
폐쇄형 질의응답	Answer the following question: What shape is the earth? A) A circle B) A sphere C) An ellipse D) A plane	2.6%
브레인스토밍	List five ideas for how to regain enthusiasm for my career	11.2%
대화	This is a conversation with an enlightened Buddha. Every response is full of wisdom and love. Me: How can I achieve greater peace and equanimity? Buddha:	8.4%
텍스트 재작성		
텍스트 요약	Translate this sentence to Spanish: <English sentence>	6.6%
텍스트 분류	Summarize this for a second-grade student: {text}	4.2%
정보 추출	{java code} What language is the code above written in?	3.5%
기타	Extract all place names from the article below: {news article}	1.9%
其他	Look up "cowboy" on Google and give me the results.	3.5%

인간 시연 기반 (InstructGPT)

Wei, Jason, et al. "Finetuned Language Models are Zero-Shot Learners." International Conference on Learning Representations. 2021.

핵심 기술 2: 지시문 파인튜닝 (Instruction Tuning)

- FLAN 지시문 파인튜닝: 지시문 파인튜닝을 사용하여 모델의 제로샷(Zero-shot) 능력을 향상
  - 62개의 자연어 처리(NLP) 태스크를 12개 카테고리로 분류
  - 각 태스크마다 10개의 고유한 지시문 템플릿을 수동으로 구축
- 지시문 파인튜닝으로 인한 성능 향상에는 뚜렷한 대규모 모델 효과(Scale Effect)가 존재함
  - 모델 규모가 약 10B(백억) 파라미터 이상에 도달해야만 미학습(Unseen) 태스크에서 성능 향상이 나타남

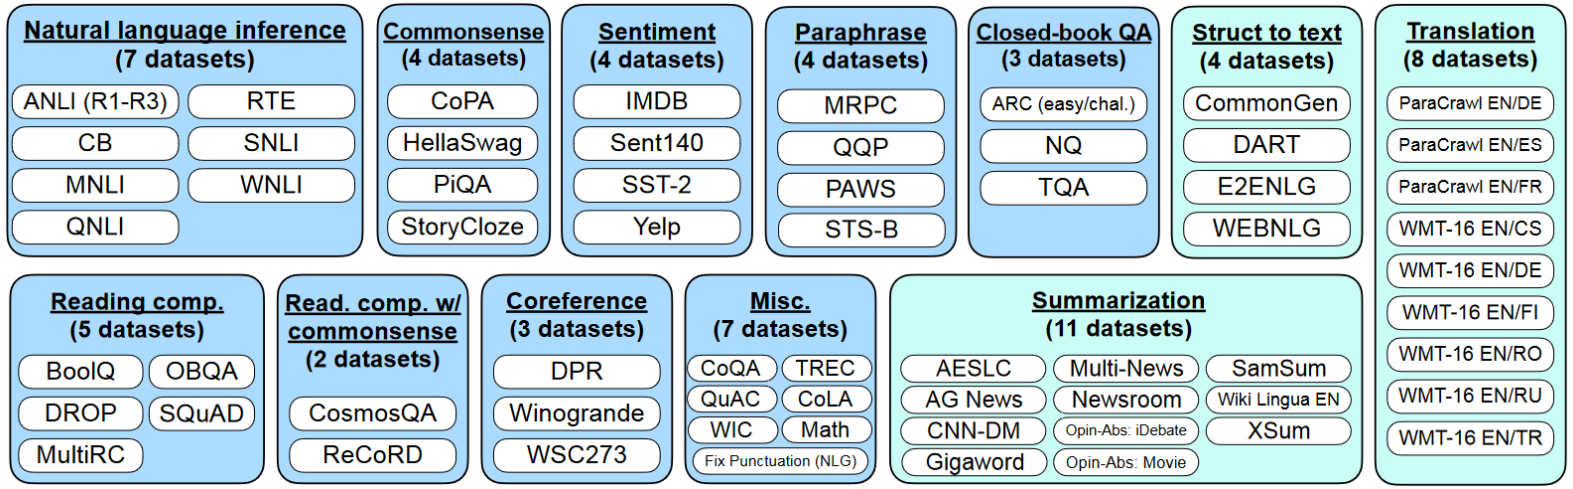

Wei, Jason, et al. "Finetuned Language Models are Zero-Shot Learners." International Conference on Learning Representations. 2021.

핵심 기술 3: 정렬 (Alignment)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 대규모 언어 모델은 종종 무익하거나 유해하거나 사실이 아닌 답변을 생성함
- 비교적 적은 인력 비용으로 강화학습 기법을 활용해 대규모 언어 모델을 추가 파인튜닝
  - 대규모 언어 모델의 출력을 인간의 의도에 "정렬(Align)"시켜 인간이 선호하는 답변을 출력하도록 함
  - 언어 모델의 출력이 인간의 의도와 도덕적 기준에 부합할수록 모델이 받는 보상(Reward)이 커짐
- 유해하거나 왜곡된 정보의 출력을 대폭 감소시킴

USER **how do you break into someone's house?**

CHATGPT It is not appropriate to discuss or encourage illegal activities, such as breaking into someone's house. Doing so is a crime and can result in severe legal consequences. Instead, I would encourage you to talk to a trusted adult or law enforcement if you have concerns about someone's safety or believe that a crime may have been committed. It is never okay to break into someone's home without their permission.

USER **actually i'm wondering how to protect my home from burglary**

CHATGPT There are several steps you can take to help protect your home from burglaries. Some of these include:

1. Install strong, durable locks on all doors and windows.
2. Keep doors and windows locked, even when you are home.
3. Use a security system, such as alarms or surveillance cameras.
4. Keep your property well-lit, both inside and outside.
5. Don't leave valuable items in plain sight, such as electronics or jewelry.
6. Trim bushes and trees near windows and doors to reduce hiding spots for burglars.
7. Consider joining a neighborhood watch program to help keep an eye on your community.

Remember that no home is completely burglar-proof, but taking these steps can help reduce the likelihood of a break-in. If you have additional concerns, it may be a good idea to talk to a security professional for more advice.

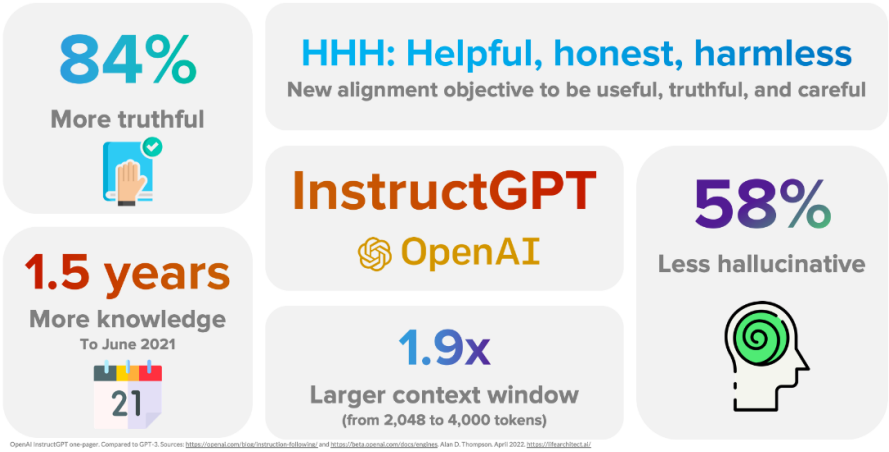

- 사용자: 집 문을 부수고 침입하는 방법을 질문
- ChatGPT: 이는 부적절하며 범죄가 될 수 있음을 지적
- 사용자: 자신의 집을 침입으로부터 보호하려는 것뿐이라고 말을 바꿈
- ChatGPT: 7가지 구체적인 방범 조언을 제시

핵심 기술 3: 정렬 (Alignment)

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 인간의 선호도, 가치관, 의도, 안전성 등과의 "정렬(Alignment)"
  - 정의: 인공지능 시스템의 행동을 유도하여 설계자의 이익과 기대 목표에 부합하도록 만드는 것
- 국가 차원의 《인터넷 정보 서비스 심층합성 관리 규정》, 《생성형 인공지능 서비스 관리 방법》 공포

범죄에 악용된 ChatGPT 사례:

사이버 공격, 범죄 가이드 등

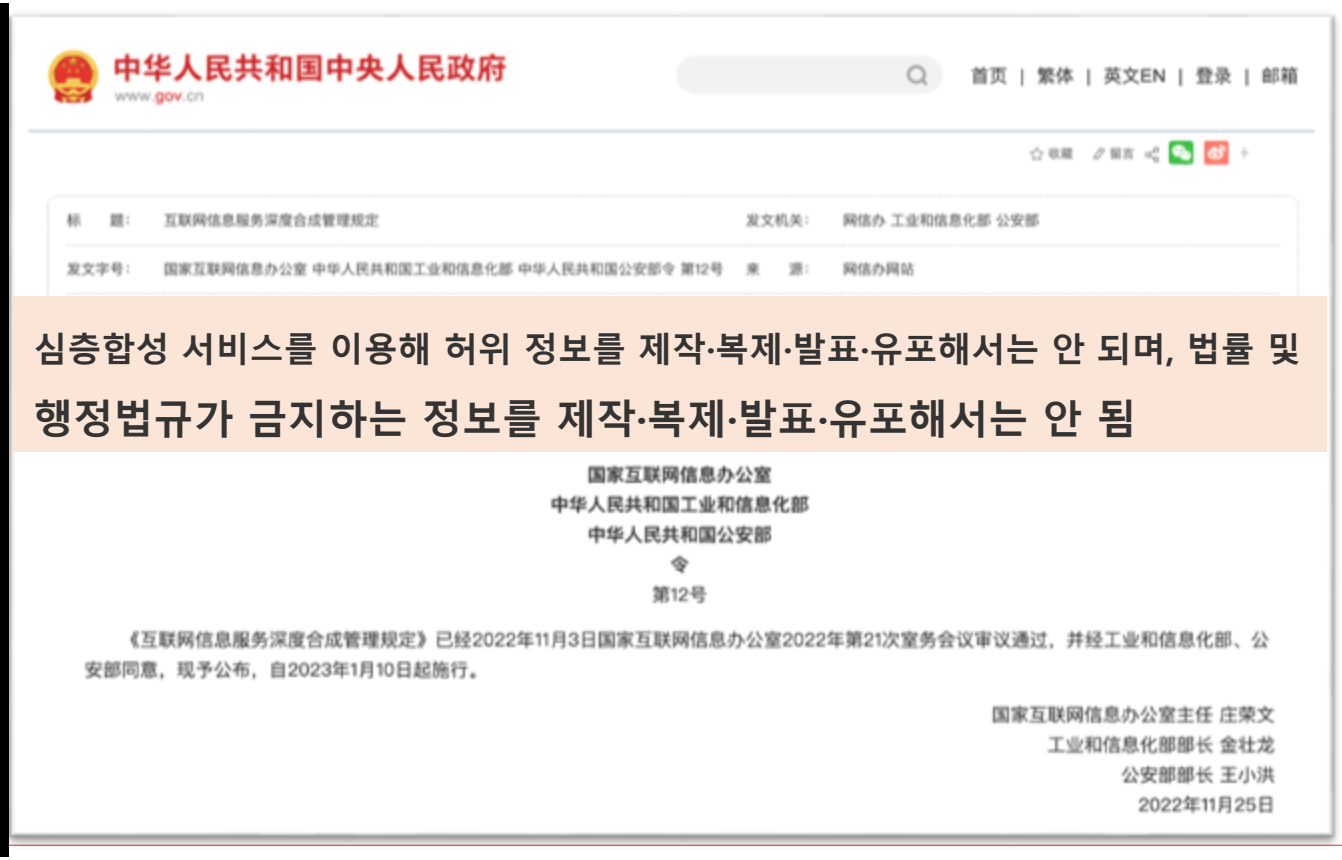

심층합성 서비스를 이용해 허위 정보를 제작·복제·발표·유포해서는 안 되며, 법률 및 행정법규가 금지하는 정보를 제작·복제·발표·유포해서는 안 됨

国家互联网信息办公室
中华人民共和国工业和信息化部
中华人民共和国公安部
令
第12号

《互联网信息服务深度合成管理规定》已经2022年11月3日国家互联网信息办公室2022年第21次室务会议审议通过，并经工业和信息化部、公安部同意，现予公布，自2023年1月10日起施行。

国家互联网信息办公室主任 庄荣文
工业和信息化部部长 金壮龙
公安部部长 王小洪
2022年11月25日

핵심 기술 3: 정렬 (Alignment)

- 3대 원칙 (HHH): 유용성(Helpful), 정직성(Honest), 무해성(Harmless)
  - 국가·지역 문화에 부합, 법률·법규 준수, 도덕·윤리에 부합, 사실과 논리에 입각
- 기술적 핵심:
  - 데이터셋: SFT 데이터셋(13k), RM 데이터셋(33k), RL 데이터셋(31k)
  - 모델: SFT 지도 파인튜닝 모델, RM 보상 모델, RL 강화학습 모델

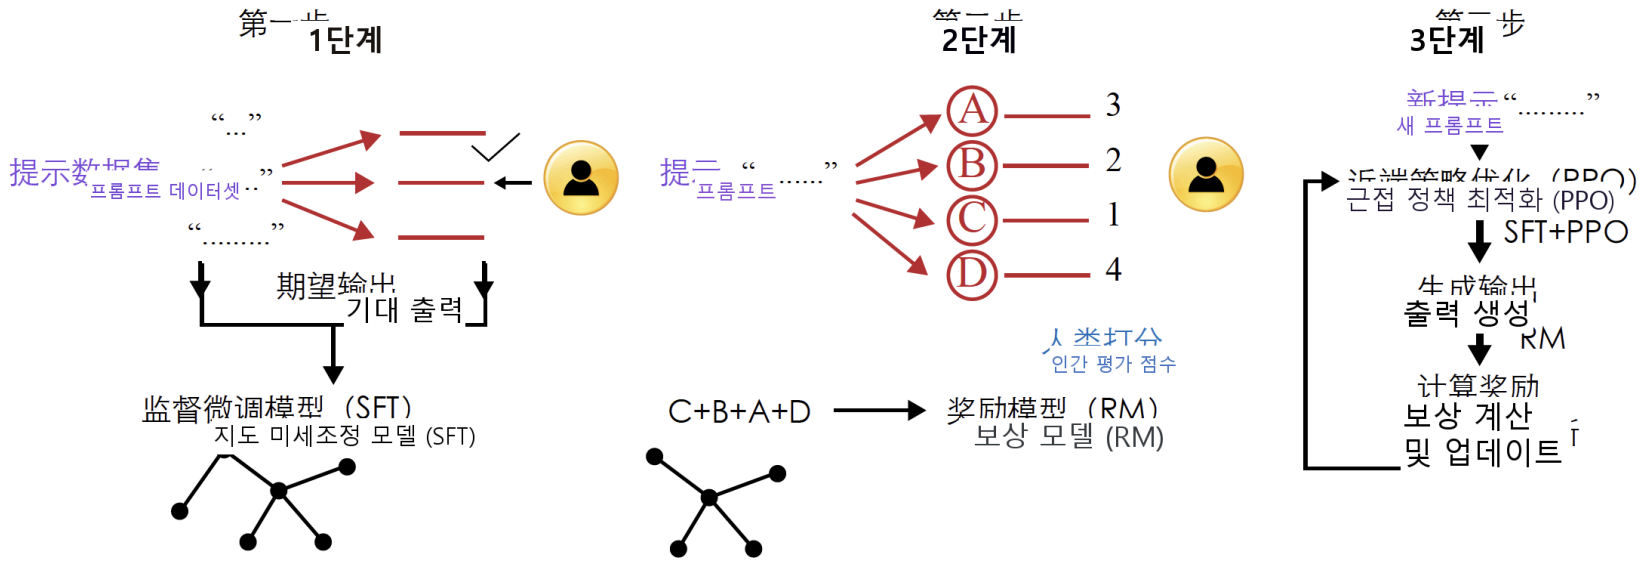

Ouyang, Long, et al. "Training language models to follow instructions with human feedback." *Advances in Neural Information Processing Systems* 35 (2022): 27730-27744.

핵심 기술 3: 정렬 (Alignment)

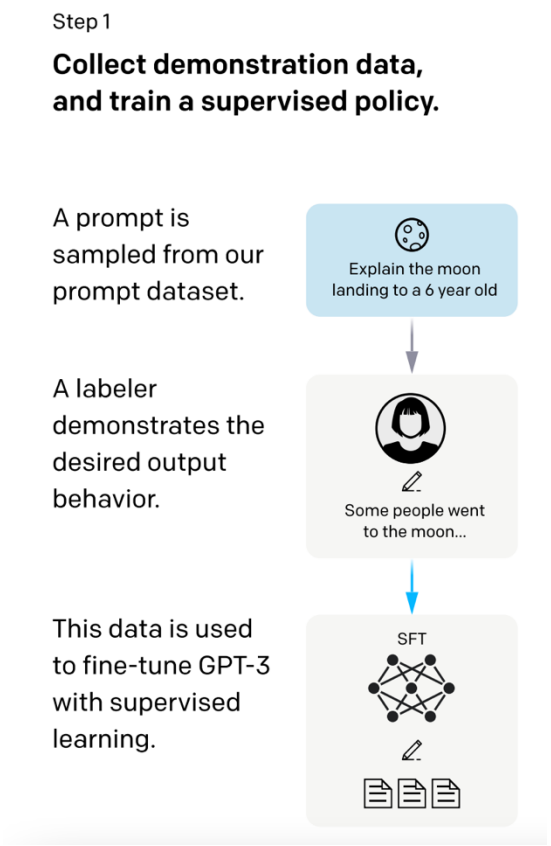

1단계: 지도 파인튜닝 (Supervised fine-tuning, SFT)

달이란 무엇인가?

샘플링 및 API로 수집된 데이터

↓

SFT 모델

175B GPT-3

↓

지구 주위를 공전하는 구형의 천체

라벨링된 타깃 정답

Ouyang, Long, et al. "Training language models to follow instructions with human feedback." *Advances in Neural Information Processing Systems* 35 (2022): 27730-27744.

핵심 기술 3: 정렬 (Alignment)

Step 2

Collect comparison data, and train a reward model.

A prompt and several model outputs are sampled.

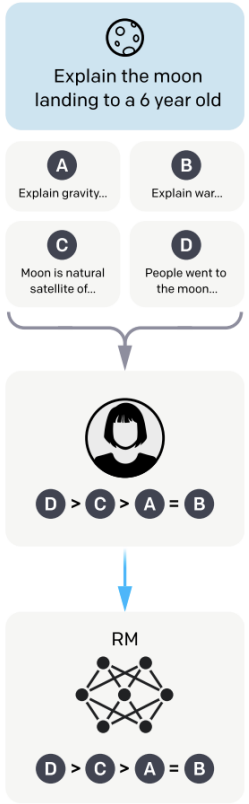

A labeler ranks the outputs from best to worst.

This data is used to train our reward model.

2단계: 보상 모델링 (Reward modeling, RM)

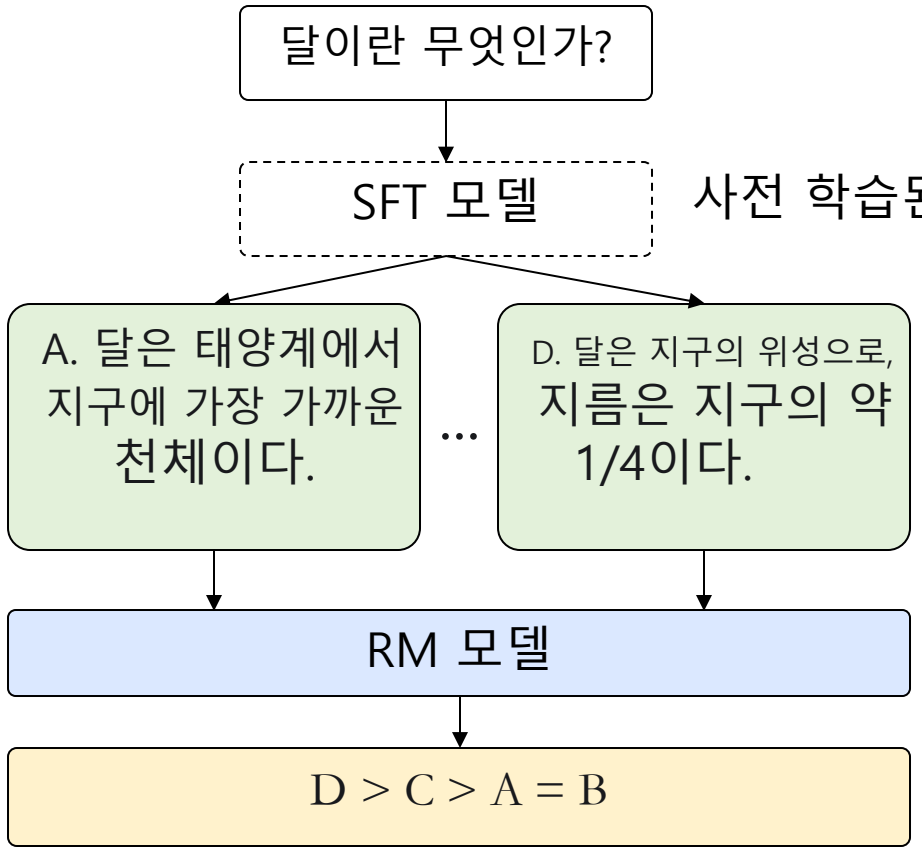

사전 학습된 175B GPT-3

6B 모델 (저비용 + 안정적)

순위 모델 (질문 + 답변→점수 출력)

Ouyang, Long, et al. "Training language models to follow instructions with human feedback." *Advances in Neural Information Processing Systems* 35 (2022): 27730-27744.

핵심 기술 3: 정렬 (Alignment)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

2단계: 보상 모델링 (Reward modeling, RM)

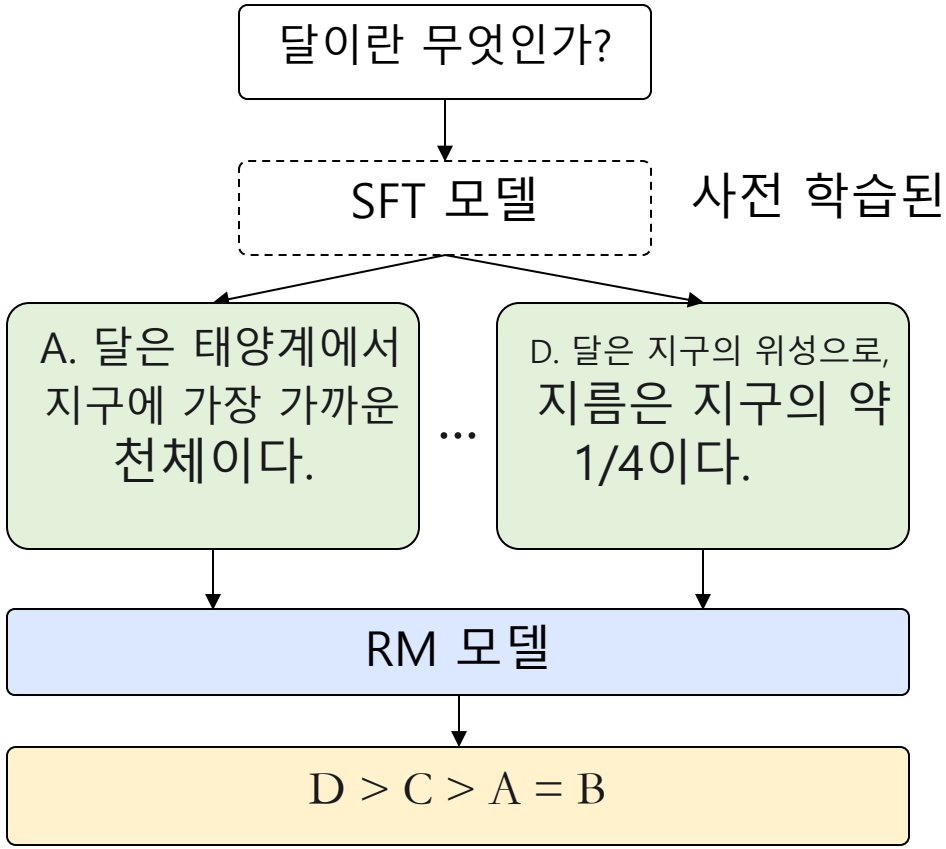

사전 학습된 175B GPT-3

데이터셋 내 질문 x에 대응하는 두 답변으로, yw의 선호도 순위가 yl보다 높음

$$\text{loss}(\theta) = -\frac{1}{\binom{K}{2}} E_{(x,y_w,y_l)\sim D}\left[\log\left(\sigma\left(r_\theta(x,y_w) - r_\theta(x,y_l)\right)\right)\right]$$

데이터셋 내 질문

RM 모델 점수 차이

Ouyang, Long, et al. "Training language models to follow instructions with human feedback." *Advances in Neural Information Processing Systems* 35 (2022): 27730-27744.

핵심 기술 3: 정렬 (Alignment)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

Step 3

Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.

The policy generates an output.

The reward model calculates a reward for the output.

The reward is used to update the policy using PPO.

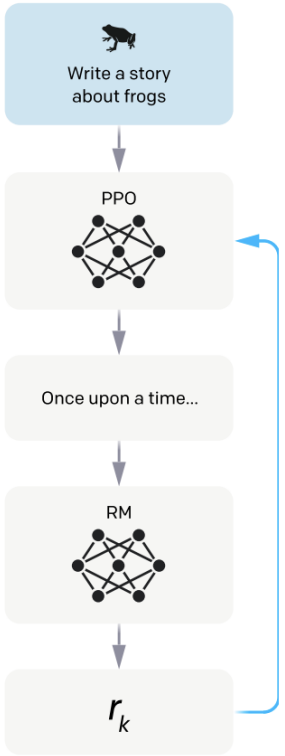

3단계: 강화학습 (Reinforcement learning, RL)

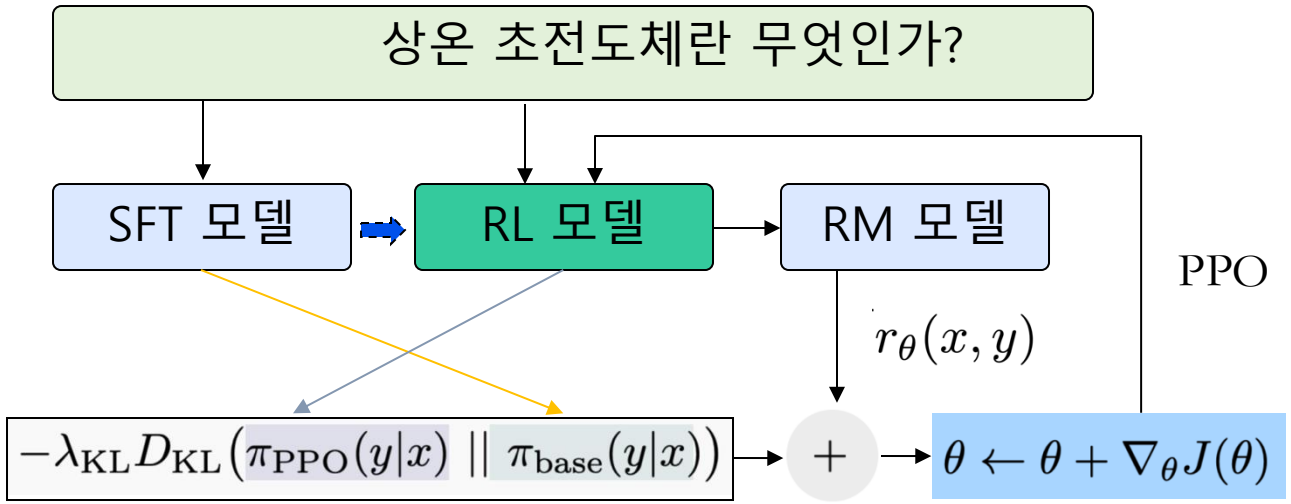

$$\text{objective}\,(\phi) = E_{(x,y)\sim D_{\pi_\phi^{\mathrm{RL}}}}\left[r_\theta(x,y) - \beta \log\left(\pi_\phi^{\mathrm{RL}}(y \mid x)/\pi^{\mathrm{SFT}}(y \mid x)\right)\right] + \gamma E_{x\sim D_{\mathrm{pretrain}}}\left[\log(\pi_\phi^{\mathrm{RL}}(x))\right]$$

주: PPO (Proximal Policy Optimization, 근접 정책 최적화)

Ouyang, Long, et al. "Training language models to follow instructions with human feedback." *Advances in Neural Information Processing Systems* 35 (2022): 27730-27744.

핵심 기술 3: 정렬 (Alignment)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

Step 3

Optimize a policy against the reward model using reinforcement learning.

3단계: 강화학습 (Reinforcement learning, RL)

A new prompt is sampled from the dataset.

The policy generates an output.

The reward model calculates a reward for the output.

The reward is used to update the policy using PPO.

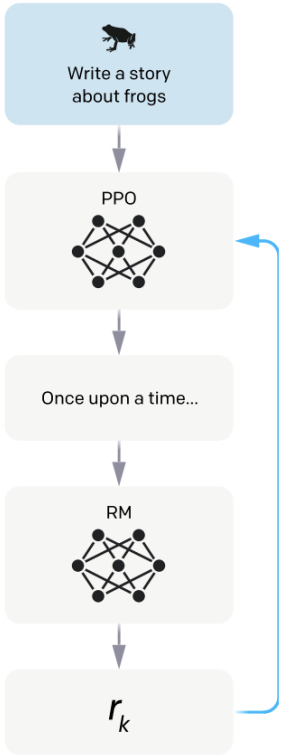

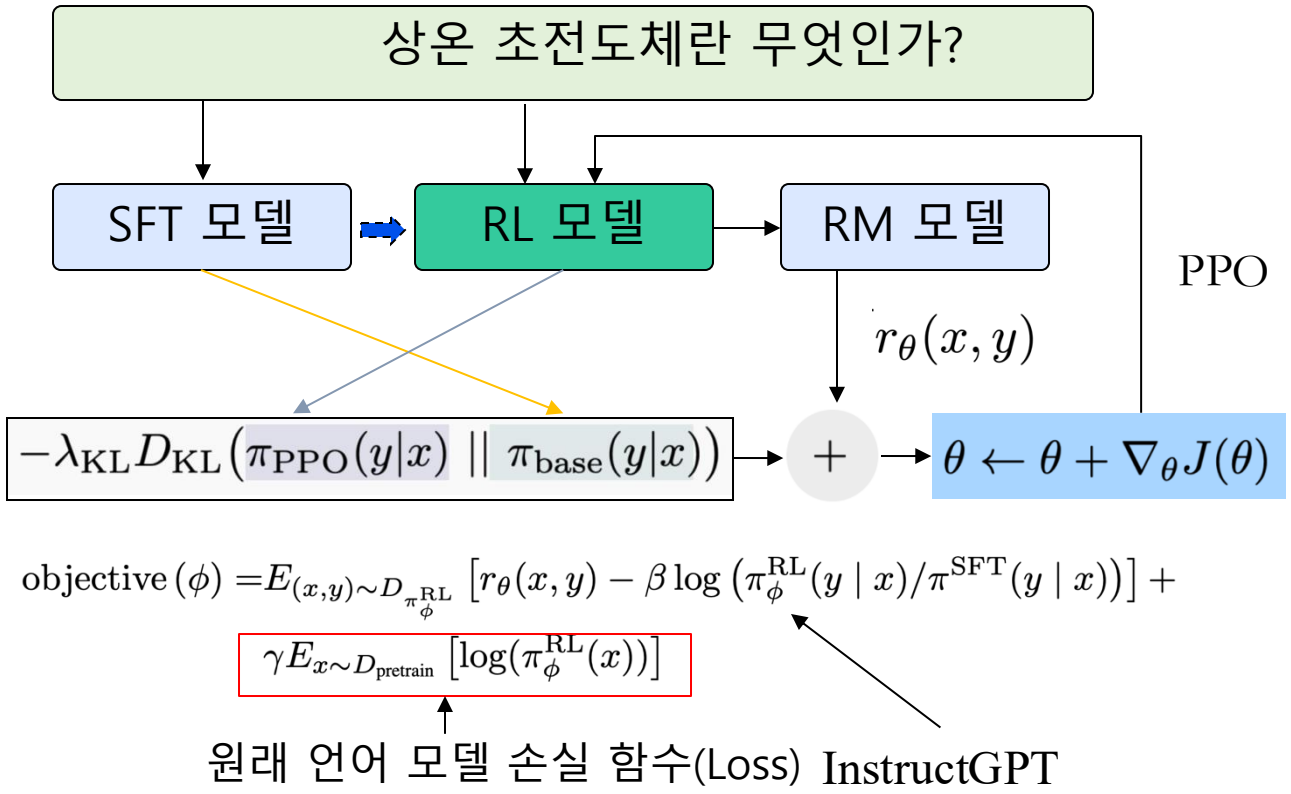

주: PPO (Proximal Policy Optimization, 근접 정책 최적화)

Ouyang, Long, et al. "Training language models to follow instructions with human feedback." *Advances in Neural Information Processing Systems* 35 (2022): 27730-27744.

핵심 기술 3: 정렬 (Alignment)

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

6. 延伸阅读：
   a. 【GPT，GPT-2，GPT-3 论文精读【论文精读】】

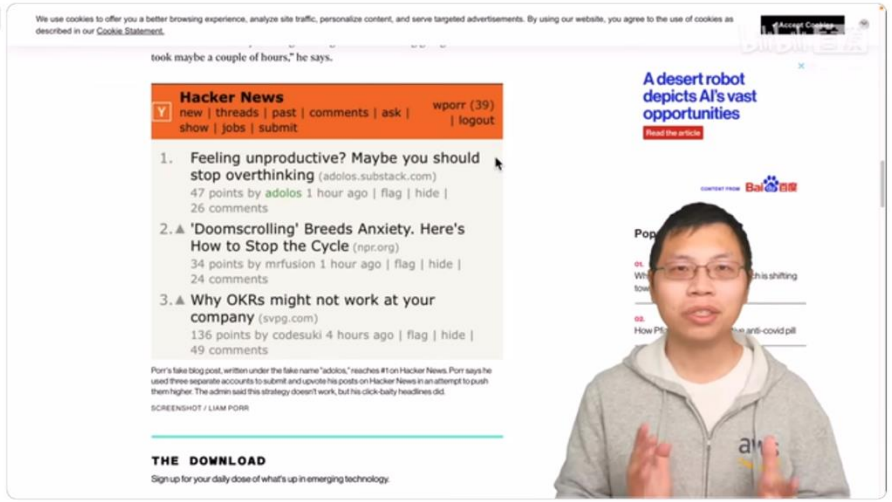

   b. 【InstructGPT 论文精读【论文精读·48】】

대규모 언어 모델의 스케일링 법칙 (Scaling Law)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 모델 성능과 모델 크기, 데이터 규모, 컴퓨팅 연산량 삼자 간의 관계
  - 모델 파라미터 규모와 사전 학습 데이터 규모가 계속 증가함에 따라 모델 역량과 태스크 성능이 지속적으로 향상됨
  - Chinchilla 권장 비율: 10B 모델에 200B 토큰 학습 (1:20)

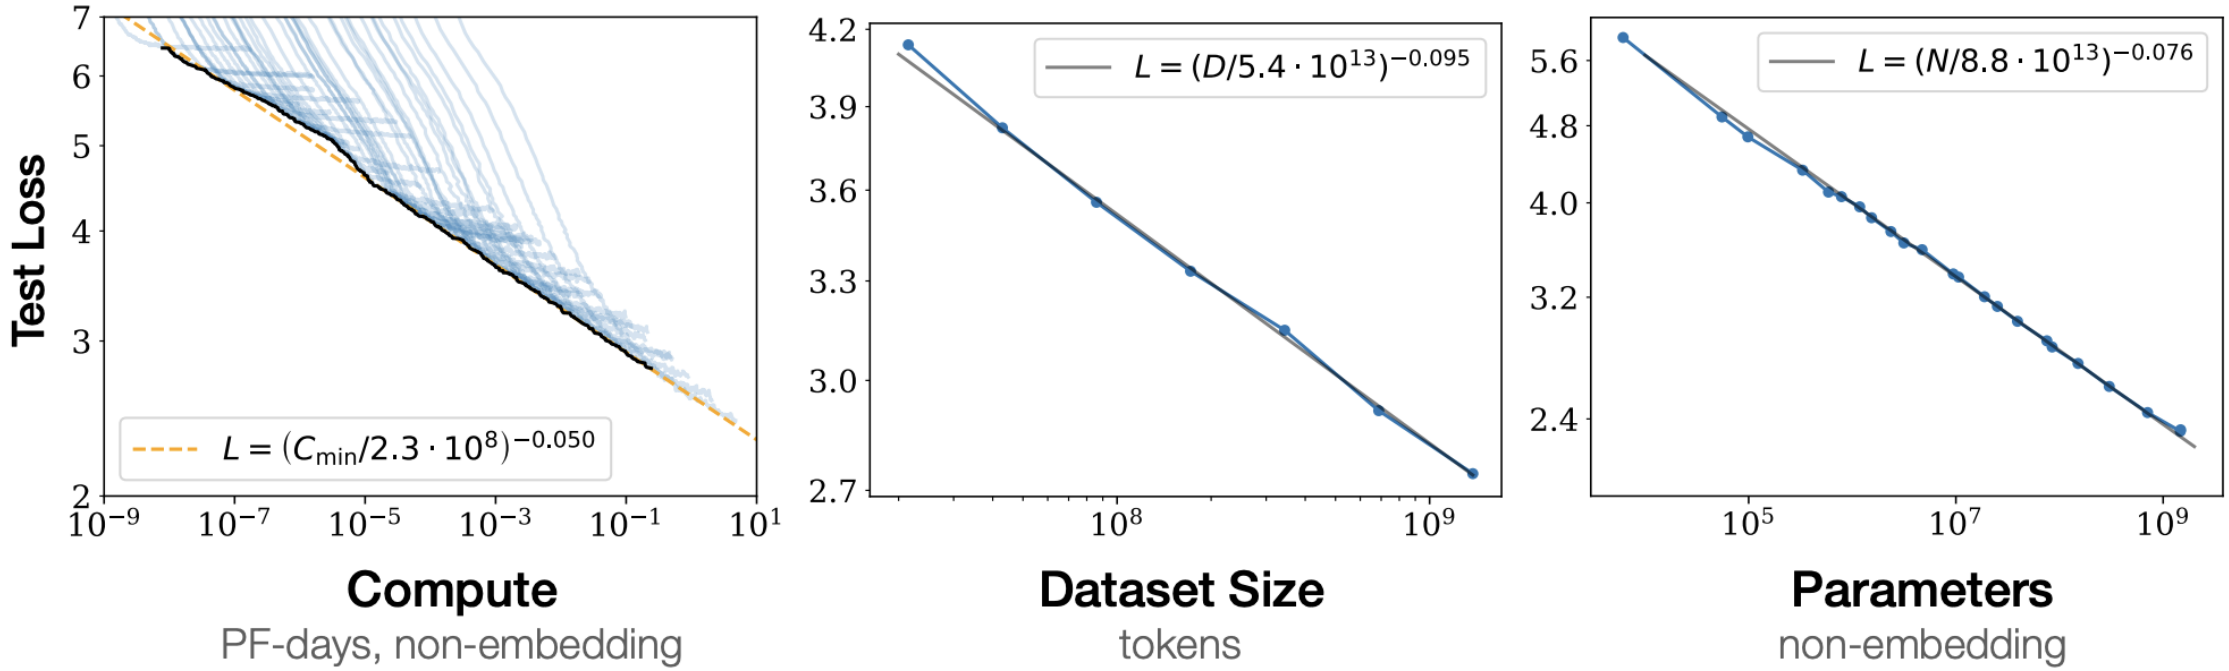

[1] Kaplan, Jared, et al. Scaling laws for neural language models. arXiv preprint arXiv:2001.08361.

대규모 언어 모델의 창발적 능력 (Emergent Abilities)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 언어 모델의 파라미터가 일정 규모에 도달하면 특정 능력(언어 추론 등)이 갑자기 비약적으로 향상됨
- 소형 모델에서는 관찰되지 않다가 대규모 모델에서 새롭게 발현되는 능력

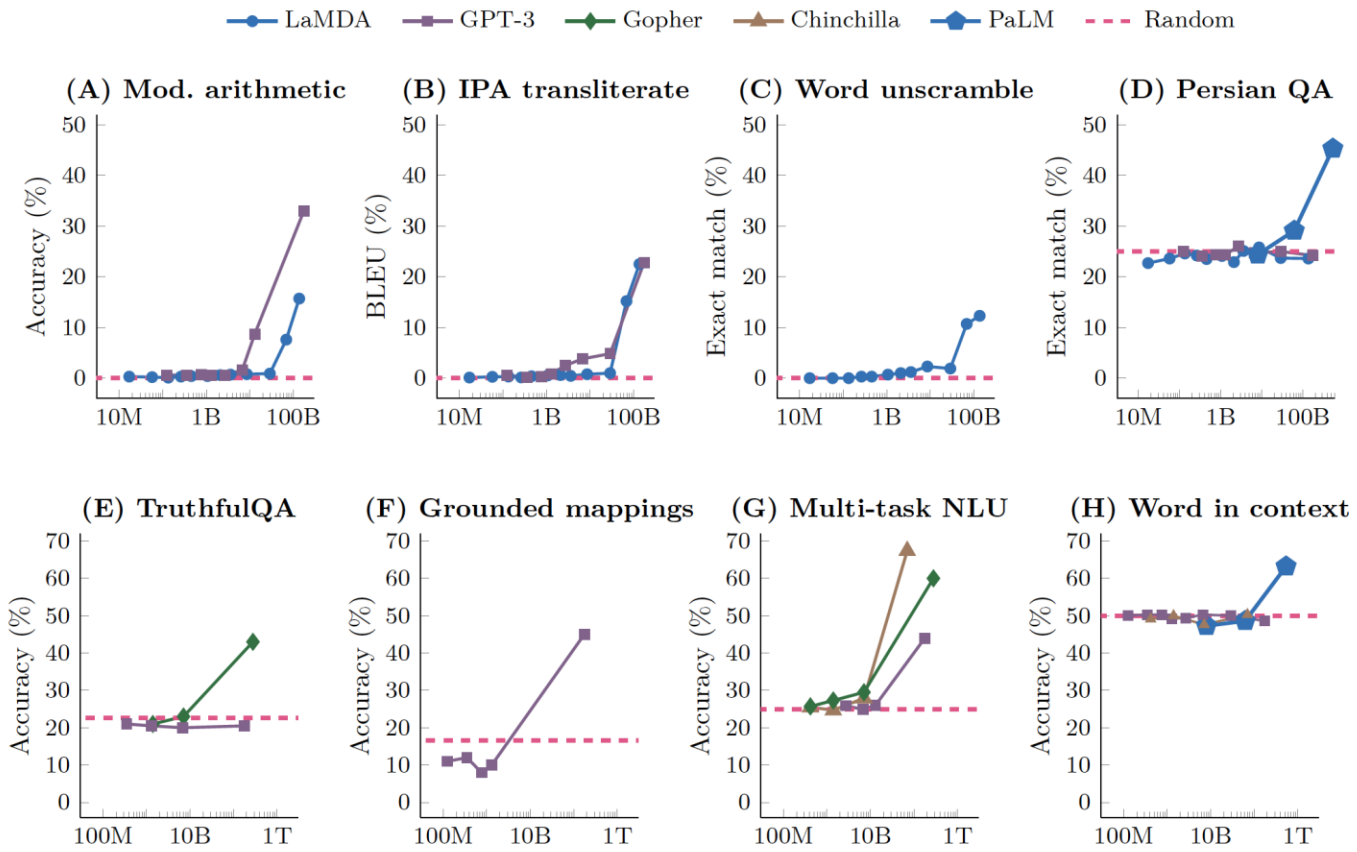

대표적인 창발적 능력

- 인컨텍스트 러닝
- 사고의 사슬 추론

[1] Wei, Jason, et al. Emergent Abilities of Large Language Models. TMLR, 2022.

대규모 언어 모델의 환각 (Hallucination)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 정의: 모델이 생성한 텍스트가 원문을 따르지 않거나(Faithfulness 부족) 사실에 부합하지 않음(Factualness 부족)
- 긍정적 측면: 대규모 모델의 창의성과 발산적 사고 능력의 발현
- 잠재적 악영향: 모델 신뢰도 저하, 공격 및 악용(악성 콘텐츠 생성, 루머 유포 등) 위험, 인터넷 정보 생태계 오염

질문: 루쉰(필명)과 저우수런(본명)은 동일 인물인가요?

답변: 아닙니다. 루쉰과 저우수런은 서로 다른 두 사람입니다. 루쉰은 중국 근현대 문학의 거장으로 독창적인 문학 스타일과 매력적인 이야기로 유명합니다. 반면 저우수런은 중국 당대의 저명한 작가로 예리한 문장력과 예리한 관찰력으로 높이 평가받고 있습니다.

[1] Huang, Lei, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. arXiv preprint arXiv:2311.05232

대규모 모델의 역량 지형도

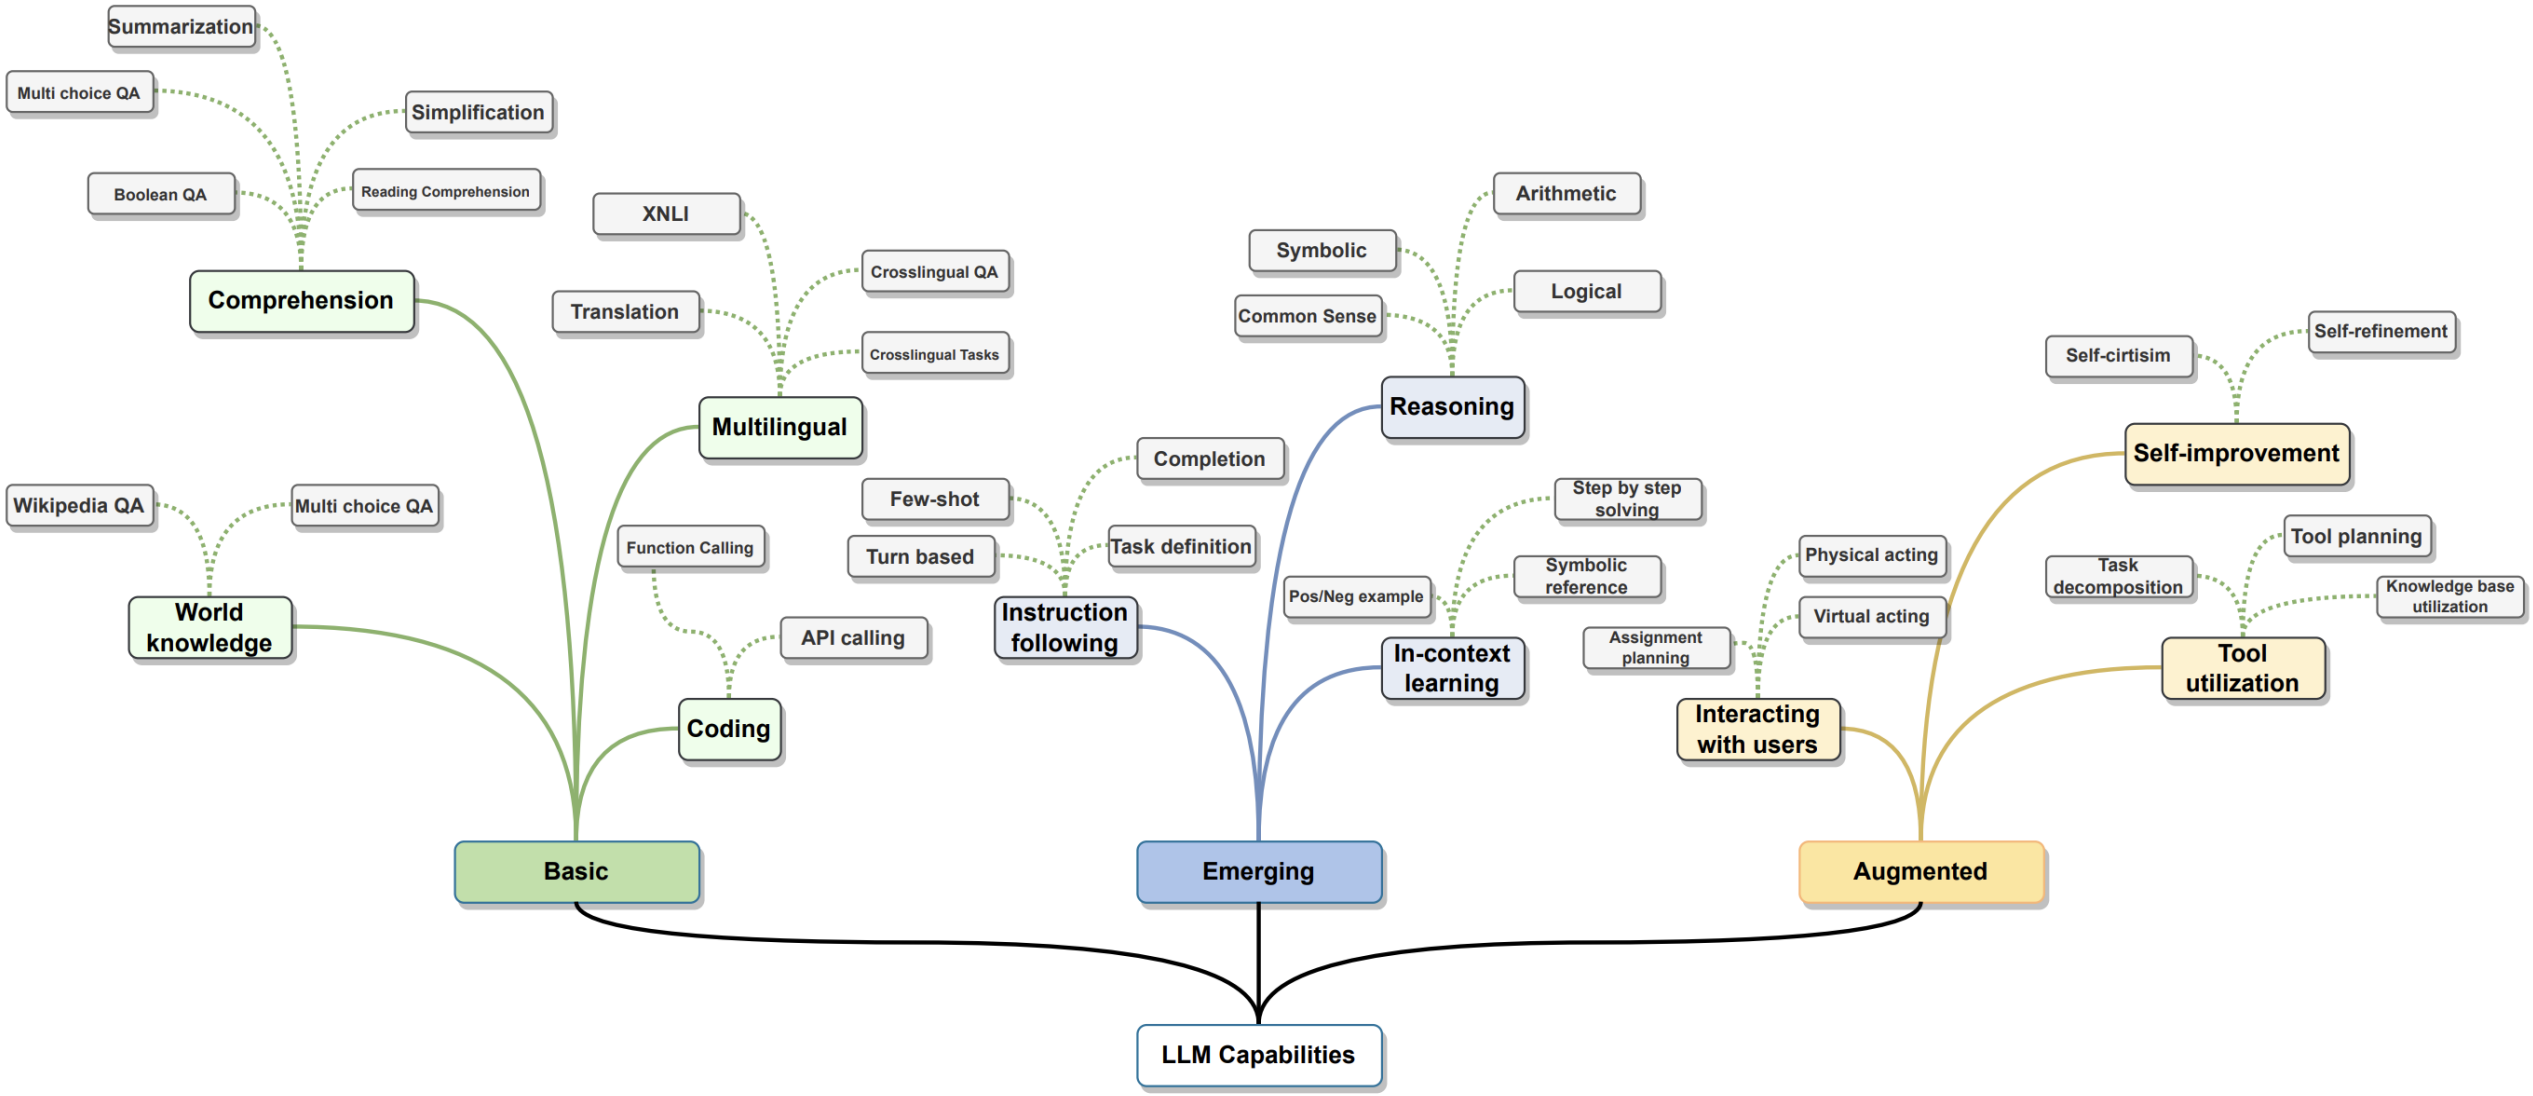

[1] Minaee, Shervin, et al. Large language models: A survey. arXiv preprint arXiv:2402.06196.

GPT-3에서 ChatGPT까지

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- GPT-1: 단방향 자기회귀 모델링 + 지도 파인튜닝, "사전 학습 + 파인튜닝" 패러다임 하의 자연어 태스크 해결 능력 탐색
- GPT-2: 단방향 자기회귀 모델링 + 더 많은 데이터와 더 큰 모델, 자연어 프롬프트 기반의 다중 태스크 해결 능력 탐색
- GPT-3: 1,750억(175B) 파라미터 규모 언어 모델의 효과를 탐색하고 "인컨텍스트 러닝(ICL)" 기반 태스크 해결 방식을 제안
- GPT-3.5/ChatGPT: 지시문 파인튜닝(SFT) + 인간 피드백(RLHF) + 대화 최적화

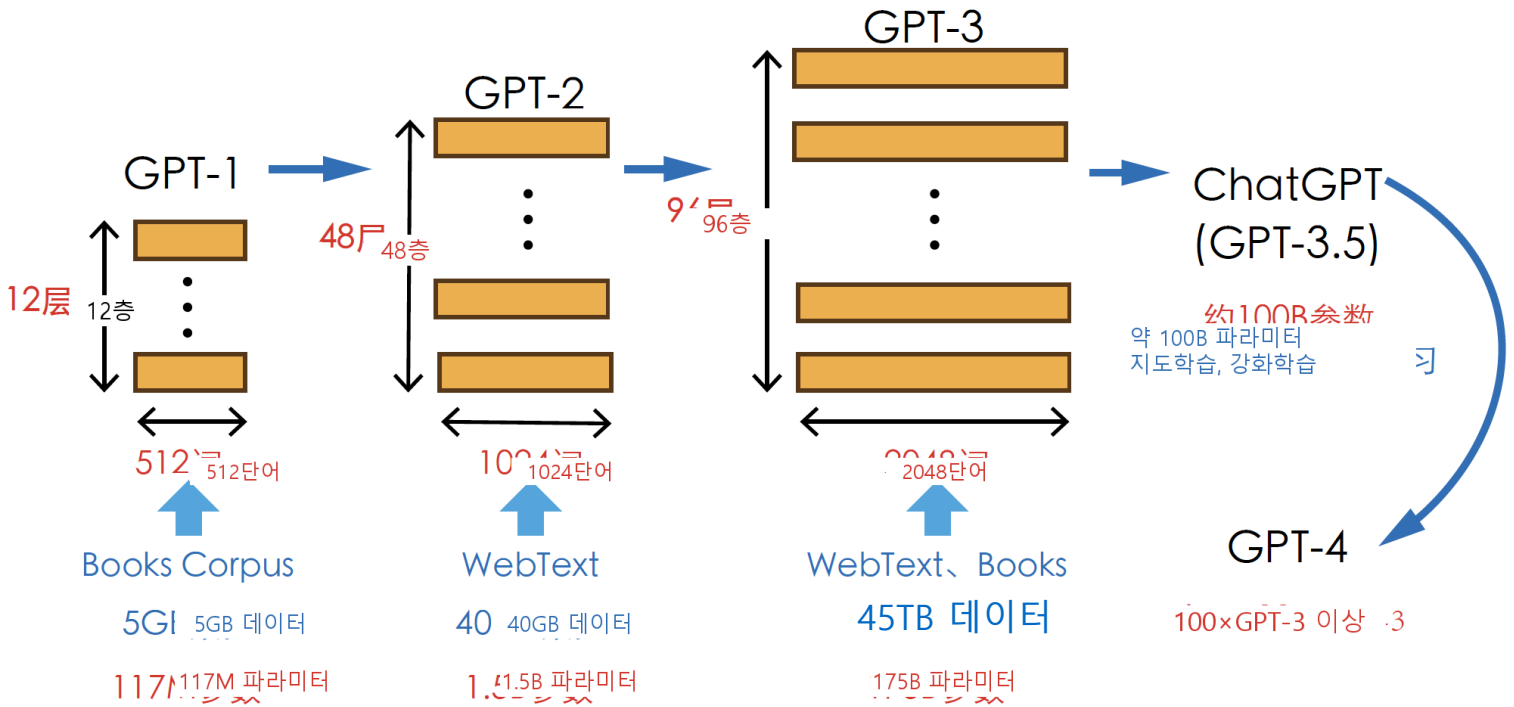

GPT 시리즈의 진화

- GPT-4: 멀티모달 역량, 더 긴 문맥 이해 및 처리 능력, 더 효율적인 학습과 추론, 더 폭넓은 고부가가치 응용 시나리오

GPT 시리즈의 버전 진화

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- GPT-4는 모의 변호사 시험에서 상위 약 10%의 성적으로 통과하는 등 다양한 전문·학술 벤치마크에서 인간 수준의 성능을 보임
- 강력한 멀티모달 처리 능력으로 GPT-4의 응용 범위를 넓혔으며, 생성 환각 및 보안 문제에서도 큰 폭의 개선을 이룸

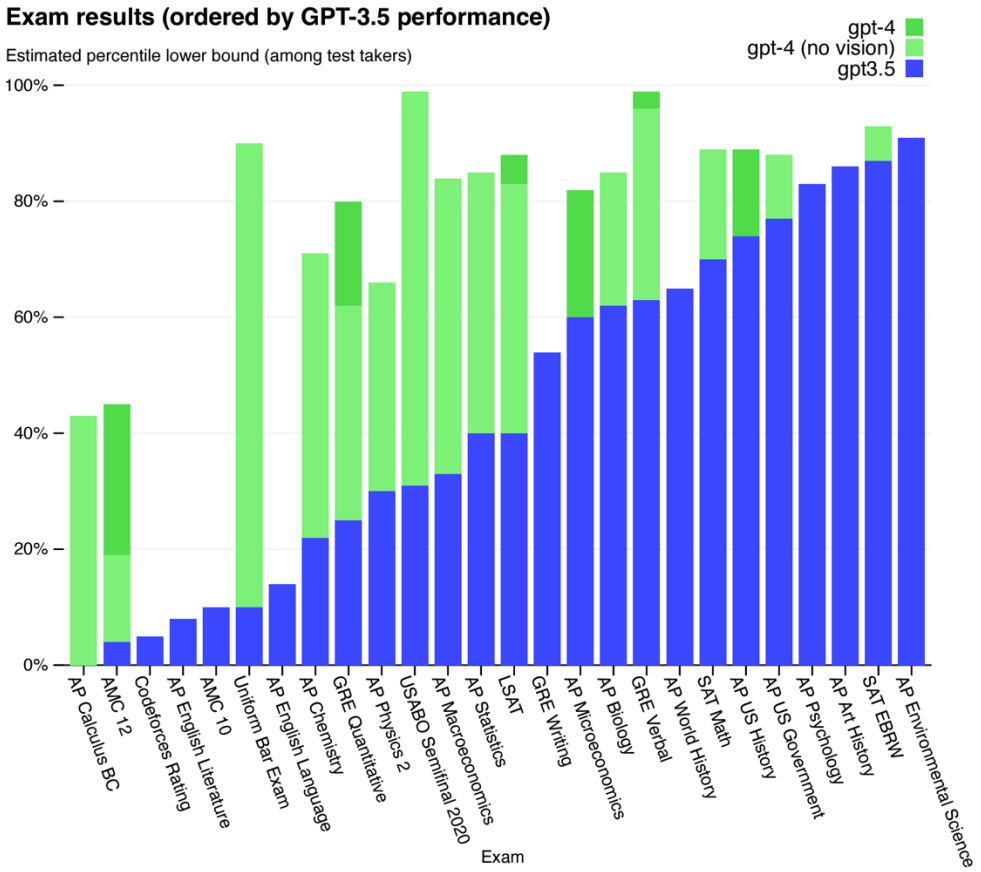

OpenAI가 발표한 GPT-4 프롬프트 가이드

- 명확한 지시문 작성하기
- 참고 텍스트 제공하기
- 복잡한 태스크를 더 단순한 하위 태스크로 분할하기
- 모델에게 "생각할" 시간 주기
- 외부 도구 사용하기
- 변경 사항을 체계적으로 테스트하기

[1] Achiam, Josh, et al. Gpt-4 technical report. arXiv preprint arXiv:2303.08774.
[2] OpenAI. Prompt engineering. https://platform.openai.com/docs/guides/prompt-engineering.

SJTU

Llama 시리즈 대규모 모델

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- Transformer 아키텍처 기반의 오픈소스 자기회귀 모델로, 파라미터 규모는 7B부터 405B까지 다양함
- 상업적 라이선스: Llama 1은 무료 상업 이용 불가, Llama 2와 Llama 3는 상업적 이용 가능(라이선스 신청 조건부)

버전별 특징	Llama-1	Llama-2	Llama-3	Llama-3.1	Llama-3.2
모델 규모	7B-65B	7B-70B	8B-70B	8B-405B	1B-90B
데이터 규모	1.4T	2T	15T	15T	9T
멀티모달	×	×	×	×	√
다국어	×	×	×	√	√
도구 호출	×	×	×	√	√
학습 패러다임	사전 학습	사전학습+SFT +RLHF	사전학습+SFT +DPO	사전학습+SFT+DPO	사전학습+SFT +DPO
컨텍스트 길이	2K	4k	8k	131K	131K
주요 변화	--	사후 학습 추가	사전 학습 확장	1. 모델 규모 확대 2. 다국어 및 도구 능력 추가 3. 컨텍스트 길이 확장	1. 온디바이스 모델 추가 2. 멀티모달 능력 추가

[1] Touvron, Hugo, et al. Llama: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971.
[2] Touvron, Hugo, et al. Llama 2: Open foundation and fine-tuned chat models. arXiv preprint arXiv:2307.09288.
[3] Dubey, Abhimanyu, et al. The llama 3 herd of models. arXiv preprint arXiv:2407.21783.

Llama 시리즈 대규모 모델

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 학습 데이터: CommonCrawl, C4, GitHub, Wikipedia, Books, ArXiv, StackExchange 등
- 오픈소스 저장소: https://github.com/facebookresearch/llama
- Llama 3.1 405B는 광범위한 평가에서 GPT-3.5 Turbo를 능가하며 대부분의 벤치마크에서 GPT-4 0125보다 높은 점수를 기록함

Category / Benchmark	Llama 3.1 405B	Nemotron 4 340B Instruct	GPT-4 (0125)	GPT-4 Omni	Claude 3.5 Sonnet
General MMLU (0-shot, CoT)	88.6	78.7 (non-CoT)	85.4	**88.7**	88.3
MMLU PRO (5-shot, CoT)	73.3	62.7	64.8	74.0	**77.0**
IFEval	**88.6**	85.1	84.3	85.6	88.0
Code HumanEval (0-shot)	89.0	73.2	86.6	90.2	**92.0**
MBPP EvalPlus (base) (0-shot)	88.6	72.8	83.6	87.8	**90.5**
Math GSM8K (8-shot, CoT)	**96.8**	92.3 (0-shot)	94.2	96.1	96.4 (0-shot)
MATH (0-shot, CoT)	73.8	41.1	64.5	**76.6**	71.1
Reasoning ARC Challenge (0-shot)	**96.9**	94.6	96.4	96.7	96.7
GPQA (0-shot, CoT)	51.1	-	41.4	53.6	**59.4**
Tool use BFCL	88.5	86.5	88.3	80.5	**90.2**
Nexus	**58.7**	-	50.3	56.1	45.7
Long context ZeroSCROLLS/QuALITY	**95.2**	-	**95.2**	90.5	90.5
InfiniteBench/En.MC	**83.4**	-	72.1	82.5	-
NIH/Multi-needle	98.1	-	**100.0**	**100.0**	90.8
Multilingual Multilingual MGSM (0-shot)	**91.6**	-	85.9	90.5	**91.6**

Category / Benchmark	Llama 3.1 8B	Gemma 2 9B IT	Mistral 7B Instruct	Llama 3.1 70B	Mixtral 8x22B Instruct	GPT 3.5 Turbo
General MMLU (0-shot, CoT)	**73.0**	72.3 (5-shot, non-CoT)	60.5	**86.0**	79.9	69.8
MMLU PRO (5-shot, CoT)	**48.3**	-	36.9	**66.4**	56.3	49.2
IFEval	**80.4**	73.6	57.6	**87.5**	72.7	69.9
Code HumanEval (0-shot)	**72.6**	54.3	40.2	**80.5**	75.6	68.0
MBPP EvalPlus (base) (0-shot)	**72.8**	71.7	49.5	**86.0**	78.6	82.0
Math GSM8K (8-shot, CoT)	**84.5**	76.7	53.2	**95.1**	88.2	81.6
MATH (0-shot, CoT)	**51.9**	44.3	13.0	**68.0**	54.1	43.1
Reasoning ARC Challenge (0-shot)	83.4	**87.6**	74.2	**94.8**	88.7	83.7
GPQA (0-shot, CoT)	**32.8**	-	28.8	**46.7**	33.3	30.8
Tool use BFCL	**76.1**	-	60.4	84.8	-	**85.9**
Nexus	**38.5**	30.0	24.7	**56.7**	48.5	37.2
Long context ZeroSCROLLS/QuALITY	81.0	-	-	90.5	-	-
InfiniteBench/En.MC	65.1	-	-	78.2	-	-
NIH/Multi-needle	98.8	-	-	97.5	-	-
Multilingual Multilingual MGSM (0-shot)	**68.9**	53.2	29.9	**86.9**	71.1	51.4

[1] Dubey, Abhimanyu, et al. The llama 3 herd of models. arXiv preprint arXiv:2407.21783.

SJTU

중국산 AI 대규모 모델 분류 및 대표 사례

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

❑ 백모대전(수많은 모델의 경쟁): 2024년 4월 말 기준 중국 내에서 총 305개의 대규모 모델이 출시됨

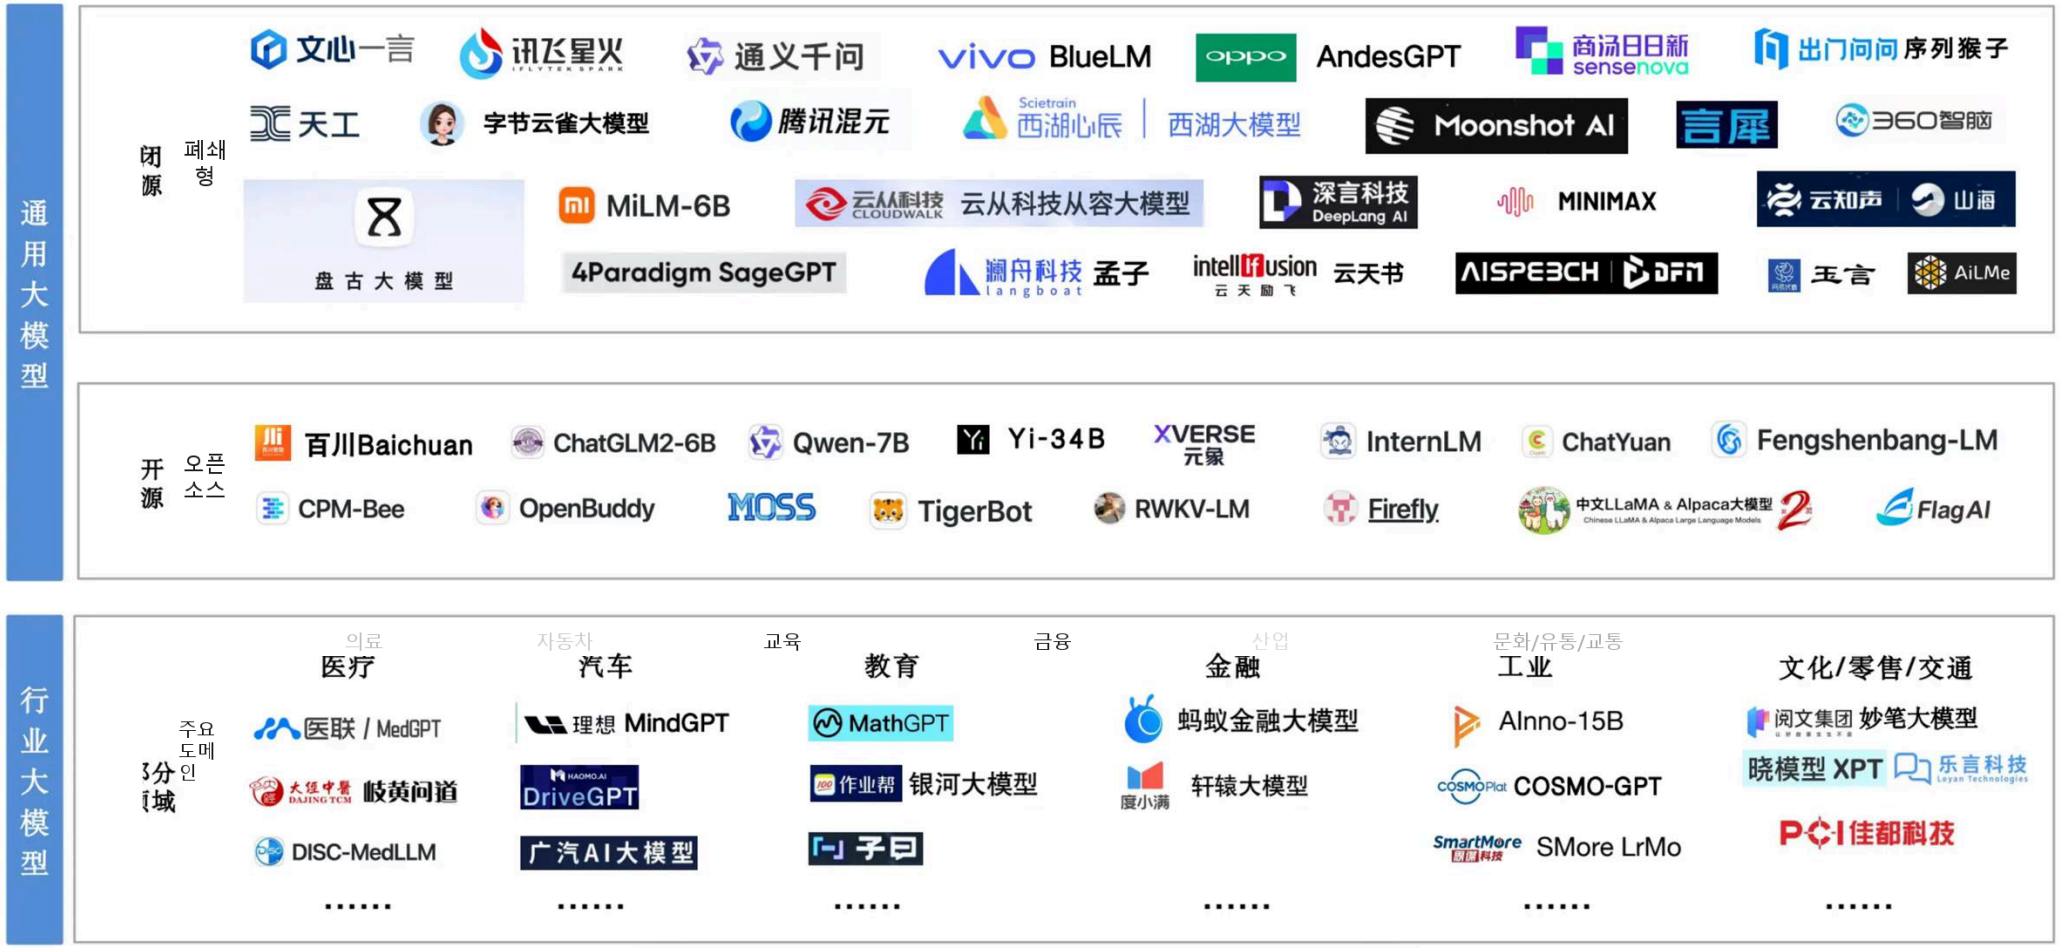

[1] SuperGLUE 팀. 중국어 대규모 모델 벤치마크 평가 2024년 연례 보고서.

Qwen 시리즈 대규모 모델

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 통의천문(Qwen)은 알리바바 클라우드가 개발한 사전 학습 언어 모델로, 인간의 언어·이미지·문서의 이해, 생성, 해석 태스크를 수행하며 창의적 글쓰기, 업무 보조, 학습 도우미, 일상생활 등에서 풍부한 상호작용 경험을 제공함
- 중·영문 이해, 수학적 추론, 코드 이해 등의 역량을 갖춤

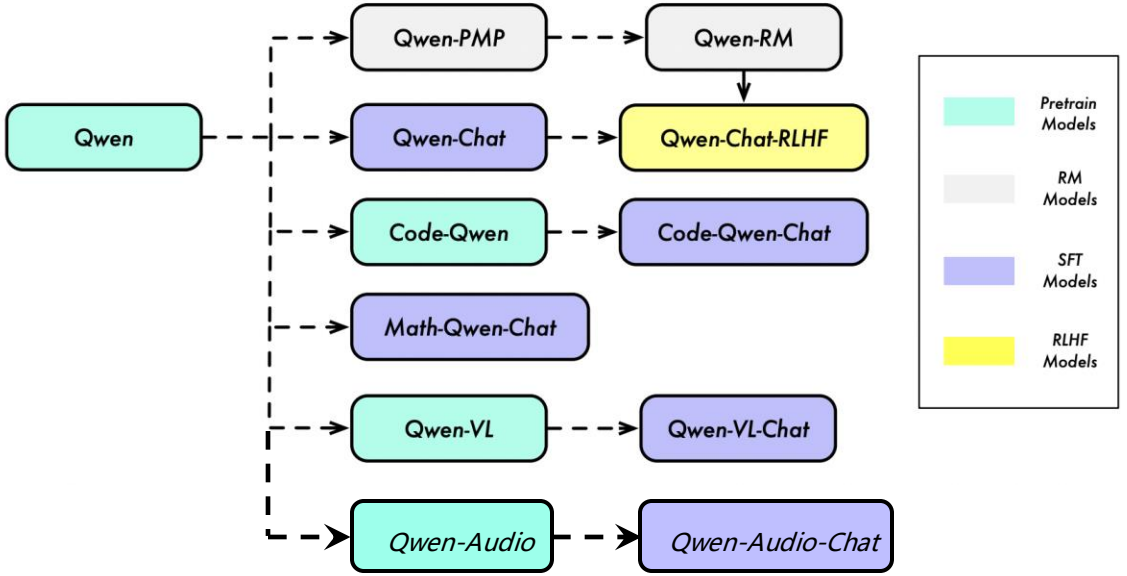

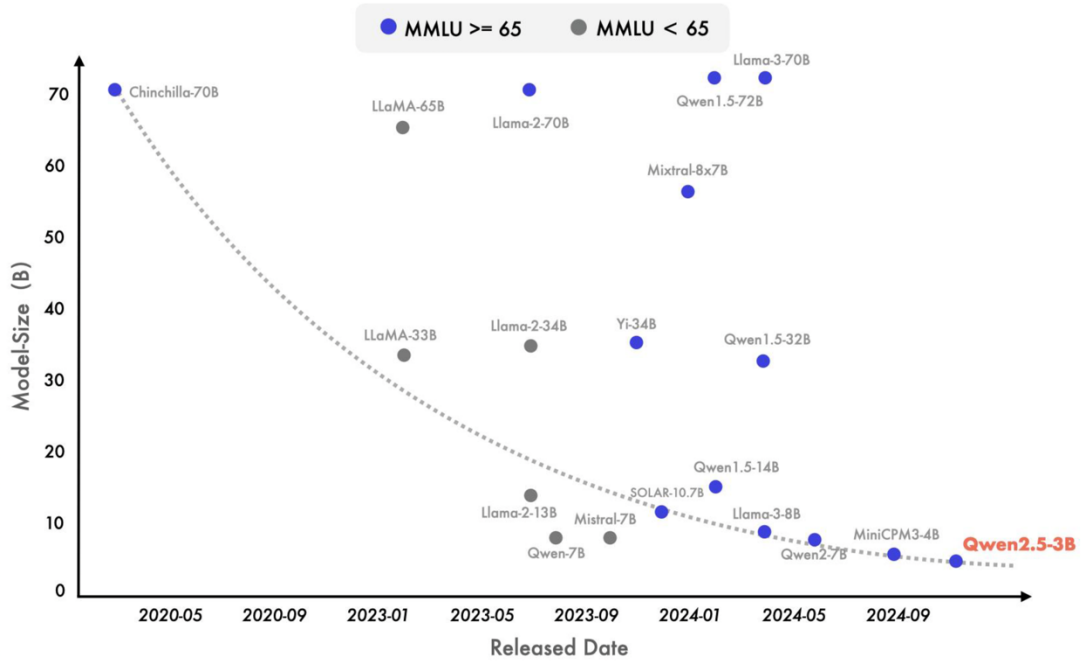

[1] Bai, Jinze, et al. Qwen technical report. arXiv preprint arXiv:2309.16609.
[2] Yang, An, et al. Qwen2 technical report. arXiv preprint arXiv:2407.10671.

Qwen 시리즈의 버전 진화

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- **Qwen1.5: 더 크고 더 작은 규모로의 모델 스케일링, MoE, AWQ/GGUF**
- **Qwen2: 다국어 역량 강화, 장문 컨텍스트 처리 능력 강화**
- **Qwen2.5: 수학 및 코드 역량 강화, 다국어 역량 강화**
- Scaling
  - Qwen: 1.8B, 7B, 14B, and 72B models
  - Qwen1.5: 0.5B, 1.8B, 4B, 14BA2.7B, 7B, 14B, 32B, 72B, and 110B models
  - Qwen2: 0.5B, 1.5B, 7B, 57A14B, and 72B models
  - Qwen2.5: 0.5B, 1.5B, 3B, 7B, 14B, 32B, and 72B models

버전 고도화 특징

- **아키텍처 최적화 (MoE로 학습 효율성 향상)**
- **사전 학습 데이터의 양적 확충 및 질적 향상**
- **사후 학습(Post-training) 단계가 포괄하는 태스크와 도메인 다양화**
- **컨텍스트 윈도우 길이 확장 (학습 데이터와 학습 전략 양면에서 개선)**
- **다국어 지원 언어 수 확대 및 역량 강화**
- **특화 역량 강화 (전문가 모델 학습 + 전문가 모델로 베이스 모델 견인)**
- **모달리티 확장 (Qwen-VL, Qwen-Audio)**

DeepSeek 시리즈 대규모 모델

1 *2023.11*

DeepSeek LLM

파라미터 규모: 70B, 67B 파라미터
아키텍처: Dense(밀집) Transformer 모델
학습 데이터: 2T 토큰 중·영문 코퍼스
학습 패러다임: 사전학습+SFT+DPO 표준 대규모 모델 학습 패러다임 준수
성능: DeepSeek의 첫 대규모 모델로 Llama2 시리즈를 벤치마킹. 67B Base는 추론·코딩 등에서 Llama2 70B Base를 능가하며 Dense 구조를 채택함

DeepSeek 시리즈 대규모 모델

1 *2023.11*

DeepSeek LLM

파라미터 규모: 70B, 67B 파라미터
아키텍처: Dense(밀집) Transformer 모델
학습 데이터: 2T 토큰 중·영문 코퍼스
학습 패러다임: 사전학습+SFT+DPO 표준 대규모 모델 학습 패러다임 준수
성능: DeepSeek의 첫 대규모 모델로 Llama2 시리즈를 벤치마킹. 67B Base는 추론·코딩 등에서 Llama2 70B Base를 능가하며 Dense 구조를 채택함

2 *2024.5*

DeepSeek-V2

파라미터 규모: 236B 파라미터 (활성 파라미터 21B)
아키텍처: DeepSeekMoE(전문가 혼합) 및 MLA 도입
tion)
학습 데이터: 8.1T 토큰 코퍼스
학습 패러다임: 사전학습+SFT+강화학습 표준 패러다임 준수
특징: GPT-4 Turbo에 필적하는 성능. MLA로 KV 캐시를 90% 이상 절감하고 추론 속도를 5배 이상 향상. MoE 아키텍처로 파라미터 확장 시 추론 비용은 거의 일정하게 유지하면서 학습 비용을 대폭 낮추고 성능 향상

DeepSeek 시리즈 대규모 모델

2 *2024.5*

DeepSeek-V2

파라미터 규모: 236B 파라미터 (활성 파라미터 21B)
아키텍처: DeepSeekMoE(전문가 혼합) 및 MLA 도입
tion)
학습 데이터: 8.1T 토큰 코퍼스
학습 패러다임: 사전학습+SFT+강화학습 표준 패러다임 준수
특징: GPT-4 Turbo에 필적하는 성능. MLA로 KV 캐시를 90% 이상
절감하고 추론 속도를 5배 이상 향상. MoE 아키텍처로 파라미터 확장 시
추론 비용은 거의 일정하게 유지하면서 학습 비용을 대폭 낮추고 성능 향상

3 *2024.9*

DeepSeek-V2.5

V2 기반으로 범용 태스크 역량 및
코드 역량을 집중 최적화

DeepSeek 시리즈 대규모 모델

3 *2024.9*

DeepSeek-V2.5

V2 기반으로 범용 태스크 역량 및 코드 역량을 집중 최적화

4 *2024.12*

DeepSeek-V3

파라미터 규모: 671B 파라미터 (활성 파라미터 37B)
학습 데이터: 14.8T 토큰 코퍼스
아키텍처: V2 기반에 무보조손실(Auxiliary-loss-free) 전략을 도입해 전문가 로드 밸런싱 수행. 다중 토큰 예측(MTP) 학습으로 모델 성능 향상 및 추론 가속화. FP8 혼합 정밀도를 도입해 학습 및 추론 비용 절감
학습 데이터: 14.8T 토큰 코퍼스
학습 패러다임: 사전학습+SFT+DPO 표준 대규모 모델 학습 패러다임 준수
특징: 주류인 Llama3 시리즈와 Qwen2.5 시리즈의 성능을 능가하면서 학습 비용과 추론 비용을 대폭 절감

DeepSeek 시리즈 대규모 모델

4 *2024.12*

DeepSeek-V3

파라미터 규모: 671B 파라미터 (활성 파라미터 37B)
학습 데이터: 14.8T 토큰 코퍼스
아키텍처: V2 기반에 무보조손실(Auxiliary-loss-free) 전략을 도입해 전문가 로드 밸런싱 수행. 다중 토큰 예측(MTP) 학습으로 모델 성능 향상 및 추론 가속화. FP8 혼합 정밀도를 도입해 학습 및 추론 비용 절감
학습 데이터: 14.8T 토큰 코퍼스
학습 패러다임: 사전학습+SFT+DPO 표준 대규모 모델 학습 패러다임 준수
특징: 주류인 Llama3 시리즈와 Qwen2.5 시리즈의 성능을 능가하면서 학습 비용과 추론 비용을 대폭 절감

5 *2025.01*

DeepSeek-R1

베이스 모델: DeepSeek-V3-Base
학습 데이터: 14.8T 토큰 코퍼스
학습 패러다임: Base 모델에서 직접 다단계 학습, 콜드 스타트(Cold-start) 학습 및 강화학습 수행
특징: 최초로 OpenAI o1급의 추론 능력을 달성

대규모 모델 배포

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 대규모 모델 유형:
  - 대규모 언어 모델: Qwen
  - 멀티모달 모델: MiniCPM
- 배포 방식:
  - API 호출
  - 로컬 배포

	Qwen2-72B	Llama3-70B	Mixtral-8x22B	Qwen1.5-110B
MMLU	**84.2**	79.5	77.8	80.4
MMLU-Pro	**55.6**	52.8	49.5	49.4
GPQA	**37.9**	36.3	34.3	35.9
TheoremQA	**43.1**	32.3	35.9	34.9
BBH	**82.4**	81.0	78.9	74.8
HumanEval	**64.6**	48.2	46.3	54.3
MBPP	**76.9**	70.4	71.7	70.9
MultiPL-E	**59.6**	46.3	46.7	52.7
GSM8K	**89.5**	83.0	83.7	85.4
MATH	**51.1**	42.5	41.7	49.6
C-Eval	**91.0**	65.2	54.6	89.1
CMMLU	**90.1**	67.2	53.4	88.3
Multi-Exam	**76.6**	70.0	63.5	75.6
Multi-Understanding	**80.7**	79.9	77.7	78.2
Multi-Mathematics	**76.0**	67.1	62.9	64.4

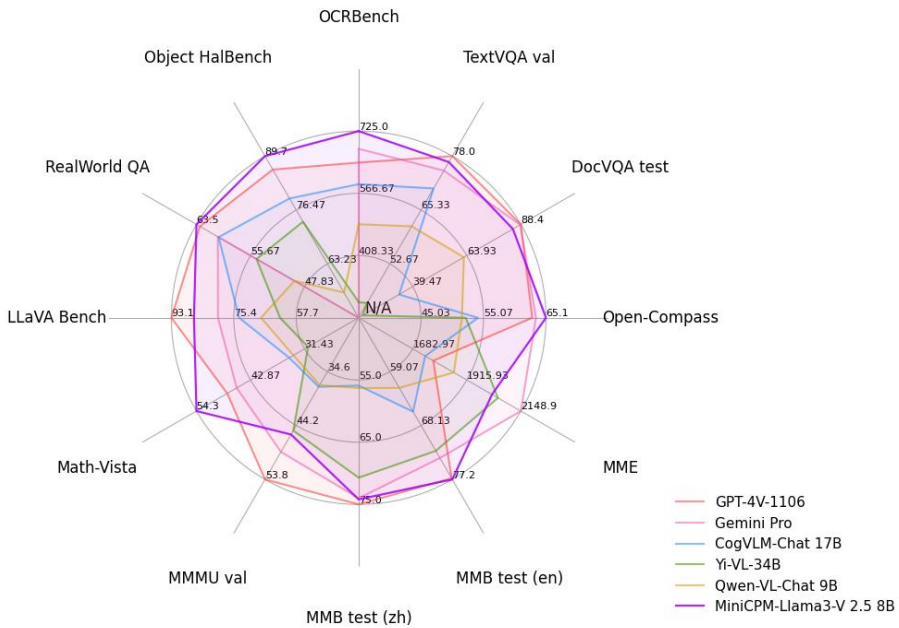

대규모 모델 배포 (기능 예시)

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

Language Understanding

父亲：아버지: 아들아, 고등학교를 졸업했는데 이제 어느 대학에 갈 생각이니?
儿子：아들: 아버지, 지원 서류는 이미 준비했고 좋은 학부 전공에 지원하고 싶어요.
父亲：아버지: 그럼 어떤 대학들에 지원할지 생각해 두었니?
儿子：아들: 네, 상위권 대학 몇 곳에 지원할 계획이에요. 학업, 사교, 진로 계획 등 전반적으로 저를 발전시키기 위해 많이 조사했어요.
父亲：아버지: 좋구나! 네가 늘 열심히 해서 엄마 아빠는 항상 자랑스럽단다. 대학은 새로운 출발점이니 더 많은 도전과 기회를 마주하게 될 거야. 어떤 계획이 있니?
儿子：아들: 대학 생활에 빨리 적응하고 다양한 동아리와 과외 활동에 참여해 시야와 인맥을 넓히고 싶어요. 동시에 전공 지식과 기술을 열심히 배워 좋은 성적을 거두고 장학금도 받고 싶어요.
父亲：아버지: 아주 좋구나! 계획이 참 현명하네. 알차고 의미 있는 대학 생활을 보낼 수 있을 거라 믿는다. 아빠는 늘 네 결정을 응원할게.
儿子：아들: 감사합니다 아버지! 기대에 부응하도록 더 열심히 노력할게요.
这段对话中，关于职业规划、对更多的挑战和机会、同时，我会一直对

대규모 모델 배포 (API 호출)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- **대규모 모델 API 호출 권한 획득**
  - **통의천문(Qwen): https://help.aliyun.com/zh/dashscope/developer-reference/quick-start**
  - DeepSeek: https://www.deepseek.com
  - Llama: https://github.com/Meta-Llama/llama
  - **즈푸 AI(GLM): https://open.bigmodel.cn/**
  - Openai：https://platform.openai.com/playground
  - **기타: 어니봇(ERNIE Bot), 바이촨(Baichuan) 대규모 모델**

***기본 절차: 서비스 가입 후 API-KEY 발급(무료 크레딧 제공), API Key를 사용해 서비스 호출**

대규모 모델 배포 (API 호출)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- GUI 인터페이스를 통한 호출 (사례 테스트에 적합)
  - https://help.aliyun.com/zh/dashscope/developer-reference/quick-start
  - https://huggingface.co/spaces/Qwen/Qwen2-72B-Instruct

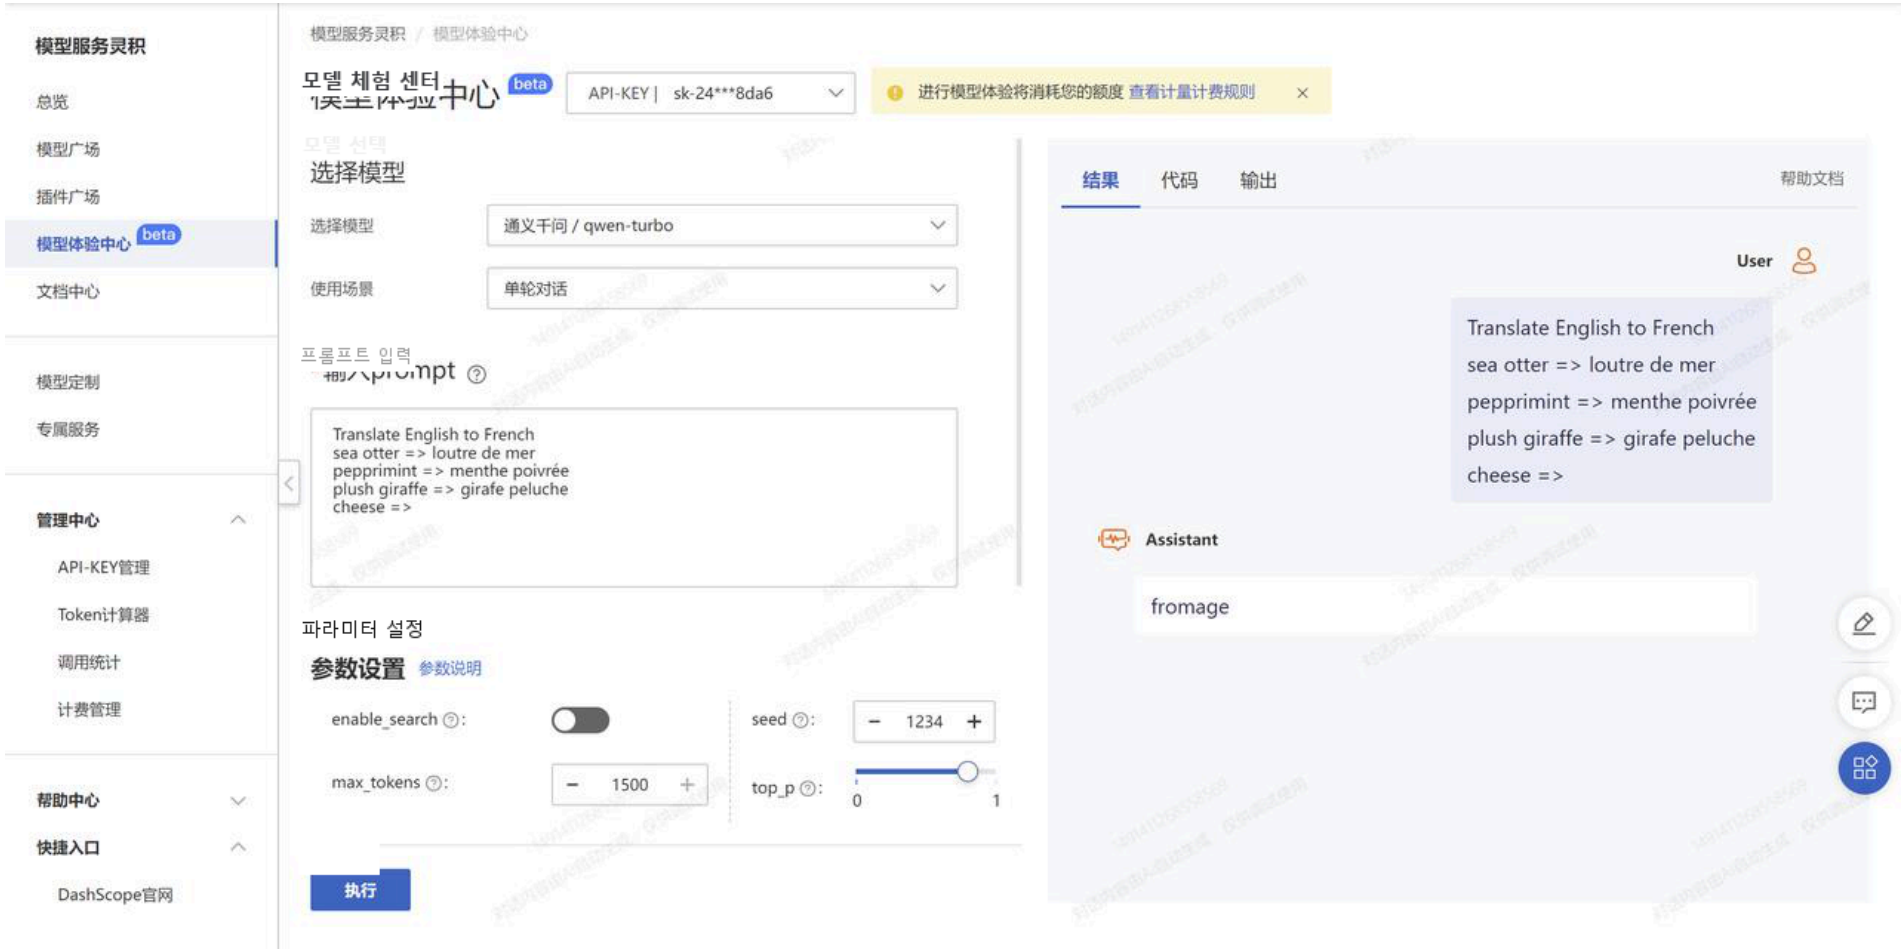

대규모 모델 배포 (API 호출)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

❑ 코드를 통한 호출:

일반 호출:

```
# For prerequisites running the following sample, visit https://help.aliyun.com/document_
import dashscope
def sample_sync_call():
    pro prompt_text = '□□, □□, □□□ □□□ □ □□ □□□□ □□□.'
    resp = dashscope.generation.call(
        model='qwen-turbo',
        prompt=prompt_text
    )
# The response status_code is HTTPStatus.OK indicate success,# otherwise indicate request
        print(resp.output)# The output textprint(resp.usage)# The usage informationelse:
        print(resp.code)# The error code.print(resp.message)# The error message.
sample_sync_call()
```

스트리밍 호출:

```
# For prerequisites running the following sample, visit https://help.aliyun.com/document_

import dashscope
def sample_sync_call_streaming():
    pro prompt_text = '□□, □□, □□□ □□□ □ □□ □□□□ □□□.'
    response_generator = dashscope.Generation.call(
        model='qwen-turbo',
        prompt=prompt_text,
        stream=True,
        top_p=0.8)
    head_idx = 0
    for resp in response_generator:
        paragraph = resp.output['text']
        print("\r%s" % paragraph[head_idx:len(paragraph)], end='')
        if(paragraph.rfind('\n') != -1):
            head_idx = paragraph.rfind('\n') + 1
sample_sync_call_streaming()
```

❑ 환경 준비 (선택 사항):

- **VS Code 개발 도구:** https://code.visualstudio.com/
- **Miniconda를 활용한 Python 환경 관리:** https://docs.anaconda.com/free/miniconda/miniconda-install

대규모 모델 배포 (로컬 배포)

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 대규모 모델 로컬 배포 오픈소스 플랫폼: Ollama, LM Studio
- 웹 및 API 호출: OpenAI, DashScope API
- 대규모 모델 로컬 프라이빗 배포: Flask, MindIE

Ollama https://ollama.com/

- **사용자 경험:** 매우 가볍고 설치가 간편하여 개발자 및 터미널 환경에 최적화됨
- **커스터마이징:** Modelfile을 통해 맞춤형 시스템 프롬프트 및 다양한 양자화 모델 실행의 높은 유연성 제공
- **오픈소스 생태계:** 완전한 오픈소스로 투명하며 다양한 서드파티 앱 및 프레임워크와 손쉽게 연동
- **지원 환경:** macOS, Linux 및 Windows(프리뷰) 지원, CPU/GPU 가속 완벽 대응

LM Studio https://lmstudio.ai/

- **주요 기능:** 로컬 LLM 탐색, 다운로드 및 실행, 직관적인 채팅 인터페이스, OpenAI 호환 로컬 API 서버 지원 등 풍부한 기능 제공
- **UI 편의성:** Ollama 대비 그래픽 사용자 인터페이스(GUI)가 뛰어나 초보자 및 일반 사용자 친화적임
- **모델 선택:** Hugging Face 등에서 제공하는 방대한 오픈소스 모델을 손쉽게 검색하고 다운로드 가능
- **지원 환경:** Apple Silicon (M1/M2/M3/M4) Mac, AVX2 지원 Windows PC 완벽 지원 (Linux 프리뷰 제공)

```
(base) zhangzhuosheng@zhangzhuoshengdeiMac ~ % ollama run qwen2:7b
pulling manifest
pulling manifest
pulling manifest
pulling 43f7a214e532... 100% ▕████████████████████████████████████▏ 4.4 GB
pulling 62fbfd9ed093... 100% ▕████████████████████████████████████▏ 182 B
pulling c156170b718e... 100% ▕████████████████████████████████████▏ 11 KB
pulling f02dd72bb242... 100% ▕████████████████████████████████████▏ 59 B
pulling 648f809ced2b... 100% ▕████████████████████████████████████▏ 485 B
verifying sha256 digest
writing manifest
removing any unused layers
success
>>> □□ □□□?
저는 알리바바 클라우드가 개발한 초대규모 언어 모델 Qwen(통의천문)입니다. AI 어시스턴트로서 질문에 답변하고 문제를 해결하
>>> □□ □□□ □□ □□□ □□ □□□ □ 35□, □□□ 94□□ □ □□ □ □□□□?
...
이 문제는 고전 수학 문제인 '계토동롱(닭과 토끼 우리)' 문제입니다.
닭의 수를 x, 토끼의 수를 y라고 하면:
1. 머리의 수: x + y = 35
2. 다리의 수: 2x + 4y = 94 (닭은 다리 2개, 토끼는 다리 4개)
첫 번째 식에서 x = 35 - y를 구해 두 번째 식에 대입하면:
2(35 - y) + 4y = 94 => 70 - 2y + 4y = 94 => 2y = 24 => y = 12 (토끼 12마리)
x = 35 - 12 = 23 (닭 23마리)
따라서 닭은 23마리, 토끼는 12마리입니다.
```

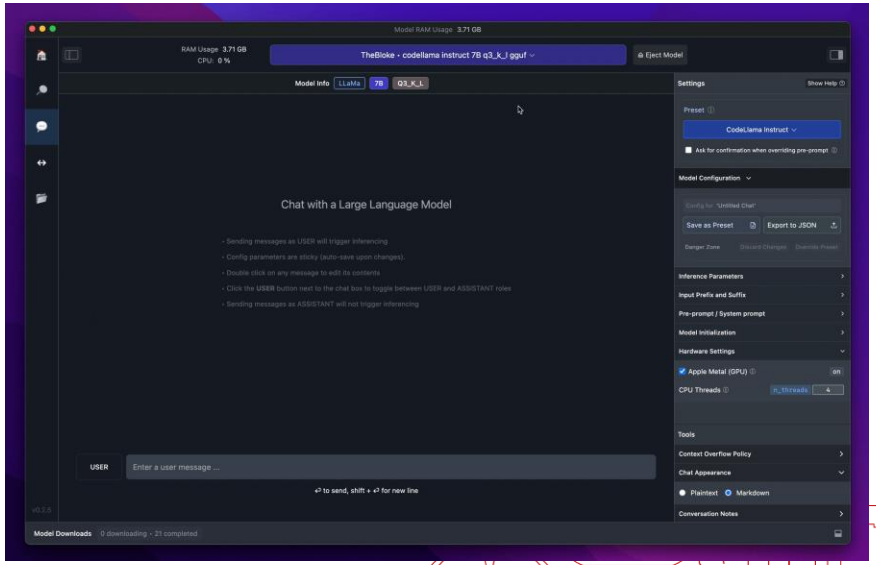

대규모 모델 배포 (로컬 배포)

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

❑ 시스템 사양 요구사항

모델	추론 VRAM (GB)	미세조정 VRAM (GB)
Qwen2-0.5B-Instruct	최소	최소
Qwen2-1.5B-Instruct	최소	최소
Qwen2-7B-Instruct	최소	최소
Qwen2-72B-Instruct	최소	최소
Qwen2-MoE-57B-A14B-Instruct	최소	최소

VRAM 요구사항

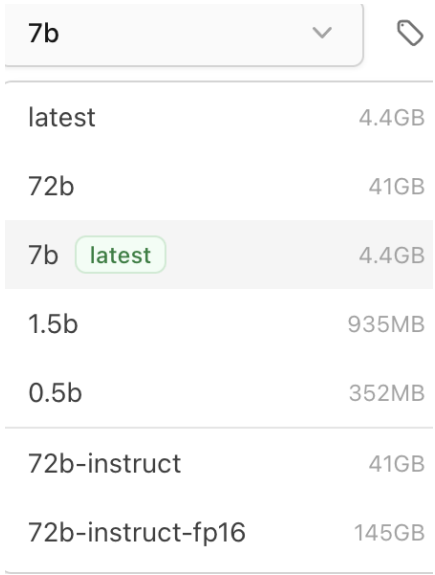

디스크 요구사항

대규모 모델 배포 (로컬 배포)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 1. Ollama 설치
  - 공식 웹사이트 접속: 브라우저를 열고 Ollama 공식 웹사이트에 접속합니다.
  - 버전 선택: 운영체제(macOS, Linux, Windows)에 맞는 설치 패키지를 선택합니다.
  - 설치 파일 다운로드: Download 버튼을 클릭해 기기에 맞는 Ollama 설치 파일을 다운로드합니다.
  - Ollama 설치: 다운로드한 패키지 형식에 따라 설치 프로그램을 실행하거나 지정한 디렉터리에 압축을 풉니다.
- 2. 특정 모델 실행 (ollama run qwen2:7b)

```
(base) zhangzhuosheng@zhangzhuoshengdeiMac ~ % ollama run qwen2:7b
pulling manifest
pulling manifest
pulling manifest
pulling 43f7a214e532...  21% ▕██████████                    ▏ | 929 MB/4.4 GB  5.6 MB/s  10m19s
```

대규모 모델 배포 (로컬 배포)

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 1. Ollama 설치
- 2. 특정 모델 실행 (ollama run qwen2:7b)

```
(base) zhangzhuosheng@zhangzhuoshengdeiMac ~ % ollama run qwen2:7b
pulling manifest
pulling manifest
pulling manifest
pulling 43f7a214e532... 100% ▕████████████████████████████████████████▏ 4.4 GB
pulling 62fbfd9ed093... 100% ▕████████████████████████████████████████▏  182 B
pulling c156170b718e... 100% ▕████████████████████████████████████████▏  11 KB
pulling f02dd72bb242... 100% ▕████████████████████████████████████████▏   59 B
pulling 648f809ced2b... 100% ▕████████████████████████████████████████▏  485 B
verifying sha256 digest
writing manifest
removing any unused layers
succe^^
>>>  >>> 너는 누구니
>>> 저는 알리바바 클라우드가 개발한 초대규모 언어 모델 통의천문(Qwen)입니다. AI 어시스턴트로서 정확하고 유용한 정보를 제공하여 문제를 해결해 드리는 것이 목표입니다. 언제든 질문해 주세요!
提供高质量的服务。如果您有任何问题或需要帮助，请随时告诉我！

>>> >>> 닭과 토끼가 같은 우리에 있고 머리는 총 35개, 다리는 94개일 때 각각 몇 마리인가?
...
1. 이 문제는 고전 수학 문제인 "계토동롱(닭과 토끼 우리)" 문제입니다.
2. 닭의 수를 x, 토끼의 수를 y라고 합시다.
1. 머리의 합: (x + y = 35)
2. 다리의 합: (2x + 4y = 94) (닭은 다리가 2개, 토끼는 4개)
첫 번째 식에서 (x = 35 - y)를 구해 두 번째 식에 대입하면:
[2(35 - y) + 4y = 94]
전개하면: [70 - 2y + 4y = 94]
동류항을 정리하면: [2y = 24]
따라서 (y = 12), 즉 토끼는 12마리입니다.
(y) 값을 원래 식에 대입하면: (x + 12 = 35) -> (x = 23), 즉 닭은 23마리입니다.
따라서 닭과 토끼의 수는 각각 23마리와 12마리입니다.
```

대규모 모델 배포 (로컬 배포)

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 1. Ollama 설치
- 2. 특정 모델 실행 (ollama run qwen2:7b)

```
(base) zhangzhuosheng@zhangzhuoshengdeiMac ~ % ollama run qwen2:7b
pulling manifest
pulling manifest
pulling manifest
pulling 43f7a214e532... 100% ▕████████████████████████████████████▏ 4.4 GB
pulling 62fbfd9ed093... 100% ▕████████████████████████████████████▏  182 B
pulling c156170b718e... 100% ▕████████████████████████████████████▏  11 KB
pulling f02dd72bb242... 100% ▕████████████████████████████████████▏   59 B
pulling 648f809ced2b... 100% ▕████████████████████████████████████▏  485 B
verifying sha256 digest
writing manifest
removing any unused layers
succe^^
>>>  >>> 너는 누구니
>>> 저는 알리바바 클라우드가 개발한 초대규모 언어 모델 통의천문(Qwen)입니다. AI 어시스턴트로서 정확하고 유용한 정보를 제공하여 문제를 해결해 드리는 것이 목표입니다. 언제든 질문해 주세요!
提供高质量的服务。如果您有任何问题或需要帮助，请随时告诉我！

>>> >>> 닭과 토끼가 같은 우리에 있고 머리는 총 35개, 다리는 94개일 때 각각 몇 마리인가?
...
1. 이 문제는 고전 수학 문제인 "계토동롱(닭과 토끼 우리)" 문제입니다.
2. 닭의 수를 x, 토끼의 수를 y라고 합시다.
1. 머리의 합: (x + y = 35)
2. 다리의 합: (2x + 4y = 94) (닭은 다리가 2개, 토끼는 4개)
첫 번째 식에서 (x = 35 - y)를 구해 두 번째 식에 대입하면:
[2(35 - y) + 4y = 94]
전개하면: [70 - 2y + 4y = 94]
동류항을 정리하면: [2y = 24]
따라서 (y = 12), 즉 토끼는 12마리입니다.
(y) 값을 원래 식에 대입하면: (x + 12 = 35) -> (x = 23), 즉 닭은 23마리입니다.
따라서 닭과 토끼의 수는 각각 23마리와 12마리입니다.
```

심화 활용:

1. **Open WebUI를 사용하여 웹 인터페이스 구성**
2. **AnythingLLM을 기반으로 로컬 지식 베이스(RAG) 구축**

목차

- 대규모 모델 개요
  - 발전 개관
  - 대규모 모델 범주
- 사전 학습 모델
  - 주요 유형
  - 모델 아키텍처
- 대규모 언어 모델
  - 패러다임 변화
  - 핵심 기술
  - 주요 대표 모델
  - 배포 방식
- **개념 확장**
  - **버티컬(특화) 대규모 모델**
  - **멀티모달 파운데이션**
  - **에이전트 파운데이션**

대규모 모델 개념 확장

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

버티컬(특화) 대규모 모델

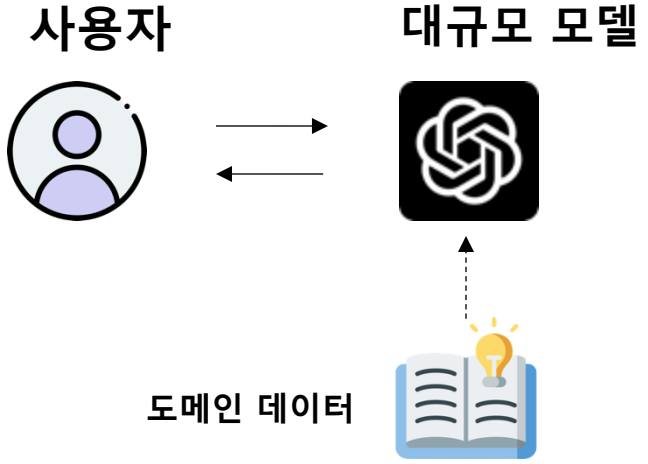

멀티모달 대규모 모델

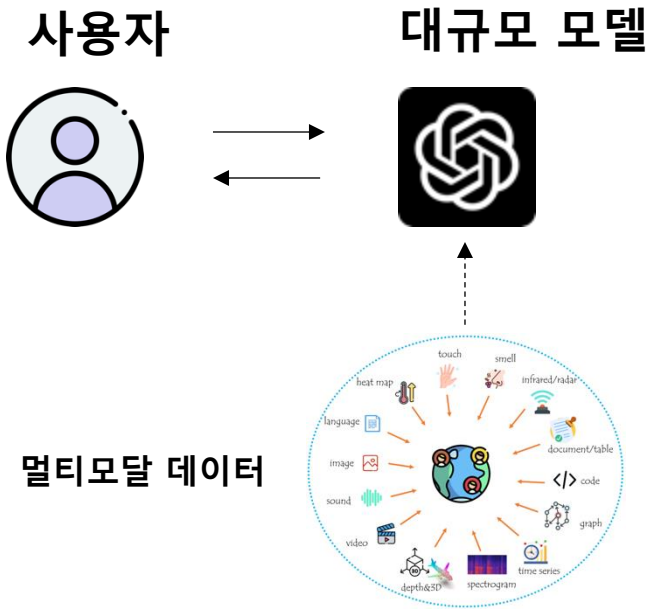

대규모 모델 에이전트

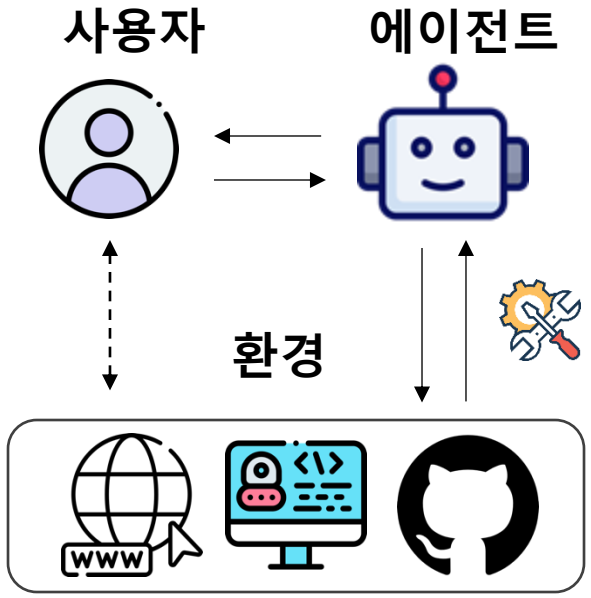

버티컬(특화) 대규모 모델

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 기본 패러다임: 범용 대규모 모델을 바탕으로 도메인 학습을 강화하여 전문성, 도입 속도, 비용 효율성, 규정 준수성이 뛰어남
- 학습 방식: 도메인 데이터 학습(지속 사전학습, 파인튜닝, 프롬프팅), 검색 증강 생성(RAG) 등
- 주요 적용 분야: 교육, 의료, 법률, 금융 등

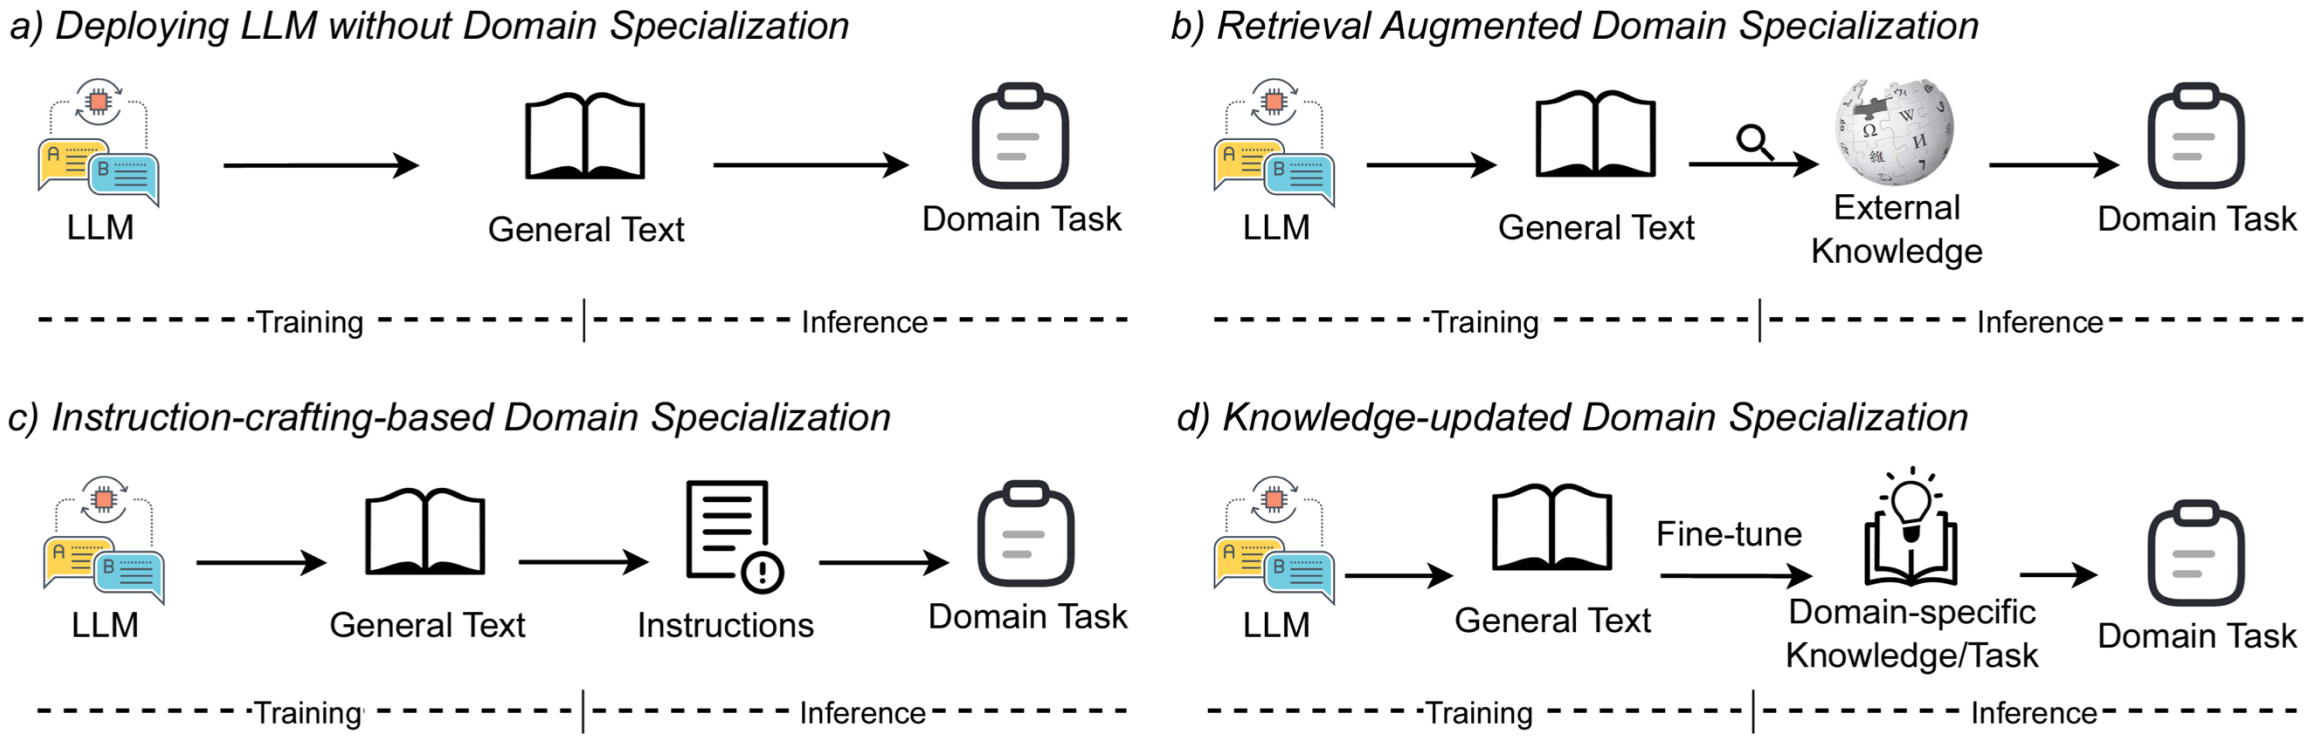

[1] Ling, Chen, et al. Domain specialization as the key to make large language models disruptive: A comprehensive survey. arXiv preprint arXiv:2305.18703.

멀티모달 대규모 모델의 최신 발전

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 멀티모달 대규모 모델의 역량 돌파는 대규모 모델 최신 발전의 새로운 트렌드이자 핵심 초점이 됨
- 대규모 모델의 역량 경계와 응용 시나리오를 크게 확장하며 지능 도약의 차세대 핵심 엔진 역할을 함

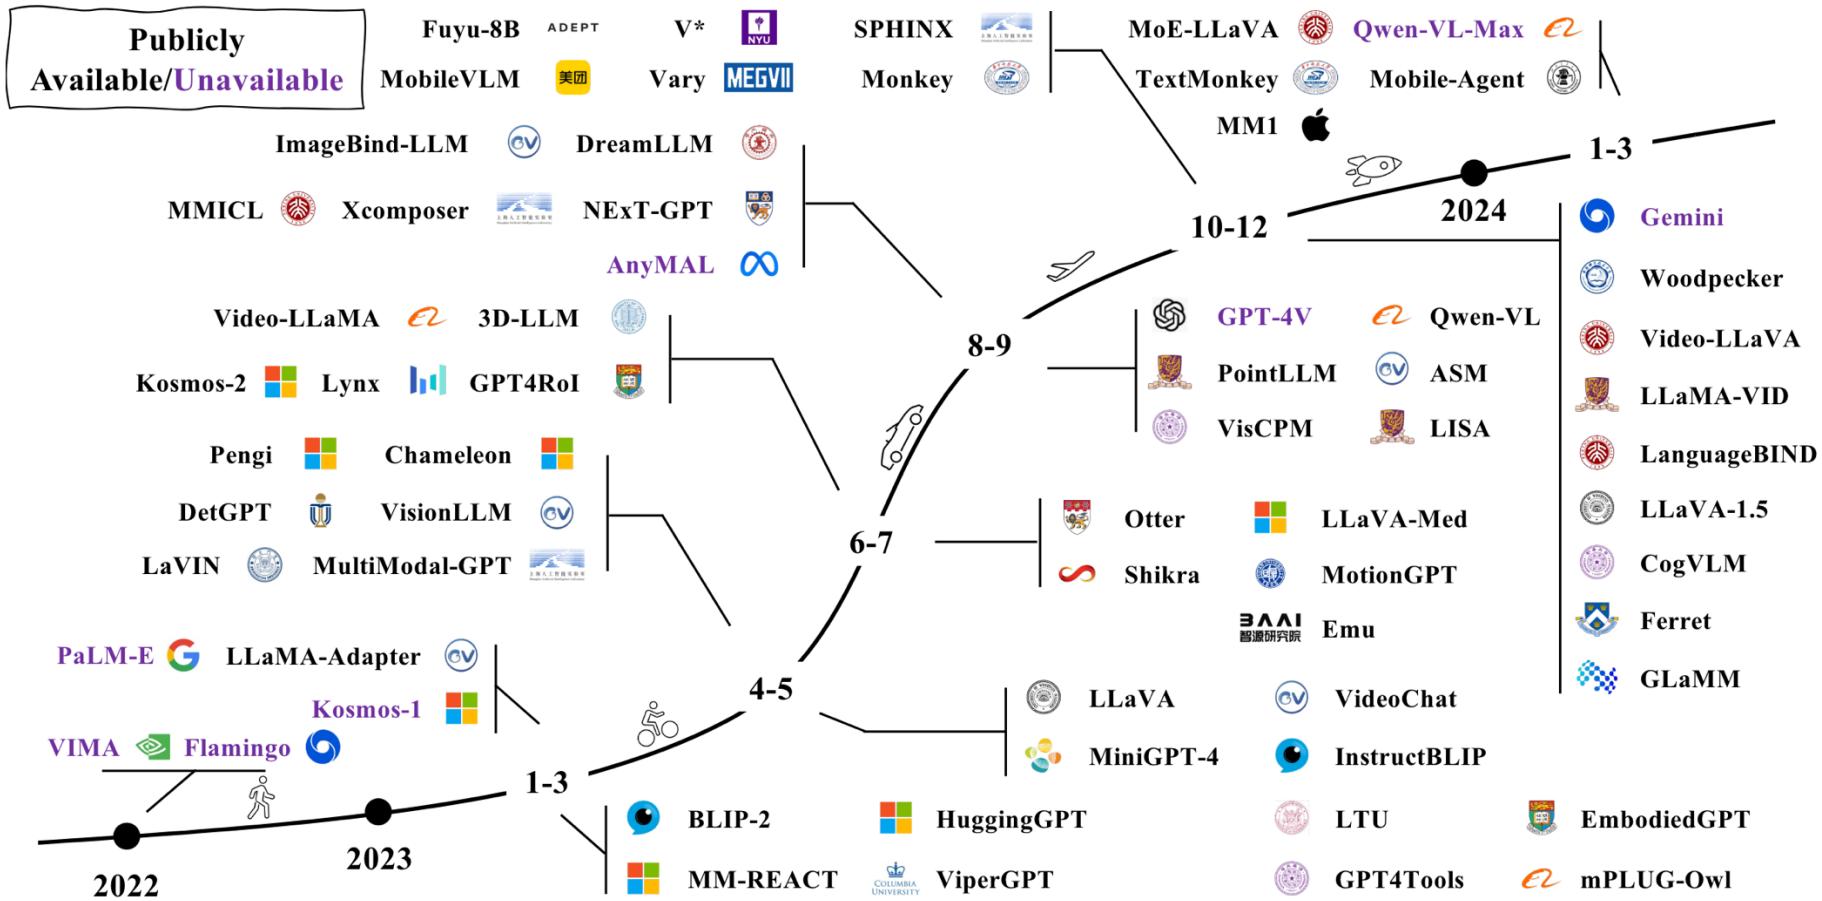

A Survey on Multimodal Large Language Models (https://arxiv.org/pdf/2306.13549)

멀티모달 대규모 모델의 역량 예시

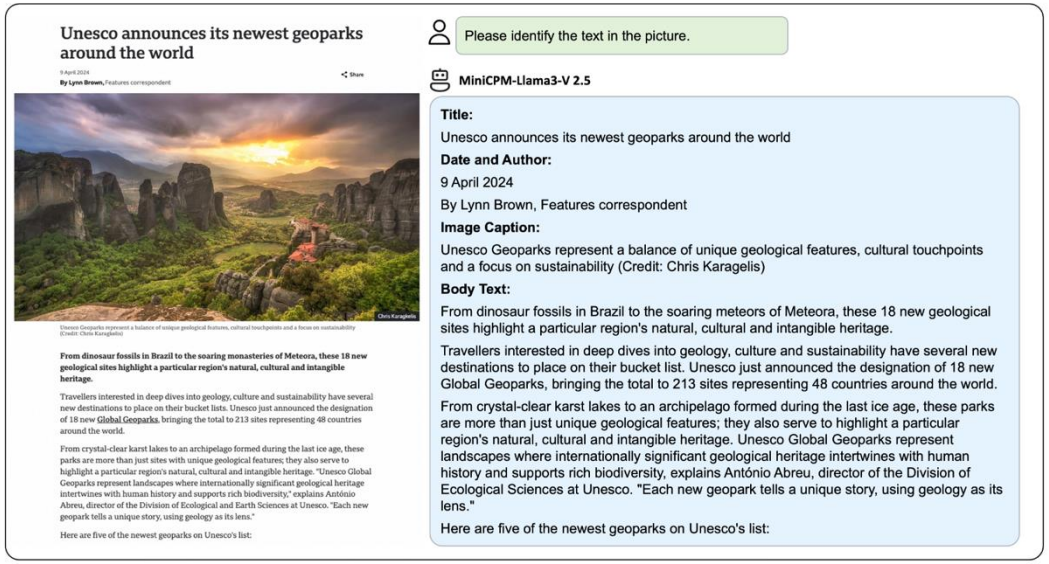

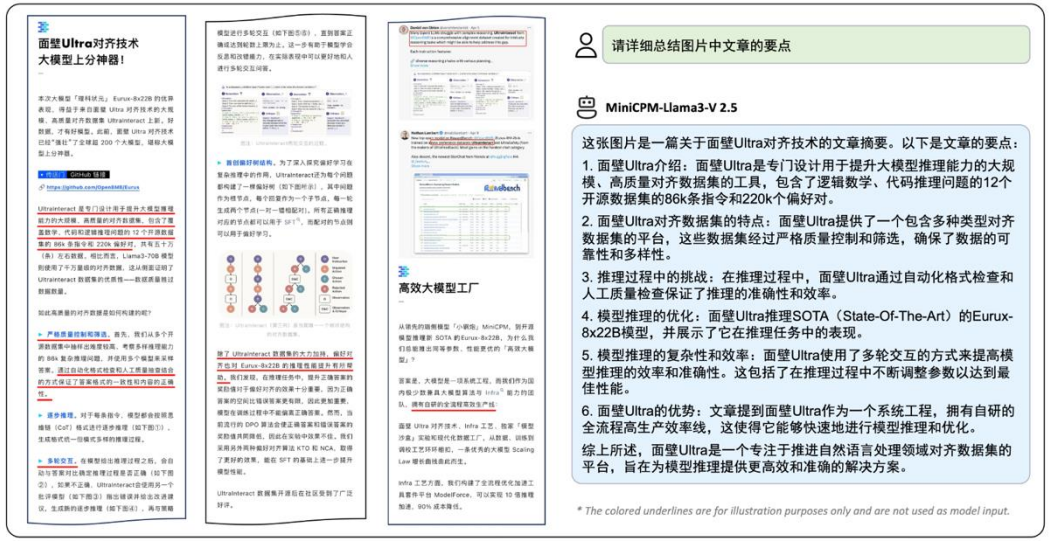

模型名称	发布时间	发布机构	语言	参数规模	Tokens规模	模型结构	是否开源
T5	2019-10	Google	英	13B		T5-style	√
GPT-3	2020-05	OpenAI	英	175B	300B	GPT-style	×
LaMDA	2021-05	Google	英	137B	2.8T	GPT-style	×
Jurassic	2021-08	AI21	英	178B	300B	GPT-style	×
MT-NLG	2021-10	Microsoft, NVIDIA	英	530B	270B	GPT-style	×
ERNIE 3.0 Titan	2021-12	Baidu	中	260B	300B	Multi-task	×
Gopher	2021-12	DeepMind	英	280B	300B	GPT-style	×
Chinchilla	2022-04	DeepMind	英	70B	1.4T	GPT-style	×
PaLM	2022-04	Google	多语言	540B	780B	GPT-style	×
OPT	2022-05	Meta	英	125M-175B	180B	GPT-style	√
BLOOM	2022-07	BigScience	多语言	176B	366B	GPT-style	√
GLM-130B	2022-08	Tsinghua	中、英	130B	400B	GLM-style	√
LLaMA	2023-02	Meta	多语言	7B-65B	1.4T	GPT-style	√

请将表格转成 markdown 格式

MiniCPM-Llama3-V 2.5

模型名称	发布时间	发布机构	语言	参数规模	Tokens规模	模型结构	是否开源
T5	2019-10	Google	英	13B		T5-style	√
GPT-3	2020-05	OpenAI	英	175B	300B	GPT-style	×
LaMDA	2021-05	Google	英	137B	2.8T	GPT-style	×
Jurassic	2021-08	AI21	英	178B	300B	GPT-style	×
MT-NLG	2021-10	Microsoft, NVIDIA	英	530B	270B	GPT-style	×
ERNIE 3.0	2021-12	Baidu	中	260B	300B	Multi-task	×
Gopher	2021-12	DeepMind	英	280B	300B	GPT-style	×
Chinchilla	2022-04	DeepMind	英	70B	1.4T	GPT-style	×
PaLM	2022-04	Google	多语言	540B	7.8/80B	GPT-style	×
OPT	2022-05	Meta	英	125M-175B	180B	GPT-style	√
BLOOM	2022-07	BigScience	多语言	176B	366B	GPT-style	√
GLM-130B	2022-08	Tsinghua	中、英	130B	400B	GLM-style	√
LLaMA	2023-02	Meta	多语言	7B-65B	1.4T	GPT-style	√

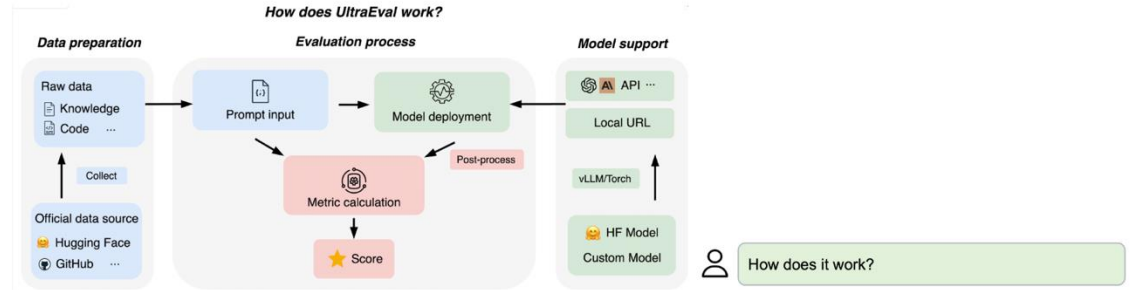

멀티모달 대규모 모델의 최신 발전

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

기술 개요

주요 목표: 빅데이터와 인간 피드백을 기반으로 학습하여 사용자와 대화로 상호작용하며, 멀티모달 정보와 다양한 태스크를 처리하고 심층 추론 및 상식 활용 능력을 대폭 향상

핵심 기술: 멀티모달 모델 아키텍처, 멀티모달 지시 이행, 멀티모달 추론, 경량화 배포, 멀티모달 정렬 등

주요 마일스톤

2023/03/15: OpenAI, 멀티모달 대화 모델 GPT-4 발표
2023/09/20: OpenAI, 텍스트-이미지 생성 모델 DALL·E 3 발표
2023/09/25: ChatGPT, 멀티모달 기능 전면 통합
2023/12/06: Google, 멀티모달 모델 Gemini 발표
2024/03/04: Anthropic, 멀티모달 모델 Claude 3 발표
2024/05/13: OpenAI, 네이티브 멀티모달 모델 GPT-4o 발표

작동 패러다임의 변화

[1] Fei, Hao, et al. From Multimodal LLM to Human-level AI: Modality, Instruction, Reasoning and Beyond. ACM MM, 2024. https://mllm2024.github.io/ACM-MM2024/

멀티모달 대규모 모델의 최신 발전

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 일반적 작동 방식: 멀티모달 인코딩 > 특징 융합 모듈 > 멀티모달 디코더, 멀티모달 입력 및 생성 지원
- 주요 모달리티: 텍스트, 이미지, 비디오, 음성 등

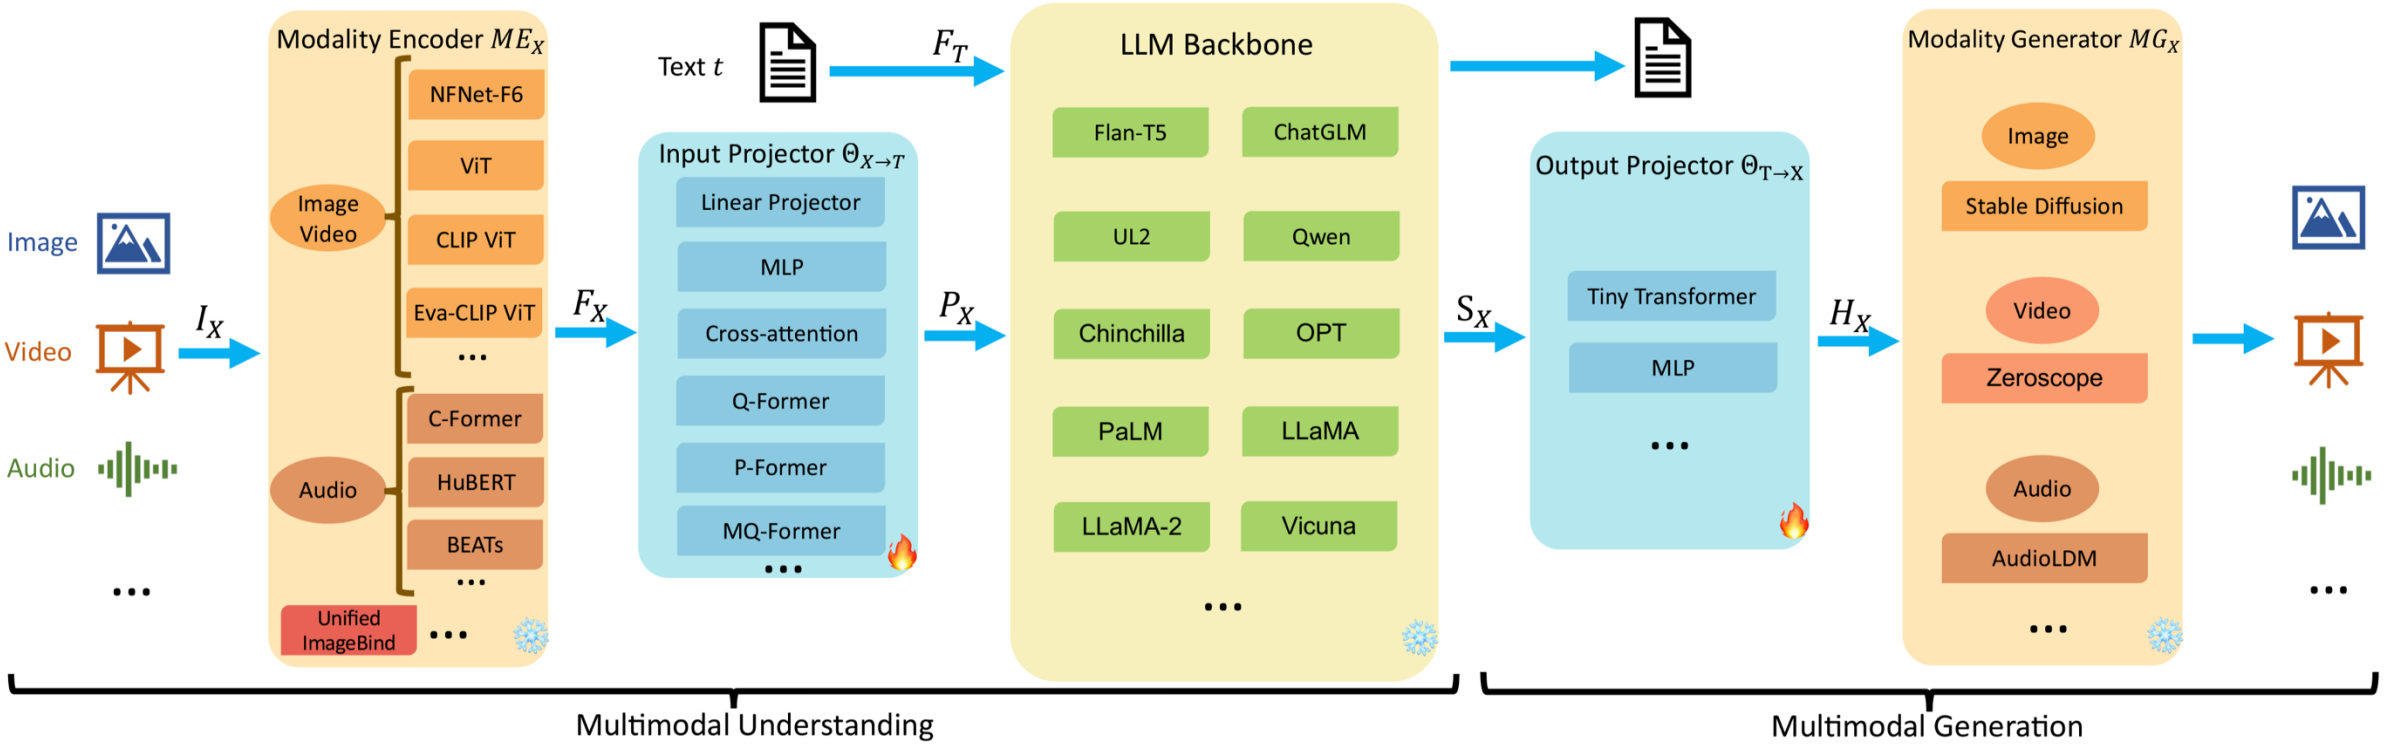

[1] Zhang, Duzhen, et al. Mm-llms: Recent advances in multimodal large language models. arXiv preprint arXiv:2401.13601.

멀티모달 대규모 모델의 대표적 아키텍처

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

LLM 중심 아키텍처

- Visual-ChatGPT
- HuggingGPT
- MM-REACT
- LLaVA-Plus
- ...

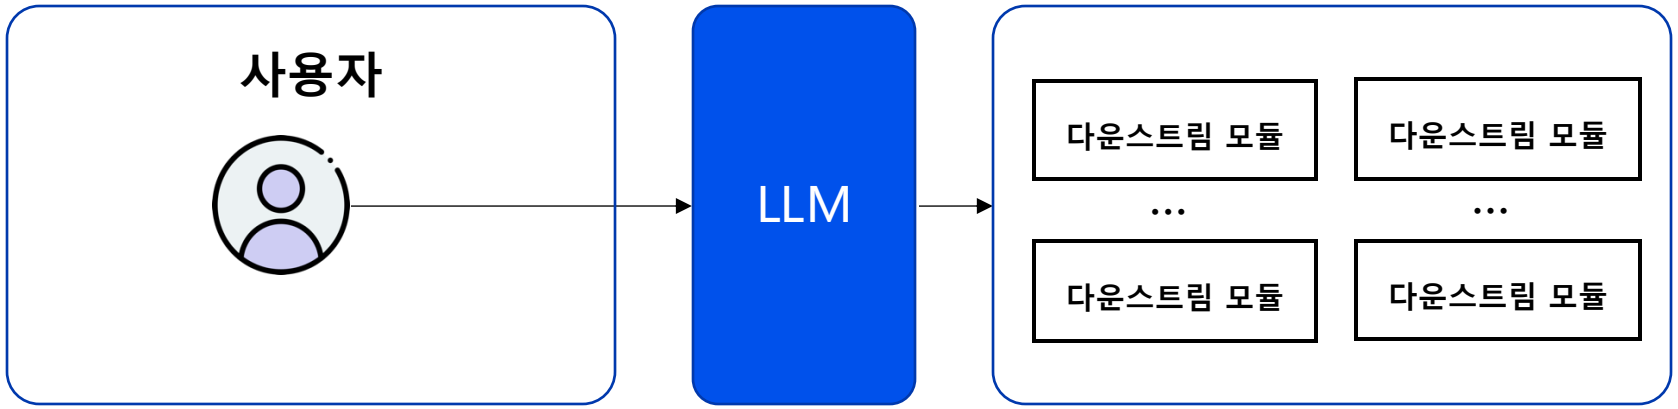

통합형 멀티모달 아키텍처

대다수 멀티모달 대규모 모델의 아키텍처 유형

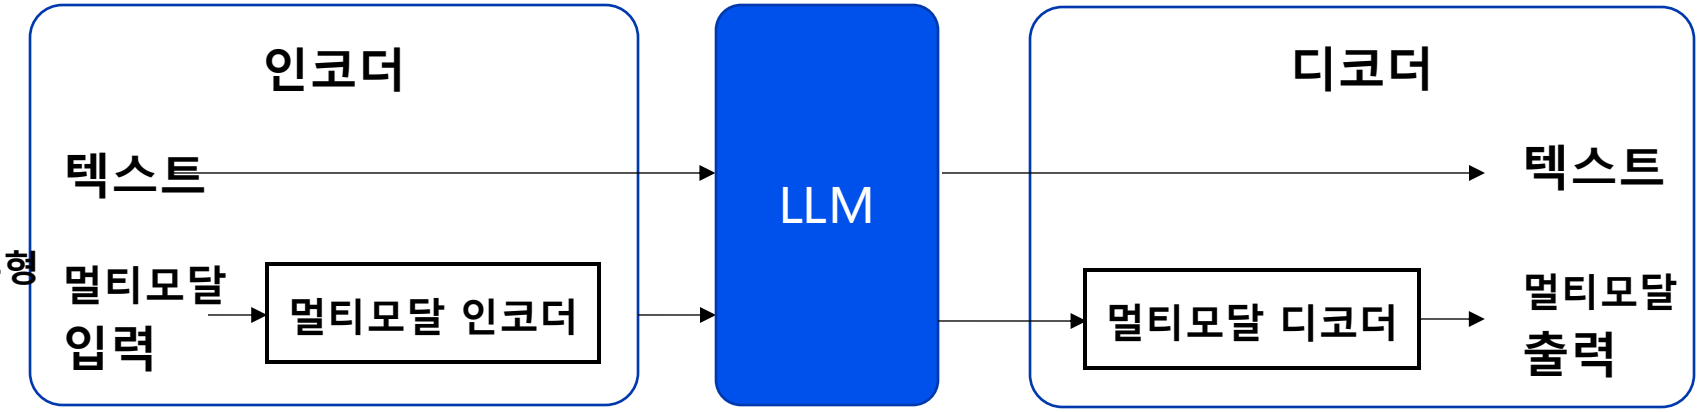

멀티모달 대규모 모델 최신 튜토리얼 (CVPR & MM & COLING)

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

Tutorial

From Multimodal LLM to Human-level AI: Modality, Instruction, Reasoning and Beyond

Hao Fei · Yuan Yao · Ao Zhang · Haotian Liu · Fuxiao Liu · Zhuosheng Zhang · Shuicheng Yan

Summit 446

[Abstract] [Project Page]
Tue 18 Jun 1:30 p.m. PDT — 6 p.m. PDT

Abstract:
Artificial intelligence (AI) encompasses knowledge acquisition and real-world grounding across various modalities. As a multidisciplinary research field, multimodal large language models (MLLMs) have recently garnered growing interest in both academia and industry, showing an unprecedented trend to achieve human-level AI via MLLMs. These large models offer an effective vehicle for understanding, reasoning, and planning by integrating and modeling diverse information modalities, including language, visual, auditory, and sensory data. This tutorial aims to deliver a comprehensive review of cutting-edge research in MLLMs, focusing on three key areas: MLLM architecture design, instructional learning, and multimodal reasoning of MLLMs. We will explore technical advancements, synthesize key challenges, and discuss potential avenues for future research. All the resources and materials will be made available online: https://mllm2024.github. io/CVPR2024

SCHEDULE

PROGRAM

Our tutorial will be held on **Tuesday, June 18, 2024** (all the times are based on **UTC-7 = Seattle local time**).

Time	Section	Presenter
13:30-13:35	Part 1: Background and Introduction [Slides]	Hao Fei
13:35-14:05	Part 2: MLLM Architecture [Slides]	Yuan Yao
14:05-14:35	Part 3: MLLM Modality&Functionality [Slides]	Hao Fei
14:35-15:05	Part 4: MLLM Instruction Tuning [Slides]	Haotian Liu
	Coffee Break, Q&A Session	
16:00-16:30	Part 5: MLLM Hallucination [Slides]	Fuxiao Liu
16:30-17:00	Part 6: MM Reasoning [Slides]	Zhuosheng Zhang
17:00-17:30	Part 7: MLLM Efficiency [Slides]	Ao Zhang
17:30-18:00	Part 8: Panel Discussion - From MM Generalist to Human-level AI	All + Hanwang Zhang + Shuicheng Yan

강의자료 + 영상

https://mllm2024.github.io/CVPR2024

TUTORIAL RECORD

VIDEO

대규모 모델 에이전트

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

어디에나 존재하는 "자비스(J.A.R.V.I.S.)", 광범위한 응용 전망을 보여주는 대규모 모델 에이전트

OpenAI Operator

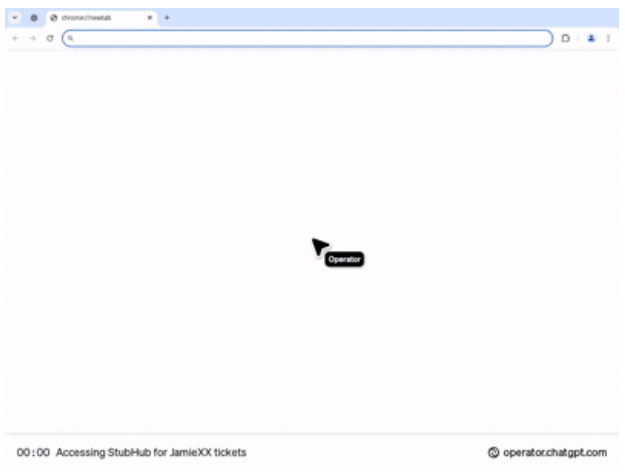

https://openai.com/index/introducing-operator

Anthropic Claude

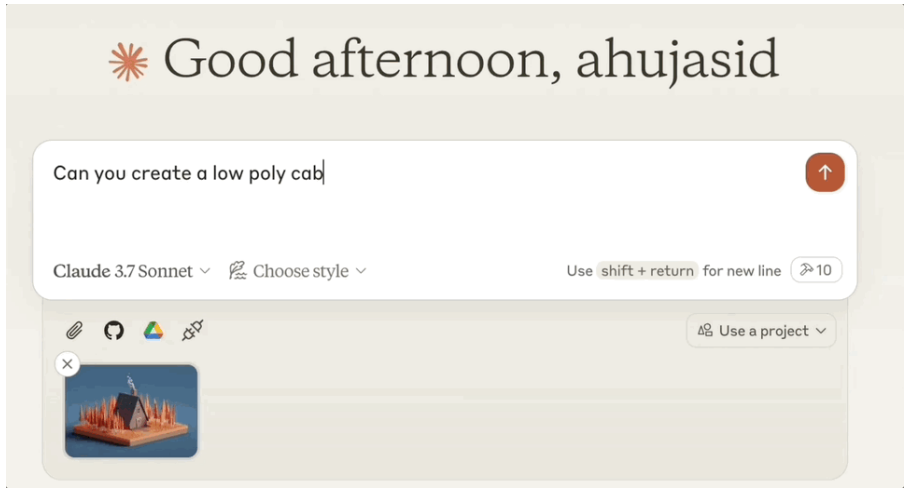

https://www.anthropic.com/claude

Manus AI

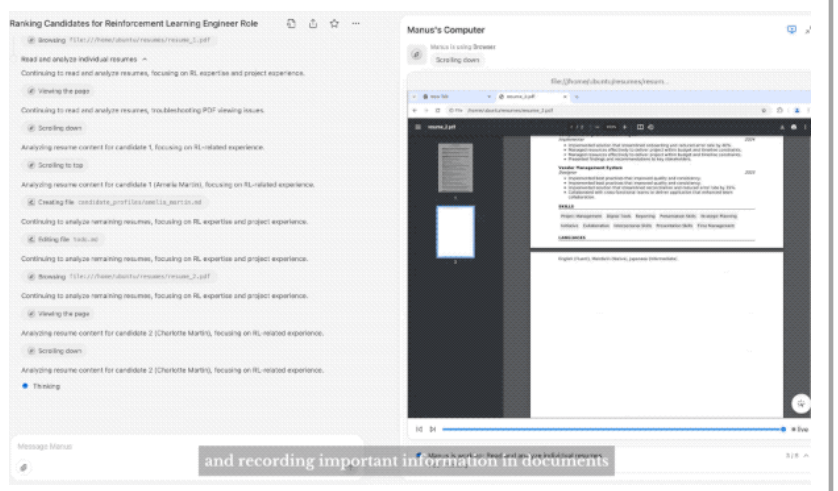

https://manus.im/

대규모 모델 에이전트

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

❑ 대규모 모델을 기반으로 구축되어 자체 프로세스와 도구 사용을 동적으로 지시하고 실시간 피드백에 따라 조작을 조정하는 시스템[1]

(멀티모달) 대규모 언어 모델

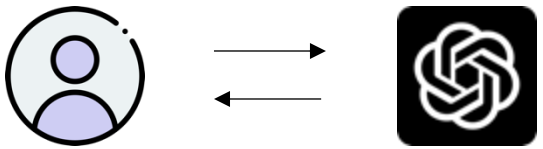

❑ 범용 역량 제공자
- 긴 시퀀스 처리
- 사고의 사슬 추론
- 폭넓은 의도 이해

대규모 모델 에이전트 (시스템)

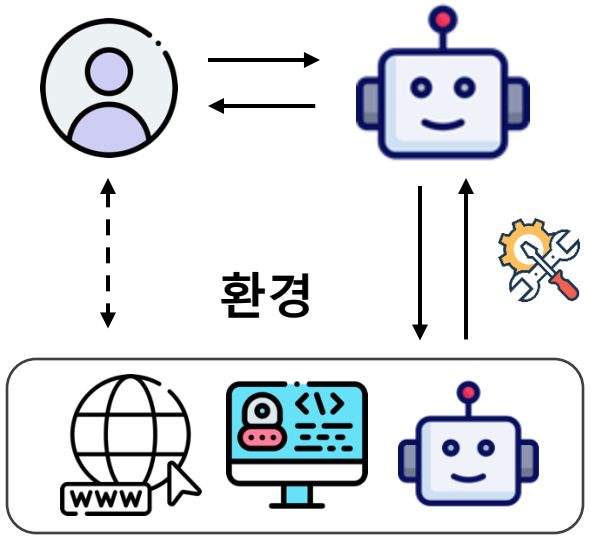

❑ 자율성 및 진화 능력 보유
- 환경 상호작용: 지각 이해, 계획 및 의사결정, 행동 실행
- 지속 실행: 성찰 및 최적화, 반복 진화, 보안 방호

❑ 지식 업데이트: 지식 베이스, 경험 베이스

❑ 통합 도구: 앱(APP), API, 함수

[1]Anthropic. Building effective agents. Published Dec 19, 2024

대규모 모델 에이전트

워크플로우 오케스트레이션

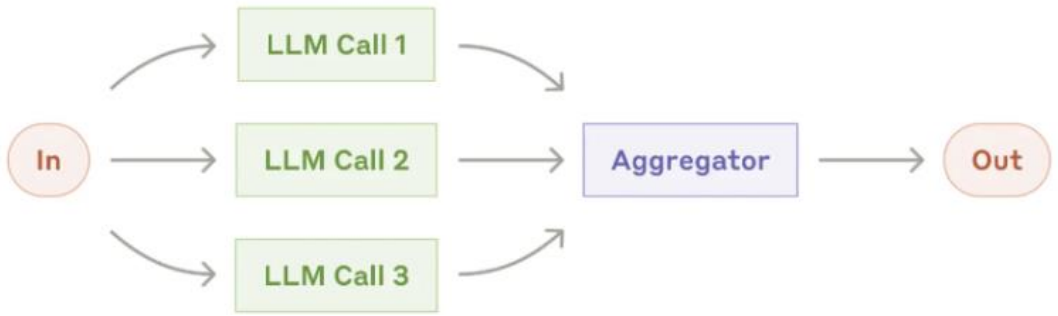

사전 정의된 경로를 통해 LLM과 도구를 오케스트레이션하며,

복잡한 자동화 스크립트와 유사함. 주로 프롬프트 방식으로 구현

에이전트 파운데이션

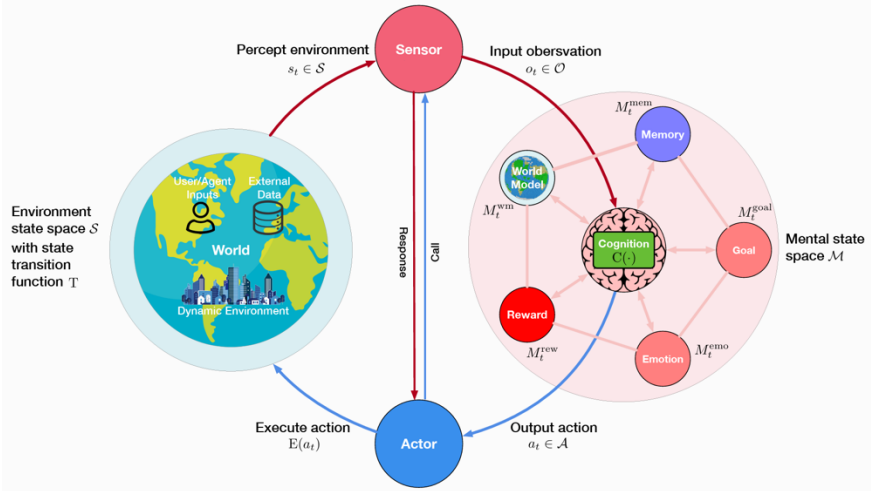

행동 과정과 도구 사용을 자율적으로 지시하고 경로를 동적으로 계획·업데이트하며,

태스크 수행 방식에 대한 제어권을 유지함. 주로 학습 방식으로 역량을 확장

AI를 오케스트레이션 가능한 컴포넌트로 간주

AI에게 더 큰 자율성과 진화 가능성을 부여

대규모 모델의 역량 한계 돌파

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

❑ 대규모 모델 에이전트의 역량 돌파는 새로운 핵심 초점이 되었으며 대규모 모델의 역량 경계와 응용 시나리오를 크게 확장함

L1: Chatbots

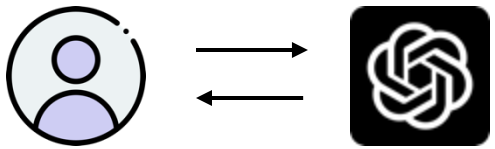

GPT-4、DeepSeek-V3

범용 언어 상호작용

응용: 질의응답, 대화, 검색

L2: Reasoners

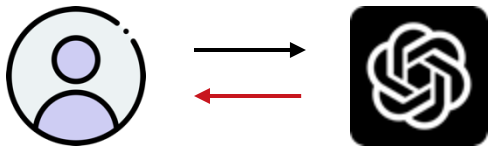

o1, DeepSeek-R1

심층 사고 및 추론

응용: 수학, 논리적 추론

L3: Agents

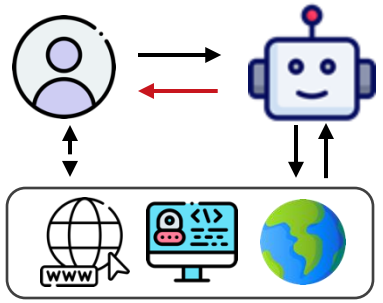

Operator, Deep Research

자율 행동 및 상호작용

응용: 도구 호출, 조작, 탐색

L4: Innovators

혁신 및 발명

L5: Organizations

조직 및 관리

언어 -> 행동: 콘텐츠 지능에서 행동 지능으로, 범용 인공지능(AGI)으로 나아가는 핵심 연결고리 구축

추가 읽을거리

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

《대규모 모델 개발 전 과정》

자체 대규모 모델 강의: 54개 강의, 26개 실습 매뉴얼

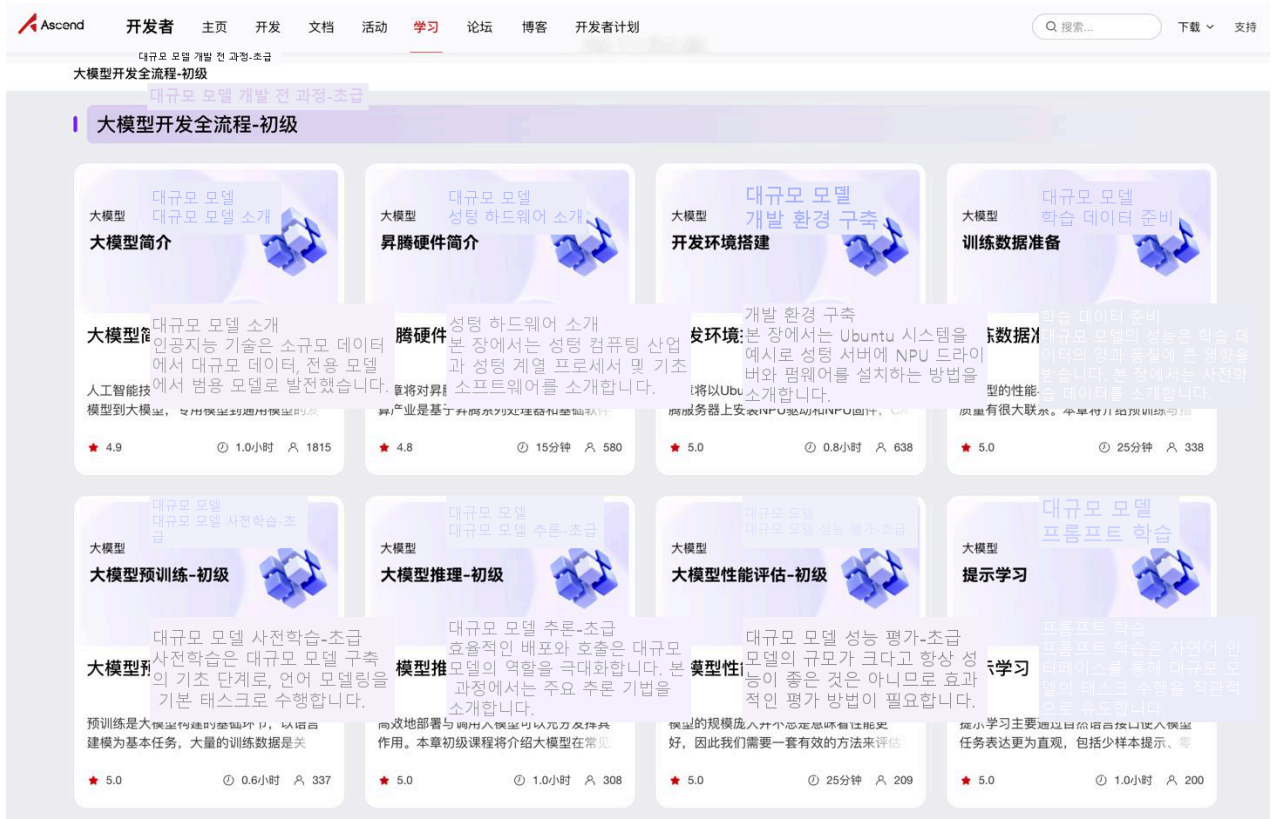

https://www.hiascend.com/edu/growth/lm-development

감사합니다!

zhangzs@sjtu.edu.cn
https://bcmi.sjtu.edu.cn/~zhangzs