직접 배우는 대규모 모델 스테가노그래피

장위룽 (Zhang Yulong)

보안 통신에서의 대규모 모델 응용

- 스테가노그래피(Steganography)는 정보 은닉 기술로, 핵심 목적은 정보를 다양한 매개체(디지털 이미지, 오디오, 비디오 또는 텍스트 등)에 삽입하여 은밀한 통신을 구현하는 것입니다. 암호화 기술과 달리 내용뿐만 아니라 정보 전송 행위의 존재 자체를 숨깁니다. 인간 지각 시스템이 특정 정보에 둔감한 특성을 이용해 비밀 정보를 디지털 매개체의 잉여 정보에 숨겨 표면적으로 일반 매개체와 다름없어 보이게 함으로써 공격자가 눈치채기 어렵게 합니다.

- 스테가노그래피의 응용은 은밀한 전송, 저작권 보호 등을 포함합니다. 기술이 발전함에 따라 군사, 상업 등의 분야에서 점점 더 중요해지고 있으며, 동시에 간첩 활동이나 테러 공격 같은 악의적 행위에 악용될 수도 있습니다.

스테가노그래피의 의의

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 간단히 말해, 스테가노그래피는 암호학과는 다른 일종의 보안 정보 전송 방법입니다.
- 암호는 평문을 "암호화"하여 전달하려는 메시지 내용을 중간자가 알 수 없게 하지만, 메시지 전달 매개체는 중간자에게 발각 및 탈취되어 메시지 전달이 변조되거나 차단될 수 있습니다.
- 반면 스테가노그래피는 메시지 전달 사실 자체를 "은닉"하여 공개 채널에 일반 콘텐츠로 위장해 숨기며, 목표는 오직 수신자만이 숨겨진 메시지를 발견하고 중간자는 눈치채지 못하게 하는 것입니다.

실생활의 간단한 스테가노그래피 사례: 삼행시(아크로스틱), 책 사이에 끼운 작은 쪽지 등.

스테가노그래피의 하위 파생 기술: 워터마킹(강건성을 더 중시하며 많은 사람이 정보를 발견하고 판독할 수 있도록 한 스테가노그래피로 이해할 수 있음).

스테가노그래피 사례와 암호 비교

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 스테가노그래피 (텍스트 서식):
  - 작동 방식: 전자 문서의 자간(예: 0.1pt 차이), 글자 색상(#000000 vs #010101)을 조정하여 이진수로 정보를 인코딩(예: "넓은 간격=1, 보통=0") [1].
  - 목표: 정보를 공개 텍스트 속에 숨겨 육안으로는 보이지 않게 함.
- 암호학 (비제네르 암호):
  - 작동 방식: 키워드를 반복 사용해 암호화 (예: 키 "KEY"로 "HELLO" 암호화 → "RIJVS").
  - 목표: 알아볼 수 없는 암호문을 생성하며 복호화에 키가 필요함 [7].
  - 비교:
    - 스테가노그래피: 매개체가 정상적인 파일(예: 계약서)이므로 의심을 사지 않음.
    - 암호학: 암호문 자체가 "비밀이 있음"을 노출하지만 내용은 기밀로 유지됨.

스테가노그래피 사례

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 스테가노그래피 (이미지 LSB):
  - 작동 방식: 이미지 픽셀의 최하위 유효 비트(LSB)를 수정해 비밀 데이터(예: 다른 이미지의 이진 데이터)를 삽입. 육안으로는 차이를 감지할 수 없으나 도구로 추출 가능 [29].
  - 목표: 일반 사진(예: 여행 사진)에 정보를 숨겨 검열을 우회.
- 암호학 (AES-256):
  - 작동 방식: 키를 사용해 파일을 난수화된 암호문으로 변환 (예: z.exe → G8x!gF2*...
  - 목표: 파일이 탈취되더라도 내용을 해독할 수 없음.
- 결합 활용 사례:
  - 먼저 AES로 민감한 데이터를 암호화;
  - 그 다음 암호문을 이미지 LSB에 삽입.
    → 이중 보호: 존재 자체를 은닉(일반 이미지처럼 보임)함과 동시에 내용도 은닉(복호화에 키 필요)

스테가노그래피 사례

- **QR 코드 내 스테가노그래피:**

  원리: 겉보기에 완전히 정상적인 QR 코드(무해한 웹사이트로 연결)를 설계하되, 오류 정정 영역이나 정교하게 설계된 모듈 패턴을 통해 추가 은닉 정보(다른 URL, 텍스트, 작은 이미지)를 삽입. 일반 스캐너 앱은 표면 정보만 읽을 수 있고, 맞춤형 소프트웨어가 있어야 은닉 계층을 읽을 수 있음.

  예시: 식당 메뉴판의 QR 코드를 스캔하면 메뉴 소개(공개 계층)가 표시되지만, 특정 앱으로 스캔하면 숨겨진 당일 할인 코드나 내부 직원 정보를 획득. 포스터의 QR 코드는 일반 스캔 시 행사 소개, 은닉 계층은 VIP 초대장.

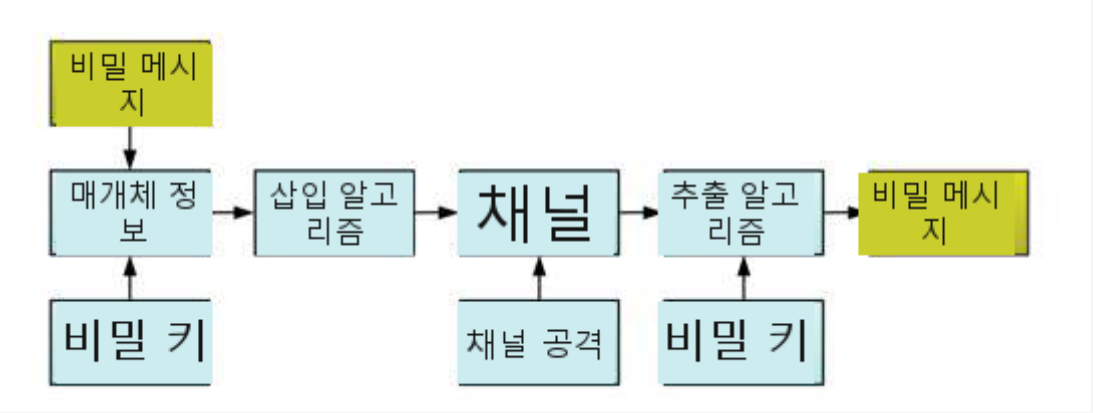
  실생활 시나리오: 마케팅 이벤트(보물찾기, 혜택 잠금 해제), 내부 정보 전달(직원 공지), 저작권 보호(공개 QR 코드에 소유자 정보 삽입).

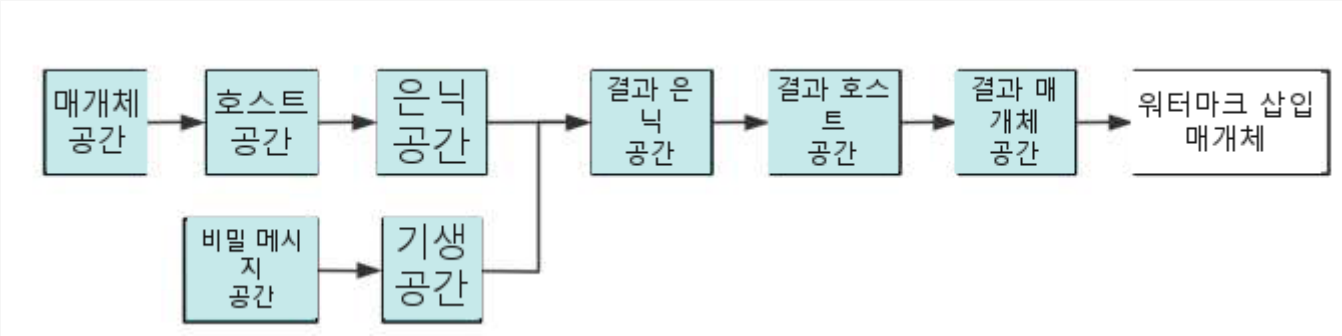
  핵심 포인트: QR 코드 구조(특히 오류 정정 코드의 잉여성)에 대한 이해 및 이중 계층 특수 QR 코드 생성 도구 필요.

스테가노그래피 모델

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 현재 디지털 미디어 매개체 선택에서 스테가노그래피는 일반적으로 정보를 삽입할 잉여 공간이 풍부한 이미지나 비디오를 선택합니다.
- 반면 텍스트는 스테가노그래피 매개체로서 잉여도가 낮지만, 유연하고 콘텐츠 양이 방대하다는 특징이 있어 다른 콘텐츠에 비교적 쉽게 삽입될 수 있습니다. 이번에는 대규모 언어 모델을 중심으로 대규모 모델 스테가노그래피를 소개합니다.
- 스테가노그래피(왼쪽)와 워터마킹(오른쪽) 각각의 프로세스 모델은 아래 그림과 같습니다.

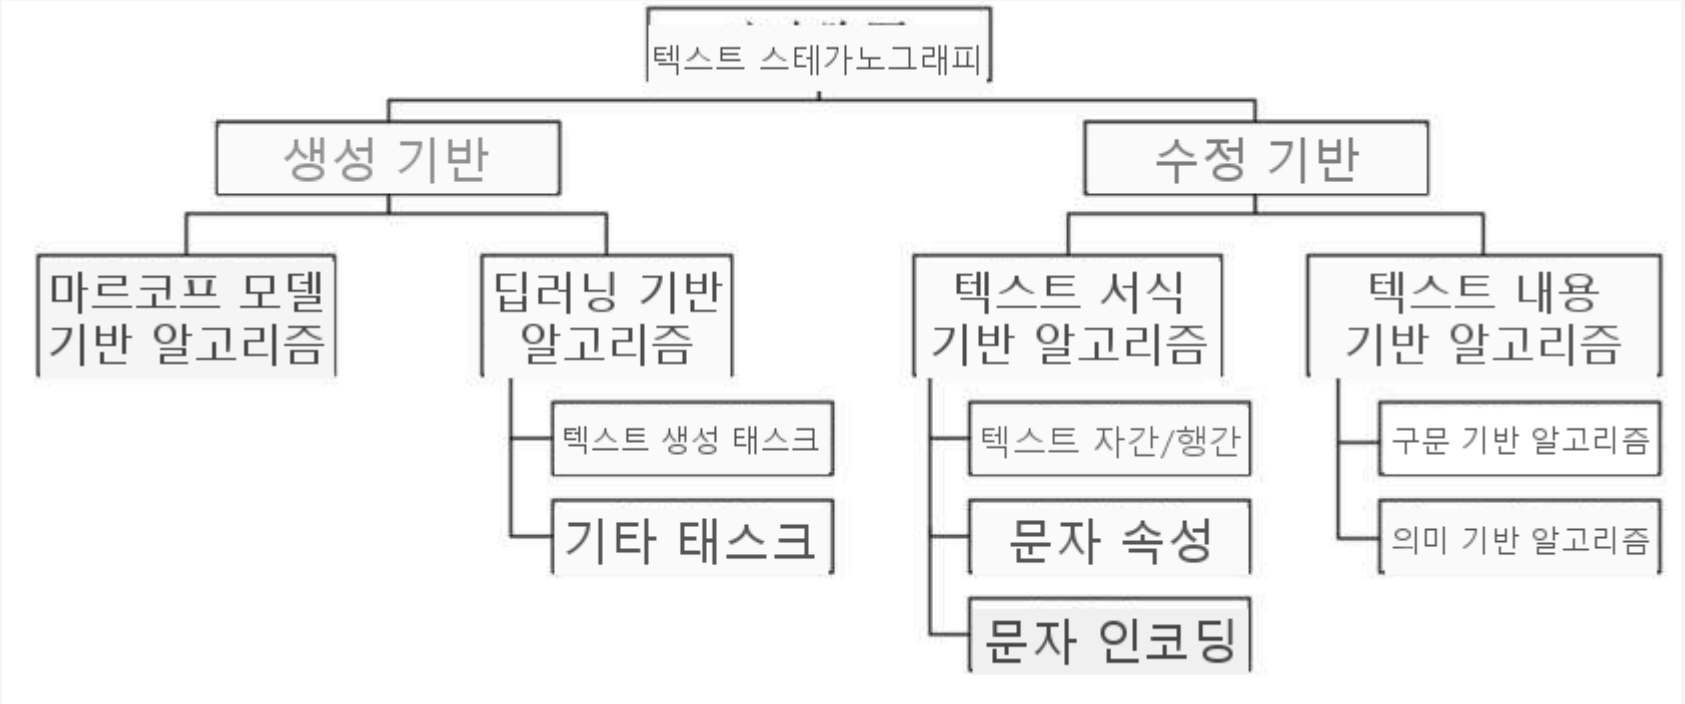




텍스트 스테가노그래피의 분류

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 텍스트 스테가노그래피는 크게 수정 기반(Modification-based)과 생성 기반(Generation-based) 두 가지로 나뉩니다.
- 최근 딥러닝, 특히 대규모 모델의 발전에 따라 생성 기반 텍스트 스테가노그래피가 주류가 되었습니다.

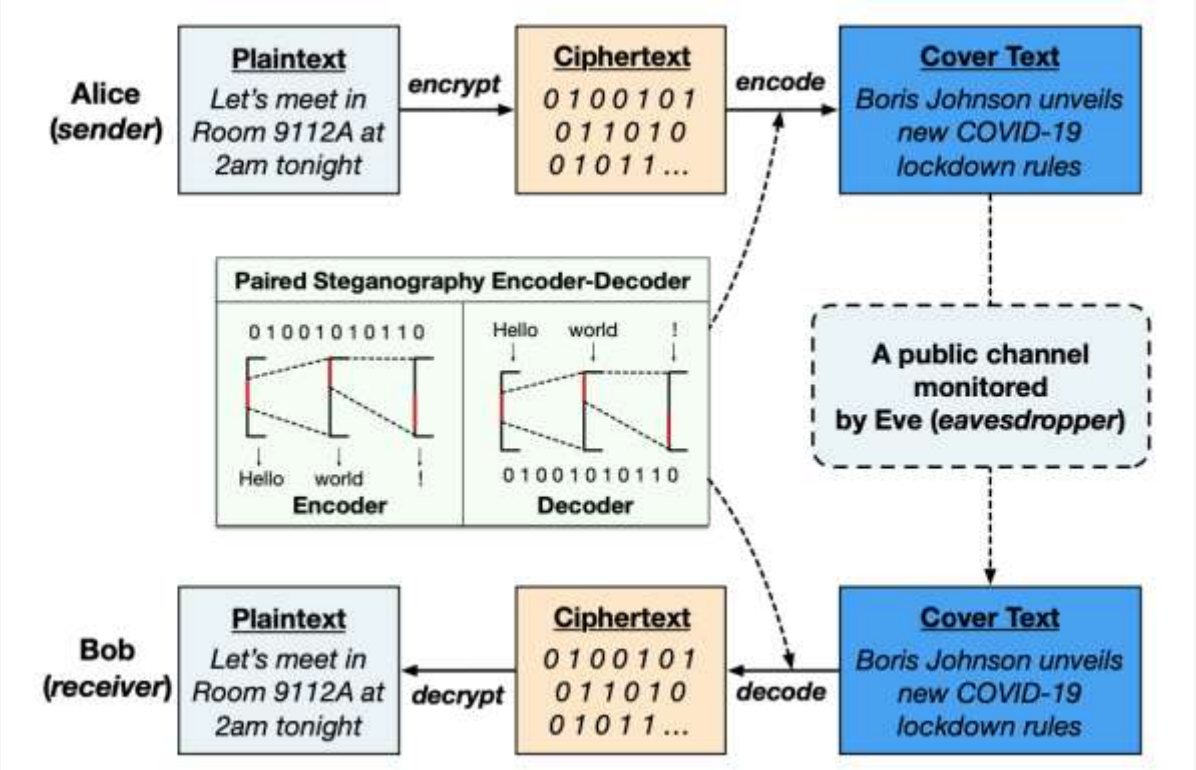


SJTU

대규모 모델 텍스트 스테가노그래피 [1-3]

상하이교통대학 SHANGHAI JIAO TONG UNIVERSITY

- 텍스트 생성 모델은 모두 "직렬화된(시퀀스)" 데이터를 다룹니다.
- 이전 문맥과 각 파라미터를 입력하면, 모델은 "next token"에 대한 예측 logits 테이블을 반환하며, 테이블 내 확률 순으로 token id들이 정렬됩니다.
- 일반적으로 모델은 파라미터에 따라 상위 n개 토큰 중 하나를 무작위 선택하여 반복 생성을 진행합니다.
- 반면 생성 기반 은닉은 추론 시 사전 설정된 규칙에 따라 next token 선택에 개입하여, 삽입하고자 하는 정보를 모델의 생성 텍스트 속으로 직접 삽입합니다.



[1] Yang, Zhong-Liang, et al. "RNN-stega: Linguistic steganography based on recurrent neural networks." IEEE Transactions on Information Forensics and Security 14.5 (2018): 1280-1295.

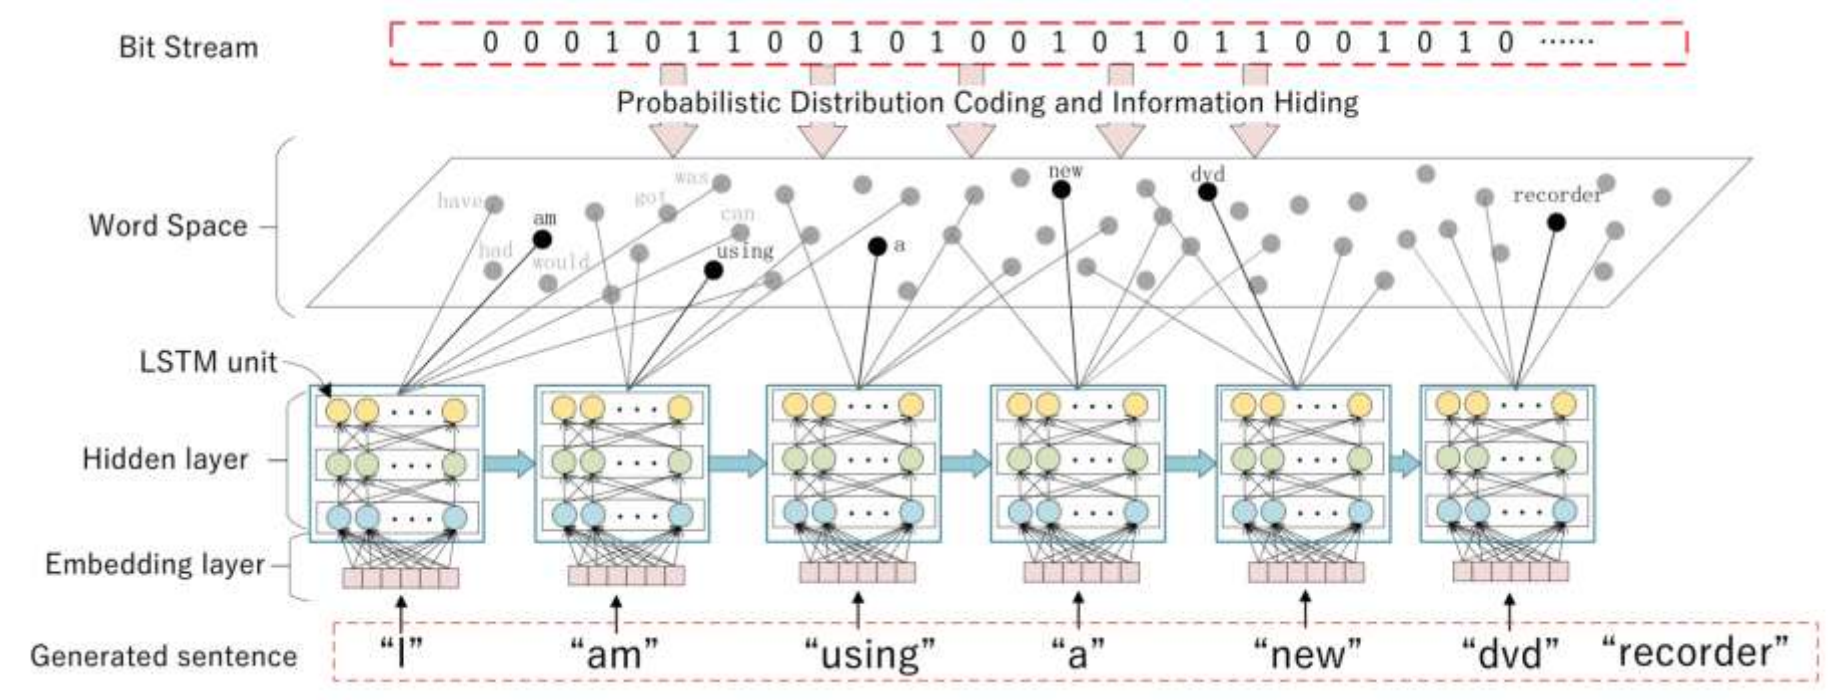
[2] Tang, Yifan, et al. "Linguistic Steganalysis via LLMs: Two Modes for Efficient Detection of Strongly Concealed Stego." IEEE Signal Processing Letters (2024).

[3] Yang, Zhong-Liang, et al. "VAE-Stega: linguistic steganography based on variational auto-encoder." IEEE Transactions on Information Forensics and Security 16 (2020): 880-895.

대규모 모델 텍스트 스테가노그래피

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

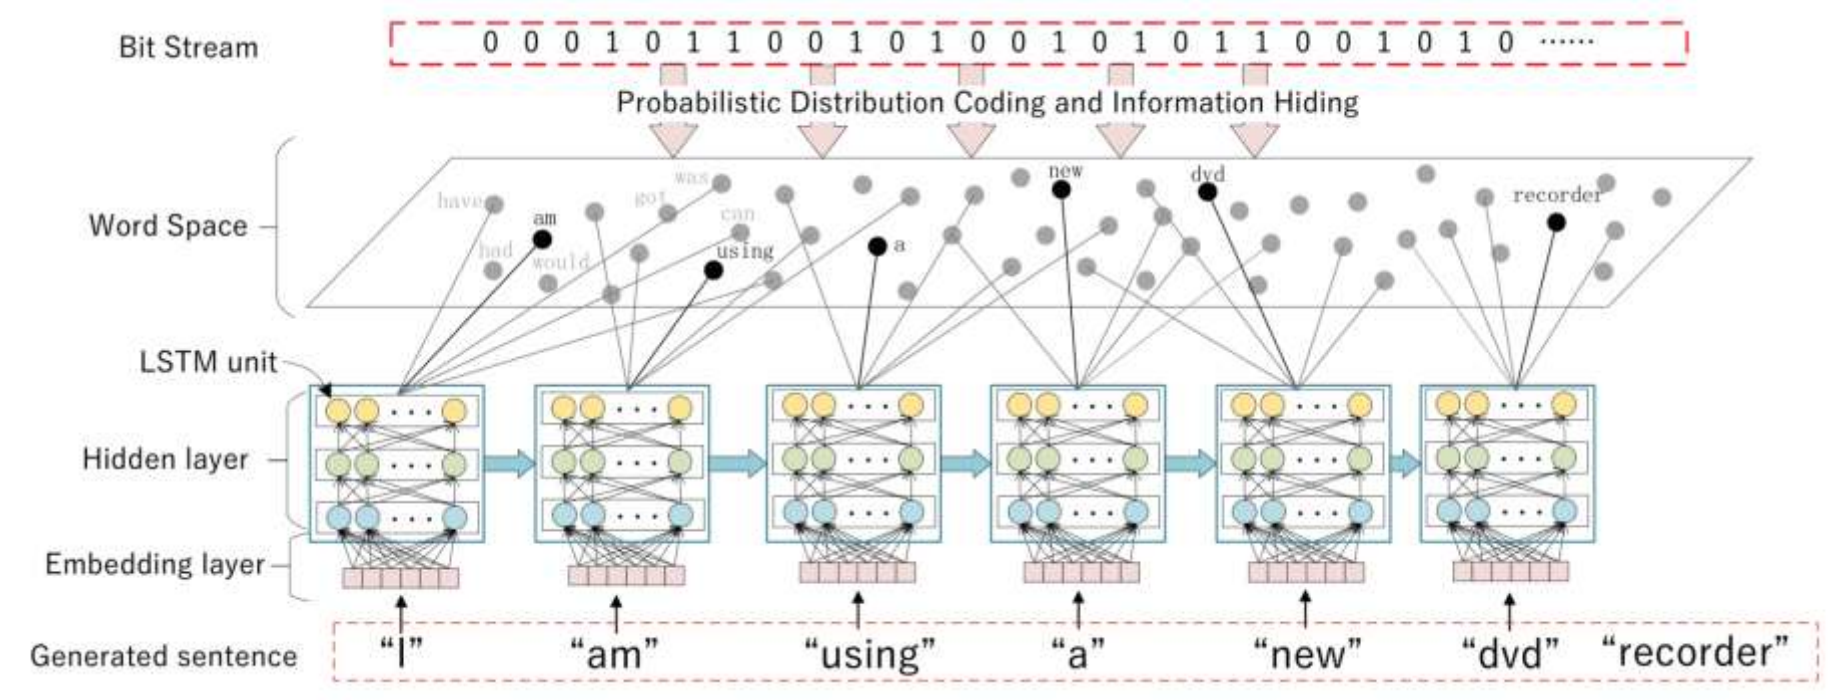
- 아래 그림을 예로 들면, 이진수로 변환된 비밀 정보를 삽입하려 할 때 매번 모델이 반환하는 상위 n개의 next token을 인코딩할 수 있습니다. 예를 들어 "I"를 입력한 후 모델이 반환한 상위 8개 토큰이 확률 순으로 have(000), am(001), was(010), can(011)...이라면 각 토큰은 3비트 이진값에 대응되며, "001"을 은닉 삽입할 때 "am"을 next token으로 선택하고 이후 반복을 계속합니다.



대규모 모델 텍스트 스테가노그래피

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

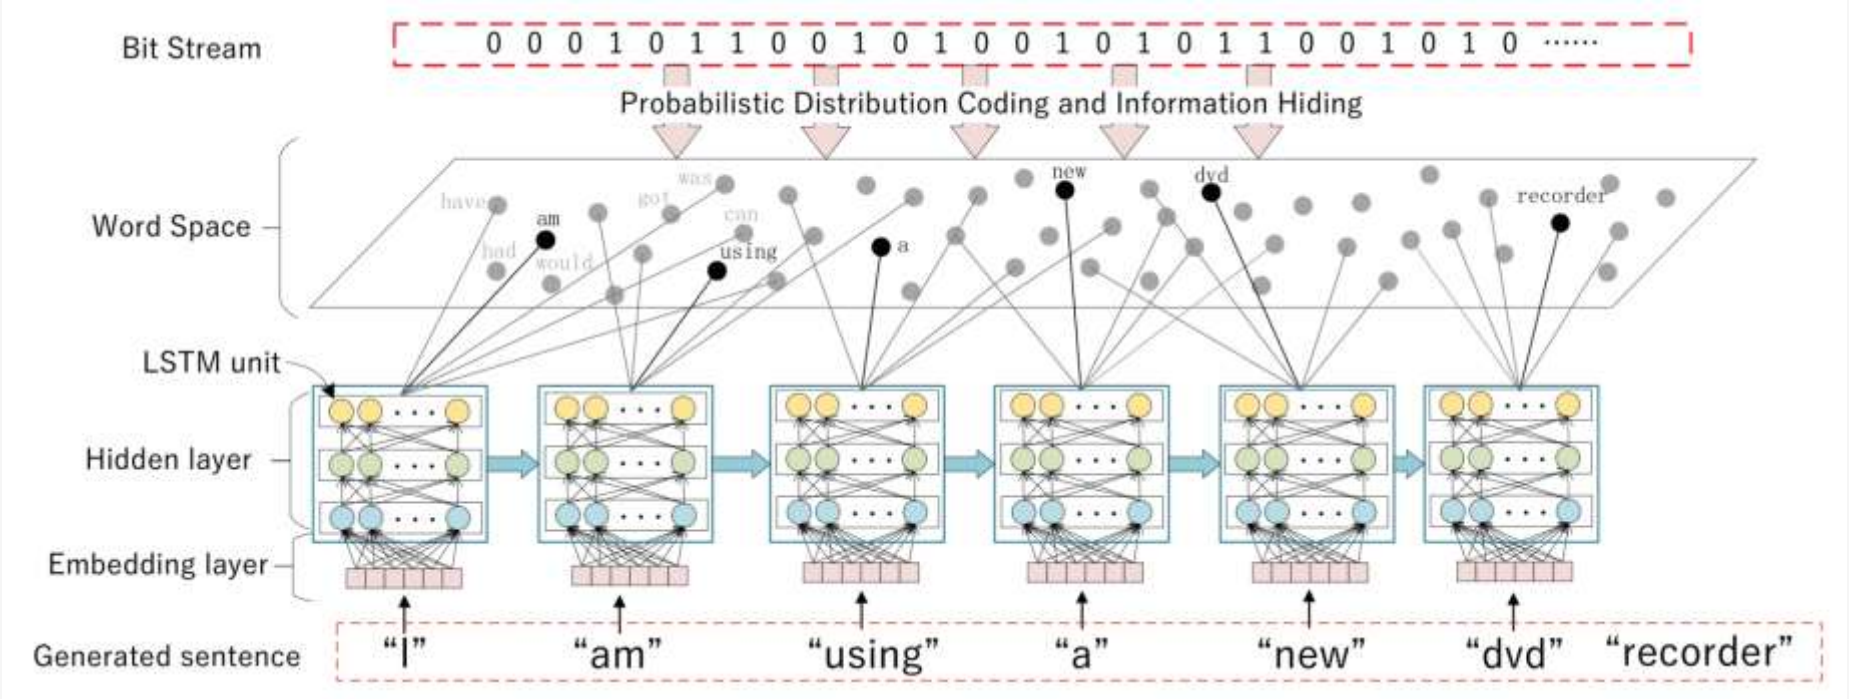
- 이 방법의 본질은 상위 n개 토큰 후보군을 인코딩하여 암묵적인 스테가노그래피 공간을 구축하는 것이며, 정보를 디코딩할 때는 동일한 모델, 문맥, 파라미터를 사용함으로써 매번 모델이 생성 시점과 완전히 동일한 인코딩 공간을 반환하도록 보장하여 토큰으로부터 원래의 이진 정보 스트림을 역추출(예: "am"에서 001을 역디코딩)할 수 있습니다.



대규모 모델 텍스트 스테가노그래피

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 물론 앞서 설명한 방법은 매우 고정적인 인코딩 방식(상위 n개 토큰을 순서대로 직접 인코딩)을 사용했지만, 아래 그림은 실제로 허프만 코딩(Huffman coding) 방식을 사용하여 가능한 한 더 많은 정보를 삽입하고 삽입률을 높입니다.



대규모 모델 스테가노그래피의 의의와 미래

상하이교통대학
SHANGHAI JIAO TONG UNIVERSITY

- 대규모 모델 스테가노그래피: 대규모 모델을 활용한 스테가노그래피의 장점은 모델의 뛰어난 성능을 활용해 더 자연스럽고 발각되기 어려운 **은닉 콘텐츠를 출력할 수 있다는 점입니다.**

- 인코딩 공간: 스테가노그래피의 다양한 기법은 인코딩 방식에 크게 의존하며, 인코딩 공간을 구축하는 새로운 방법이 있다면 **새로운 스테가노그래피 기법을 창출할 수 있습니다.**

- 교차 확장: 대규모 모델 생성 기반 텍스트 스테가노그래피의 본질은 "시퀀스 데이터의 순환 인코딩"이므로, 이 기술은 다른 매체로도 전이될 수 있습니다. 예컨대 DNA도 시퀀스 데이터이므로 장비와 대규모 모델 출력을 결합해 DNA 염기서열에 스테가노그래피를 적용하면 군사적으로 "숨겨진 정보를 물 한 병, 세포 몇 개, 머리카락 몇 올에 은닉"하여 극도로 높은 수준의 은밀한 정보 전달을 구현할 수 있습니다.

- 대규모 모델 워터마킹: 기존의 대규모 모델 워터마킹 기술 또한 스테가노그래피와 상호 결합하여 발전할 수 있습니다. 유명한 KGW 워터마크 역시 **추론 과정에서 next token의 선택을 제약하는 방식을 사용합니다.**

- 콘텐츠 보안: 스테가노그래피의 대응 기술인 "스테그아날리시스(Steganalysis, 은닉 분석)"는 온라인 미디어 콘텐츠 평가 및 필터링 탐지에 활용될 수 있습니다. 키워드 필터에 걸리지 않는 "비꼬기"나 "사이버 불링"도 본질적으로 일종의 "스테가노그래피"이므로, AI가 스테가노그래피 **탐지 기법으로 이를 자동 감지할 가능성이 있으며 이는 미래 사이버 공간의 안전을 수호하는 데 기여할 것입니다.**